

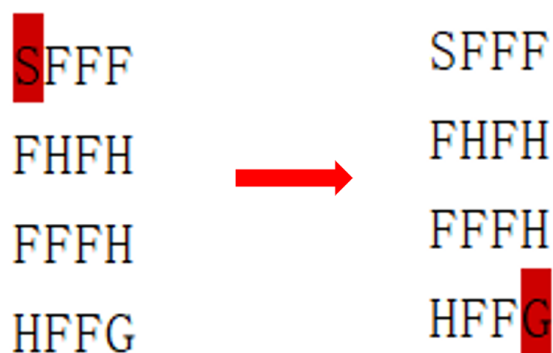
Deep Reinforcement Learning Hands-On——Tabular Learning and the Bellman Equation

作者：凯鲁嘎吉 - 博客园 <http://www.cnblogs.com/kailugaji/>

更多请看：Reinforcement Learning - 随笔分类 - 凯鲁嘎吉 - 博客园 <https://www.cnblogs.com/kailugaji/category/2038931.html>

本文代码下载：<https://github.com/kailugaji/Hands-on-Reinforcement-Learning/tree/main/01%20Tabular%20Learning%20and%20the%20Bellman%20Equation>

这一篇博文参考了书目《[Deep Reinforcement Learning Hands-On Second Edition](#)》第5章与第6章内容，主要学习两个贝尔曼最优方程：最优状态值函数方程： $V^*(s) = \max_a \mathbb{E}_{s' \sim p(s'|s,a)} [r(s,a,s') + \gamma V^*(s')]$ 与最优状态动作值函数： $Q^*(s,a) = \mathbb{E}_{s' \sim p(s'|s,a)} [r(s,a,s') + \gamma \max_{a'} Q^*(s',a')]$ ，并用Python实现对应的值迭代(Value Iteration)算法、Q迭代(Q Iteration)算法与Q学习(Q Learning)算法。值迭代建立的值表仅有状态，而Q迭代建立的值表有动作与状态。所用的游戏环境为FrozenLake-v1，其中S: initial stat 起点，F: frozen lake 冰湖，H: hole 窟窿，G: the goal 目的地，agent要学会从起点走到目的地，并且不要掉进窟窿。



SFFF	SFFF
FHFH	FHFH
FFFH	FFFH
HFFG	HFFG

由于事先随机选择动作建立值表，因此每次得到的结果并非一致。所用的模块的版本为：

```
# packages in environment at D:\ProgramData\Anaconda3\envs\RL:
#
_pytorch_select          1.2.0          gpu            http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
```

absl-py	1.0.0	<pip>	
ale-py	0.7.3	<pip>	
astunparse	1.6.3	<pip>	
atari-py	1.2.2	<pip>	
backcall	0.2.0	pyhd3eb1b0_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
blas	1.0	mkl	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
Box2D	2.3.10	<pip>	
box2d-py	2.3.8	<pip>	
ca-certificates	2021.10.26	haa95532_2	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
cached-property	1.5.2	<pip>	
cachetools	5.0.0	<pip>	
certifi	2020.6.20	py37_0	anaconda
cffi	1.15.0	py37h2bbff1b_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
charset-normalizer	2.0.11	<pip>	
cloudpickle	2.0.0	<pip>	
colorama	0.4.4	pyhd3eb1b0_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
cupshelpers	1.0.1	h74a9793_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
cython	0.29.26	<pip>	
decorator	5.1.0	pyhd3eb1b0_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
fasteners	0.16.3	<pip>	
ffmpeg	1.4	<pip>	
flatbuffers	2.0	<pip>	
fonttools	4.28.5	<pip>	
freetype	2.10.4	hd328e21_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
gast	0.5.3	<pip>	
ghostscript	0.7	<pip>	
glfw	2.5.0	<pip>	
google-auth	2.6.0	<pip>	
google-auth-oauthlib	0.4.6	<pip>	
google-pasta	0.2.0	<pip>	
grpcio	1.43.0	<pip>	
gym	0.21.0	<pip>	
h5py	3.6.0	<pip>	
idna	3.3	<pip>	
imageio	2.13.5	<pip>	
importlib-metadata	2.0.0	py_1	anaconda
importlib-metadata	4.10.0	<pip>	
importlib-resources	5.4.0	<pip>	
intel-openmp	2019.4	245	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
ipython	7.29.0	py37hd4e2768_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
jedi	0.18.0	py37haa95532_1	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
jpeg	9b	hb83a4c4_2	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
keras	2.8.0	<pip>	
Keras-Preprocessing	1.1.2	<pip>	
kiwisolver	1.3.2	<pip>	
libclang	13.0.0	<pip>	

libmklml	2019.0.5	haa95532_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
libpng	1.6.37	h2a8f88b_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
libtiff	4.2.0	hd0e1b90_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
libuv	1.40.0	he774522_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
libwebp	1.2.0	h2bbff1b_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
lockfile	0.12.2	<pip>	
lz4-c	1.9.3	h2bbff1b_1	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
Markdown	3.3.6	<pip>	
matplotlib	3.5.1	<pip>	
matplotlib-inline	0.1.2	pyhd3eb1b0_2	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
mkl	2019.4	245	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
mkl-service	2.3.0	py37h196d8e1_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
mkl_fft	1.3.0	py37h46781fe_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
mkl_random	1.1.0	py37h675688f_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
mujoco-py	1.50.1.68	<pip>	
ninja	1.10.2	py37h559b2a2_3	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
numpy	1.19.2	py37hadc3359_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
numpy	1.21.5	<pip>	
numpy-base	1.19.2	py37ha3acd2a_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
oauthlib	3.2.0	<pip>	
olefile	0.46	pyhd3eb1b0_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
opencv-python	4.5.5.62	<pip>	
openssl	1.0.2t	vc14h62dcd97_0	[vc14] anaconda
opt-einsum	3.3.0	<pip>	
packaging	21.3	<pip>	
parso	0.8.3	pyhd3eb1b0_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
pickleshare	0.7.5	pyhd3eb1b0_1003	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
Pillow	9.0.0	<pip>	
pillow	8.4.0	py37hd45dc43_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
pip	20.2.4	py37_0	anaconda
prompt-toolkit	3.0.20	pyhd3eb1b0_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
protobuf	3.19.4	<pip>	
pyasn1	0.4.8	<pip>	
pyasn1-modules	0.2.8	<pip>	
pycparser	2.21	pyhd3eb1b0_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
pyglet	1.5.21	<pip>	
pygments	2.10.0	pyhd3eb1b0_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
pyparsing	3.0.6	<pip>	
python	3.7.1	h33f27b4_4	anaconda
python-dateutil	2.8.2	<pip>	
pytorch	1.7.1	py3.7_cuda101_cudnn7_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/cloud/pytorch
requests	2.27.1	<pip>	
requests-oauthlib	1.3.1	<pip>	
rsa	4.8	<pip>	
setuptools	50.3.0	py37h9490d1a_1	anaconda
six	1.16.0	pyhd3eb1b0_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
sqlite	3.20.1	vc14h7ce8c62_1	[vc14] anaconda

swig	3.0.12	h047fa9f_3	anaconda
tensorboard	2.8.0	<pip>	
tensorboard-data-server	0.6.1	<pip>	
tensorboard-plugin-wit	1.8.1	<pip>	
tensorboardX	2.4.1	<pip>	
tensorflow	2.8.0	<pip>	
tensorflow-io-gcs-filesystem	0.24.0	<pip>	
termcolor	1.1.0	<pip>	
tf-estimator-nightly	2.8.0.dev2021122109	<pip>	
tk	8.6.11	h2bbff1b_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
torchaudio	0.7.2	py37	http://mirrors.tuna.tsinghua.edu.cn/anaconda/cloud/pytorch
torchvision	0.8.2	py37_cul01	http://mirrors.tuna.tsinghua.edu.cn/anaconda/cloud/pytorch
traitlets	5.1.1	pyhd3eb1b0_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
typing_extensions	4.0.1	<pip>	
typing_extensions	3.10.0.2	pyh06a4308_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
urllib3	1.26.8	<pip>	
vc	14.2	h21ff451_1	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
vs2015_runtime	14.27.29016	h5e58377_2	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
wcwidth	0.2.5	pyhd3eb1b0_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
Werkzeug	2.0.2	<pip>	
wheel	0.37.0	pyhd3eb1b0_1	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
wincertstore	0.2	py37_0	anaconda
wrappers	0.1.9	<pip>	
wrapt	1.13.3	<pip>	
xz	5.2.5	h62dcd97_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
zipp	3.7.0	<pip>	
zipp	3.3.1	py_0	anaconda
zlib	1.2.11	h8cc25b3_4	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main
zstd	1.4.9	h19a0ad4_0	http://mirrors.tuna.tsinghua.edu.cn/anaconda/pkg/main

1. 值迭代(Value Iteration)

1.1 算法流程

输入: MDP 五元组: $\mathcal{S}, \mathcal{A}, P, r, \gamma$;

1 初始化: $\forall s \in \mathcal{S}, V(s) = 0$;

2 **repeat**

3 $\forall s, V(s) \leftarrow \max_a \mathbb{E}_{s' \sim p(s'|s,a)} [r(s, a, s') + \gamma V(s')]$;

4 **until** $\forall s, V(s)$ 收敛;

5 根据公式(14.19) 计算 $Q(s, a)$;

6 $\forall s, \pi(s) = \arg \max_a Q(s, a)$;

输出: 策略 π

$$Q^\pi(s, a) = \mathbb{E}_{s' \sim p(s'|s,a)} [r(s, a, s') + \gamma V^\pi(s')]$$

1.2 Python程序

```
#!/usr/bin/env python3
# -*- coding=utf-8 -*-
# Value iteration for FrozenLake
# https://www.cnblogs.com/kailugaji/
import gym
import collections
from tensorboardX import SummaryWriter
import time
```

```
ENV_NAME = "FrozenLake-v1" #游戏环境
,,,
```

```
S: initial stat 起点
F: frozen lake 冰湖
H: hole 窟窿
```

G: the goal 目的地
agent要学会从起点走到目的地，并且不要掉进窟窿
,,,

GAMMA = 0.9 # 折扣率
TEST_EPISODES = 20 # 玩几局游戏

class Agent: #保存表格，并包含将在训练循环中使用的函数

```
def __init__(self):
    self.env = gym.make(ENV_NAME) #创建游戏环境
    self.state = self.env.reset() # 用于重置环境
    self.rewards = collections.defaultdict(float)
    self.transits = collections.defaultdict(collections.Counter)
    self.values = collections.defaultdict(float)
```

,,,

此功能用于从环境中收集随机经验，并更新奖励和过渡表。
注意，我们不需要等到一局游戏(回合)结束才开始学习；
我们只需执行N个步骤，并记住它们的结果。
这是值迭代和交叉熵方法的区别之一，交叉熵方法只能在完整的回合中学习。
,,,

```
def play_n_random_steps(self, count): # 玩100步，得到回报表与转换表
    for _ in range(count):
        action = self.env.action_space.sample() # 随机采样选择动作
        new_state, reward, is_done, _ = self.env.step(action) # 根据动作，与环境互动得到的新的状态与奖励
        self.rewards[(self.state, action, new_state)] = reward # 回报表：源状态，动作，目标状态
        self.transits[(self.state, action)][new_state] += 1 # 转换表：状态，动作，新状态的概率
        self.state = self.env.reset() if is_done else new_state
```

```
def calc_action_value(self, state, action): # 步骤5: 给定s, a, 计算Q(s, a)
    target_counts = self.transits[(state, action)] # 转换表：状态，动作
    total = sum(target_counts.values())
    action_value = 0.0
    for tgt_state, count in target_counts.items():
        reward = self.rewards[(state, action, tgt_state)] # 回报表：源状态，动作，目标状态
        val = reward + GAMMA * self.values[tgt_state] # 值表只有一个：目标状态
        action_value += (count / total) * val # 期望值——状态动作值函数(Q值)
    return action_value # Q值
```

```
def select_action(self, state): # 步骤6: 给定状态，找最优动作
    best_action, best_value = None, None
    for action in range(self.env.action_space.n): # 遍历所有动作
        action_value = self.calc_action_value(state, action) # 步骤5: Q值
        if best_value is None or best_value < action_value:
            best_value = action_value
            best_action = action
    return best_action # 找使Q值最大的那个动作——最优动作 a = argmax Q(s, a)
```

```

def play_episode(self, env): # 玩一局游戏
    total_reward = 0.0
    state = env.reset() # 用于重置环境
    while True:
        action = self.select_action(state) # 步骤6: 最优动作
        # 不同于"Windows下OpenAI gym环境的使用"中的随机采样动作
        new_state, reward, is_done, _ = env.step(action) # 根据动作, 与环境交互得到的新的状态与奖励
        self.rewards[(state, action, new_state)] = reward # 更新表
        self.transits[(state, action)][new_state] += 1 # 转换表
        total_reward += reward
        if is_done:
            break
        state = new_state
    return total_reward # 得到一局游戏过后的总体奖励

def value_iteration(self): # 值迭代循环
    # 用s状态下可用的动作的最大值来更新当前状态的值
    # 任意s,  $\pi(s) = \arg \max Q(s, a)$ 
    for state in range(self.env.observation_space.n): # 步骤2-4: 遍历状态空间, 找使Q值最大的最优策略
        state_values = [
            self.calc_action_value(state, action) # 计算Q(s, a)
            for action in range(self.env.action_space.n) # 遍历动作空间
        ]
        self.values[state] = max(state_values) # 步骤3: 对于每个状态,  $V(s) = \max Q(s, a)$ 
        # 更新V值表, 最优状态值函数, 贝尔曼最优方程

if __name__ == "__main__":
    test_env = gym.make(ENV_NAME)
    agent = Agent()
    writer = SummaryWriter(comment="-v-iteration")

    iter_no = 0
    best_reward = 0.0
    while True: # 重复试验, 直到20局游戏的平均奖励大于0.8, 迭代终止
        iter_no += 1 # iter_no: 重复试验的迭代次数
        agent.play_n_random_steps(100) # 步骤1: 每一局游戏执行100个随机步骤, 填充回报和转换表
        agent.value_iteration() # 步骤2-4: 100步之后, 对所有的状态进行一次值迭代循环, 更新V值表, 作为策略
        # time.sleep(0.1) #为了让显示变慢, 否则画面会非常快
        # test_env.render() # 用于渲染出当前的智能体以及环境的状态

        reward = 0.0
        for _ in range(TEST_EPISODES): # 玩20局游戏
            reward += agent.play_episode(test_env) # 用到步骤5-6, 20局游戏奖励之和
        reward /= TEST_EPISODES # 20局的平均奖励
        writer.add_scalar("reward", reward, iter_no)
        if reward > best_reward:
            print("Best reward updated %.3f -> %.3f" % (

```

```
        best_reward, reward))
    best_reward = reward # 找到最优的奖励
    if reward > 0.80: # 重复试验次数，直到奖励>0.8，停止迭代
        print("Solved in %d iterations!" % iter_no)
        break
writer.close()
```

1.3 结果

```
Best reward updated 0.000 -> 0.100
Best reward updated 0.100 -> 0.350
Best reward updated 0.350 -> 0.500
Best reward updated 0.500 -> 0.600
Best reward updated 0.600 -> 0.750
Best reward updated 0.750 -> 0.850
Solved in 14 iterations!
```

2. Q迭代(Q Iteration)

2.1 算法流程

输入: 状态空间 \mathcal{S} , 动作空间 \mathcal{A} , 折扣率 γ , 学习率 α

- 1 $\forall s, \forall a$, 随机初始化 $Q(s, a)$; 根据 Q 函数构建策略 π ;
- 2 **repeat**
 - 3 初始化起始状态 s ;
 - 4 **repeat**
 - 5 在状态 s , 选择动作 $a = \pi^\epsilon(s)$;
 - 6 执行动作 a , 得到即时奖励 r 和新状态 s' ;
 - 7 $Q(s, a) \leftarrow \mathbb{E}_{s' \sim p(s'|s, a)} [r(s, a, s') + \gamma \max_{a'} Q(s', a')]$;
 - 8 $s \leftarrow s'$;
 - 9 **until** s 为终止状态;
- 10 **until** $\forall s, a, Q(s, a)$ 收敛;

输出: 策略 $\pi(s) = \arg \max_{a \in |\mathcal{A}|} Q(s, a)$

2.2 Python程序

```
#!/usr/bin/env python3
# -*- coding=utf-8 -*-
# Q-learning for FrozenLake
# 1. 值表变了。上例保留了状态的值，因此字典中的键只是一个状态。
```

```

# 现在需要存储Q函数的值，它有两个参数：状态和动作，因此值表中的键现在是复合键。
# 2. 不需要calc_action_value()函数。因为我们的动作值存储在值表中。
# 3. value_iteration()变了。
# https://www.cnblogs.com/kailugaji/
import gym
import collections
from tensorboardX import SummaryWriter

ENV_NAME = "FrozenLake-v1" #游戏环境
,,,

S: initial stat 起点
F: frozen lake 冰湖
H: hole 窟窿
G: the goal 目的地
agent要学会从起点走到目的地，并且不要掉进窟窿
,,,

GAMMA = 0.9 # 折扣率
TEST_EPISODES = 20 # 玩几局游戏

class Agent:
    def __init__(self):
        self.env = gym.make(ENV_NAME) #创建游戏环境
        self.state = self.env.reset() # 用于重置环境
        self.rewards = collections.defaultdict(float)
        self.transits = collections.defaultdict(collections.Counter)
        self.values = collections.defaultdict(float)

    def play_n_random_steps(self, count): # 玩100步，得到回报表与转换表
        for _ in range(count):
            action = self.env.action_space.sample() # 随机采样选择动作
            new_state, reward, is_done, _ = self.env.step(action) # 根据动作，与环境互动得到的新的状态与奖励
            self.rewards[(self.state, action, new_state)] = reward # 回报表：源状态，动作，目标状态
            self.transits[(self.state, action)][new_state] += 1 # 转换表：状态，动作
            self.state = self.env.reset() if is_done else new_state

    def select_action(self, state): # 给定状态s, a = argmax Q(s, a)
        best_action, best_value = None, None
        for action in range(self.env.action_space.n): # 遍历所有动作
            action_value = self.values[(state, action)] # Q值表里有两个：状态与动作
            if best_value is None or best_value < action_value:
                best_value = action_value
                best_action = action
        return best_action # 直接建立Q表，从Q值表里找最优动作

    def play_episode(self, env): # 玩一局游戏
        total_reward = 0.0

```

```

state = env.reset() # 用于重置环境
while True:
    action = self.select_action(state) # 给定状态s, 最优动作a = argmax Q(s, a)
    new_state, reward, is_done, _ = env.step(action) # 根据动作, 与环境交互得到的新的状态与奖励
    self.rewards[(state, action, new_state)] = reward # 更新表
    self.transits[(state, action)][new_state] += 1
    total_reward += reward
    if is_done:
        break
    state = new_state # 步骤8
return total_reward # 得到一局游戏过后的总体奖励

def value_iteration(self): # 变了
# 选择具有最大Q值的动作, 然后把这个Q值作为目标状态的值
    for state in range(self.env.observation_space.n): # 步骤2-10: 其中3: 遍历状态空间
        for action in range(self.env.action_space.n): # 步骤4-9: 遍历动作空间
            action_value = 0.0
            target_counts = self.transits[(state, action)] # 转换表: 状态, 动作
            total = sum(target_counts.values())
            for tgt_state, count in target_counts.items():
                reward = self.rewards[(state, action, tgt_state)] # 回报表: 源状态, 动作, 目标状态
                best_action = self.select_action(tgt_state) # 给定状态s, 最优动作a = argmax Q(s, a)
                val = reward + GAMMA * self.values[(tgt_state, best_action)] # 值表: 目标状态, 最优动作
                action_value += (count / total) * val # 期望值——最优状态动作值函数(Q值)(其中动作为最优动作)
                # 贝尔曼最优方程
            self.values[(state, action)] = action_value # 更新Q值表: 状态, 动作

if __name__ == "__main__":
    test_env = gym.make(ENV_NAME)
    agent = Agent()
    writer = SummaryWriter(comment="-q-iteration")

    iter_no = 0
    best_reward = 0.0
    while True: # 重复试验, 直到20局游戏的平均奖励大于0.8, 迭代终止
        iter_no += 1 # iter_no: 重复试验的迭代次数
        agent.play_n_random_steps(100) # 步骤1: 每一局游戏执行100个随机步骤, 填充回报和转换表
        agent.value_iteration() # 步骤2-10: 100步之后, 对所有的状态进行一次值迭代循环, 更新Q值表, 作为策略
        # time.sleep(0.1) #为了让显示变慢, 否则画面会非常快
        # test_env.render() # 用于渲染出当前的智能体以及环境的状态

        reward = 0.0
        for _ in range(TEST_EPISODES): # 玩20局游戏
            reward += agent.play_episode(test_env) # 20局游戏奖励之和
        reward /= TEST_EPISODES # 20局的平均奖励
        writer.add_scalar("reward", reward, iter_no)
        if reward > best_reward:

```

```
        print("Best reward updated %.3f -> %.3f" % (best_reward, reward))
        best_reward = reward # 找到最优的奖励
    if reward > 0.80: # 重复试验次数，直到奖励>0.8，停止迭代
        print("Solved in %d iterations!" % iter_no)
        break
writer.close()
```

2.3 结果

```
Best reward updated 0.000 -> 0.250
Best reward updated 0.250 -> 0.300
Best reward updated 0.300 -> 0.500
Best reward updated 0.500 -> 0.600
Best reward updated 0.600 -> 0.850
Solved in 33 iterations!
```

3. Q学习(Tabular Q-Learning)

3.1 算法流程

输入: 状态空间 \mathcal{S} , 动作空间 \mathcal{A} , 折扣率 γ , 学习率 α

1 $\forall s, \forall a$, 随机初始化 $Q(s, a)$; 根据 Q 函数构建策略 π ;

2 **repeat**

3 初始化起始状态 s ;

4 **repeat**

5 在状态 s , 选择动作 $a = \pi^\epsilon(s)$;

6 执行动作 a , 得到即时奖励 r 和新状态 s' ;

7 $Q(s, a) \leftarrow (1 - \alpha)Q(s, a) + \alpha(r(s, a, s') + \gamma \max_{a'} Q(s', a'))$

8 $s \leftarrow s'$;

9 **until** s 为终止状态;

10 **until** $\forall s, a, Q(s, a)$ 收敛;

输出: 策略 $\pi(s) = \arg \max_{a \in |\mathcal{A}|} Q(s, a)$

3.2 Python程序

```
#!/usr/bin/env python3
# -*- coding=utf-8 -*-
# Q-learning for FrozenLake
# https://www.cnblogs.com/kailugaji/
# 与上一个值迭代法相比, 这个版本使用了更多的迭代来解决问题。
# 其原因是不再使用测试过程中获得的经验。
# 在上一个Q迭代例子中, 周期性的测试会引起Q表统计的更新。
```

本算法在测试过程中不接触Q值，这在环境得到解决之前会造成更多的迭代。
总的来说，环境所需的样本总数几乎是一样的。

```
import gym
import collections
from tensorboardX import SummaryWriter
```

```
ENV_NAME = "FrozenLake-v1"
GAMMA = 0.9 # 折扣率
ALPHA = 0.2 # 平滑指数
TEST_EPISODES = 20 # 玩几局游戏
```

```
class Agent:
    def __init__(self):
        self.env = gym.make(ENV_NAME)
        self.state = self.env.reset()
        self.values = collections.defaultdict(float)

    def sample_env(self): # 随机采样动作
        action = self.env.action_space.sample()
        old_state = self.state
        new_state, reward, is_done, _ = self.env.step(action)
        self.state = self.env.reset() if is_done else new_state
        return old_state, action, reward, new_state

    def best_value_and_action(self, state): # 从Q表中选择最优值与动作
        best_value, best_action = None, None
        for action in range(self.env.action_space.n):
            action_value = self.values[(state, action)]
            if best_value is None or best_value < action_value:
                best_value = action_value
                best_action = action
        return best_value, best_action

    def value_update(self, s, a, r, next_s): # 平滑
        best_v, _ = self.best_value_and_action(next_s)
        new_v = r + GAMMA * best_v #  $r(s, a, s') + \gamma * \max Q(s, a)$ 
        old_v = self.values[(s, a)]
        self.values[(s, a)] = old_v * (1-ALPHA) + new_v * ALPHA # 这变了，Q值平滑收敛
        #  $Q(s, a) \leftarrow (1-\alpha) * Q(s, a) + \alpha * (r(s, a, s') + \gamma * \max Q(s, a))$ 

    def play_episode(self, env): # 玩一局游戏
        total_reward = 0.0
        state = env.reset()
        while True:
            _, action = self.best_value_and_action(state) # 给定状态，从Q表中选择最优动作
            new_state, reward, is_done, _ = env.step(action)
            total_reward += reward
```

```

        if is_done:
            break
        state = new_state
    return total_reward

if __name__ == "__main__":
    test_env = gym.make(ENV_NAME)
    agent = Agent()
    writer = SummaryWriter(comment="-q-learning")

    iter_no = 0
    best_reward = 0.0
    while True:
        iter_no += 1
        s, a, r, next_s = agent.sample_env() # 执行一个随机步骤
        agent.value_update(s, a, r, next_s)

        reward = 0.0
        for _ in range(TEST_EPISODES):
            reward += agent.play_episode(test_env)
        reward /= TEST_EPISODES
        writer.add_scalar("reward", reward, iter_no)
        if reward > best_reward:
            print("Best reward updated %.3f -> %.3f" % (
                best_reward, reward))
            best_reward = reward
        if reward > 0.80:
            print("Solved in %d iterations!" % iter_no)
            break
    writer.close()

```

3.3 结果

```

Best reward updated 0.000 -> 0.200
Best reward updated 0.200 -> 0.250
Best reward updated 0.250 -> 0.350
Best reward updated 0.350 -> 0.500
Best reward updated 0.500 -> 0.550
Best reward updated 0.550 -> 0.600
Best reward updated 0.600 -> 0.650
Best reward updated 0.650 -> 0.700
Best reward updated 0.700 -> 0.800
Best reward updated 0.800 -> 0.850
Solved in 16682 iterations!

```

4. 参考文献

- [1] <https://github.com/PacktPublishing/Deep-Reinforcement-Learning-Hands-On-Second-Edition>
- [2] 邱锡鹏, 神经网络与深度学习, 机械工业出版社, <https://nndl.github.io/>, 2020.
- [3] [强化学习\(Reinforcement Learning\)](#)