

I-Con: A UNIFYING FRAMEWORK FOR REPRESENTATION LEARNING

Shaden Alshammari, John Hershey, Axel Feldmann¹ William T. Freeman, Mark Hamilton

译文：机翻。最终呈现：凯鲁嘎吉 - 博客园 <http://www.cnblogs.com/kailugaji/>

		Supervisory Signal								
		Gaussian	Student-T	Identity	Graph Kernel Weights	Uniform over K-Neighbors	Uniform over Positive Pairs	Cross-Modal Pairs	Uniform over Classes	Data-Label Pairs
Learned Representation	Gaussian	SNE [Hinton 2002]	Dual t-SNE		SNE Graph Embeddings	SNE with Uniform Affinities	InfoNCE [Bachman 2019]	CLIP [Radford 2021]	SupCon [Khosla 2020]	Cross Entropy [Good 1963]
		X-Sample CL [Sobal 2025]				SimCLR [Chen 2020]	CMC [Tian 2020]			
						LGSimCLR [El Banani 2023]		MoCoV3 [Chen 2021]		
	Gaussian $\sigma \rightarrow \infty$			PCA [Pearson 1901]			VI-Reg [Bardes 2021]	Average Margin CLIP	Average Margin SupCon	
	Gaussian $\sigma \rightarrow 0$						Triplet Loss [Schroff 2015]	Triplet CLIP	Triplet SupCon	Error rate
Student-T	t-SNE [Van der Maaten 2008]	Doubly t-SNE		t-SNE Graph Embedding	t-SNE with Uniform Affinities	t-SimCNE [Böhm 2023]	t-CLIP	t-SupCon	Harmonic Loss [Baek 2025]	
	t-SimCLR [Hu 2023]									
Uniform on Clusters	K-Means [Macqueen 1967]	t K-Means		Normalized Cuts [Shi 2000]	DCD [Yang 2012]	InfoNCE Clustering [Ours]		Supervised Clustering		
		Dimensionality Reduction	Cluster Learning	Unimodal SSL	Multimodal SSL	Supervised Learning	Interpretation of Gaps			

图 1: 由 I-Con 框架统一的表征学习方法。通过选择不同类型的邻居条件概率分布, I-Con 对 23 种常用的表征学习方法进行了概括。

1 信息对比学习

令 $i, j \in \mathcal{X}$ 是数据集 $\mathcal{X}$ 的元素, 具有定义转移概率的概率邻域函数 $p(j|i)$ 。为了确保有效的概率分布, 必须满足 $p(j|i) \geq 0$ 和 $\int_{j \in \mathcal{X}} p(j|i) = 1$ 。我们通过 $\theta \in \Theta$ 对该分布进行参数化, 以创建一个可学习的函数 $p_\theta(j|i)$ 。类似地, 我们定义另一个由 $\phi \in \Phi$ 参数化的分布 $q_\phi(j|i)$ 。核心 I-Con 损失函数为:

$$\mathcal{L}(\theta, \phi) = \int_{i \in \mathcal{X}} D_{\text{KL}}(p_\theta(\cdot|i) || q_\phi(\cdot|i)) = \int_{i \in \mathcal{X}} \int_{j \in \mathcal{X}} p_\theta(j|i) \log \frac{p_\theta(j|i)}{q_\phi(j|i)}. \quad (1)$$

在实践中, p 通常是一个固定的“监督”分布, 而 q_ϕ 是通过比较深度网络表征、原型或簇来学习的。图 2 说明了这一对齐过程。优化过程将 q_ϕ 与 p 对齐, 最小化它们的 KL 散度。尽管大多数现有方法仅优化 q_ϕ , 但 I-Con 也允许同时学习 p_θ 和 q_ϕ , 尽管必须小心以防止出现平凡解。




图 2: I-Con框架概述

2 用I-Con创建新的表征学习器

I-Con框架将表示学习的各种方法统一在一个单一的数学公式下，并且至关重要，它促进了不同领域之间技术的转移。例如，对比学习的技巧可以应用于聚类，反之亦然。在本文中，我们展示了测量现代表征方法如何使聚类和无监督分类算法的发展超越以前的性能水平。具体来说，我们整合了谱聚类，t-SNE和去偏见对比学习(Chuang et al., 2020)的见解，以构建最先进的无监督图像分类管道。

2.1 去偏

去偏对比学习 (Debiased Contrastive Learning, DCL) 解决了在对比学习中由于随机负抽样而导致的不匹配问题，特别是在类数较少的情况下。随机选择的否定可能变成积极的，在类似的例子之间引入虚假的排斥力。Chuang et al. (2020)通过减去这些虚假的排斥项和增强吸引力来纠正这一点，从而大大提高了表示质量。然而，他们的方法修改了softmax本身，这意味着 $q_{j|i}$ 不再是一个真正的概率分布，并且使得将该方法扩展到聚类或监督任务变得更加困难。

我们的观点，基于I-Con框架，提出了一个更简单和更通用的选择：而不是调整学习分布 $q_{j|i}$ ，我们将额外的“不确定性”直接纳入监督分布 $p(j|i)$ 。这保留了 $q_{j|i}$ 作为一个有效的分布，并使该方法适用于超越对比学习的任务。

2.2 均匀分布去偏

我们的第一个例子采用了一个简单的均匀混合物：

$$\tilde{p}(j|i) = (1 - \alpha)p(j|i) + \frac{\alpha}{N},$$

其中 N 是局部邻域大小， α 指定混合的程度。这种方法为每个“负”样本分配一个小的概率质量 $\frac{\alpha}{N}$ ，从而减轻过于自信的分配。在监督上下文中，这类似于标签平滑 (Szegedy et al., 2016)。相比之下，Chuang et al. (2020) 在保留独热标签的同时调整了 softmax 函数本身。

另一种看待此方法的方式是通过重尾或更广泛分布的视角。通过添加一个均匀成分，我们反映了 t-SNE 的 Student- t 分布的思想 (Van der Maaten & Hinton, 2008)，该分布为远离的点分配了更大的质量。在这两种情况下，扩展分布减少了对狭义定义的邻居集的过拟合机会。

2.3 邻居传播去偏

第二种策略应用基于图的扩展。用度加权的 k -最近邻替换 k-Means 的高斯邻域可以恢复谱聚类，该方法以其稳健的高质量解决方案而闻名。在此基础上，我们使用基于 KNN 的邻域定义训练对比学习者。给定最近邻图，我们可以通过进行更长的游走进一步扩展它，这类似于 Word-Graph2Vec 或 tsNET (Li et al., 2023; Kruiger et al., 2017)，我们将这一过程称为 邻居传播 (neighbor propagation)。

形式上，设 P 为条件分布矩阵，其条目 $P_{ij} = p(x_j | x_i)$ 定义了选择 x_j 作为 x_i 的邻居的概率。将 P 解释为训练数据的邻接矩阵，我们可以通过对 P 的幂求和，平滑它，直到长度 k ：

$$\tilde{P} \propto P + P^2 + \dots + P^k.$$

我们可以通过对所有在 k 步内可达的点进行均匀分布来进一步简化这一点，表示为：

$$\tilde{P}_U \propto I[P + P^2 + \dots + P^k > 0],$$

其中 $I[\cdot]$ 是指示函数。基于游走的平滑方法扩展了有效邻域，使得模型能够从更密集的监督信号中学习。

3 统一降维方法及其证明

我们首先定义在 I-Con 背景下的降维方法的设置。令 $x_i \in \mathbb{R}^d$ 表示高维数据点， $\phi_i \in \mathbb{R}^m$ 表示其对应的低维嵌入，其中 $m \ll d$ 。降维方法的目标，例如随机邻居嵌入 (SNE) 和 t-分布随机邻居嵌入 (t-SNE)，是学习这些嵌入，使得高维空间中的邻域结构在低维空间中得以保留。在此背景下，低维嵌入 ϕ_i 可以被解释为映射函数 $f_\theta(x_i)$ 的输出，其中 f_θ 本质上是一个嵌入矩阵或查找表。I-Con 框架非常适合通过两个邻域分布之间的 KL 散度损失来表达这种关系：一个在高维空间中，另一个在低维空间中。

方法	$p_\theta(j i)$ 的选取	$q_\phi(j i)$ 的选取
(A) 降维		
SNE (Hinton & Roweis, 2002) Theorem 1	Gaussian over data points, x_i	Gaussian over learned low-dimensional points, ϕ_i $\frac{\exp(-\ \phi_i - \phi_j\ ^2)}{\sum_{k \neq i} \exp(-\ \phi_i - \phi_k\ ^2)}$
t-SNE (Van der Maaten & Hinton, 2008) Corollary 1	$\frac{\exp(-\ x_i - x_j\ ^2/2\sigma_i^2)}{\sum_{k \neq i} \exp(-\ x_i - x_k\ ^2/2\sigma_i^2)}$	Cauchy distribution over ϕ_i $\frac{(1 + \ \phi_i - \phi_j\ ^2)^{-1}}{\sum_{k \neq i} (1 + \ \phi_i - \phi_k\ ^2)^{-1}}$
PCA (Pearson, 1901) Theorem 2	$\mathbb{1}[i = j]$	Wide Gaussian on linear projection features, $f_\phi(x_i)$ $\lim_{\sigma \rightarrow \infty} \frac{\exp(-\ f_\phi(x_i) - f_\phi(x_j)\ ^2/2\sigma^2)}{\sum_{k \neq i} \exp(-\ f_\phi(x_i) - f_\phi(x_k)\ ^2/2\sigma^2)}$

Theorem 1. 随机邻居嵌入 (SNE) ([Hinton & Roweis, 2002](#)) 是 I-Con 框架的一个实例。

证明. 这是本文中最直接的证明之一，本质上是基于 SNE 的定义。目标分布（监督部分）由高维空间中的邻域分布描述，由下式给出：

$$p_\theta(j|i) = \frac{\exp(-\|x_i - x_j\|^2/2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|^2/2\sigma_i^2)},$$

而学习到的低维邻域分布为：

$$q_\phi(j|i) = \frac{\exp(-\|\phi_i - \phi_j\|^2)}{\sum_{k \neq i} \exp(-\|\phi_i - \phi_k\|^2)}.$$

目标是最小化这些分布之间的 KL 差异：

$$\mathcal{L} = \sum_i D_{\text{KL}}(p_\theta(\cdot|i) \| q_\phi(\cdot|i)) = \sum_i \sum_j p_\theta(j|i) \log \frac{p_\theta(j|i)}{q_\phi(j|i)}.$$

嵌入 θ_i 是通过最小化 $\mathcal{L}$ 来隐式学习的。映射器是一个嵌入矩阵，因为 SNE 是一个非参数优化。因此，SNE 是 I-Con 框架的一个特例，其中 $p_\theta(j|i)$ 和 $q_\phi(j|i)$ 分别表示高维和低维空间中的邻域概率。□

Corollary 1 (t-SNE ([Van der Maaten & Hinton, 2008](#))). t-SNE 是 I-Con 框架的一个实例。

证明. 这个证明和 SNE 的证明很相似。虽然高维目标分布 $p_\theta(j|i)$ 保持不变，但 t-SNE 将低维分布修改为一个自由度的 Student's t 分布（Cauchy 分布）：

$$q_\phi(j|i) = \frac{(1 + \|\phi_i - \phi_j\|^2)^{-1}}{\sum_{k \neq i} (1 + \|\phi_i - \phi_k\|^2)^{-1}}.$$

目标仍然是尽量减少 KL 差异。因此，t-SNE 是 I-Con 框架的一个实例。□

下面是主成分分析（PCA）的证明。

Proposition 1. 令 $X := \{x_i\}_{i=1}^n$ ，那么下面的凝聚方差损失

$$\mathcal{L}_{\text{cohesion-var}} = \frac{1}{n} \sum_{ij} w_{ij} \|f_\phi(x_i) - f_\phi(x_j)\|^2 - 2\text{Var}(X)$$

在特殊情况下是 $I - \text{Con}$ 的实例，其中 $w_{ij} = p(j|i)$ 和 q_ϕ 是高斯分布，其宽度和 $\sigma \rightarrow \infty$ 一样大。

证明. 利用AM-GM不等式，得到

$$\frac{1}{n} \sum_{k=1}^n e^{-z_k} \geq (\prod_{k=1}^n e^{-z_k})^{\frac{1}{n}} \implies \frac{1}{n} \sum_{k=1}^n e^{-z_k} \geq (e^{-\sum_{k=1}^n z_k})^{\frac{1}{n}}$$

这意味着

$$\log \sum_{k=1}^n e^{-z_k} - \log n \geq \log \left(e^{-\sum_{k=1}^n z_k} \right)^{\frac{1}{n}} \implies \log \sum_{k=1}^n e^{-z_k} \geq -\frac{1}{n} \sum_{k=1}^n z_k + \log(n)$$

或者，它可以写成

$$-\log \sum_{k=1}^n e^{-z_k} \leq \frac{1}{n} \sum_{k=1}^n z_k - \log(n)$$

现在假设我们有一个高斯核 q_ϕ

$$q_\phi(j|i) = \frac{\exp(-\|f_\phi(x_i) - f_\phi(x_j)\|^2/\sigma^2)}{\sum_{k \neq i} \exp(-\|f_\phi(x_i) - f_\phi(x_k)\|^2/\sigma^2)},$$

因此，考虑到我们上面展示的指数和不等式，我们有

$$\begin{aligned} \log q_\phi(j|i) &= -\frac{\|f_\phi(x_i) - f_\phi(x_j)\|^2}{\sigma^2} - \log \sum_{k \neq i} \exp\left(-\frac{\|f_\phi(x_i) - f_\phi(x_k)\|^2}{\sigma^2}\right) \\ &\leq -\frac{1}{\sigma^2} \|f_\phi(x_i) - f_\phi(x_j)\|^2 + \frac{1}{n\sigma^2} \sum_{k \neq i} \|f_\phi(x_i) - f_\phi(x_k)\|^2 - \log(n) \\ &= -\frac{1}{\sigma^2} (-\|f_\phi(x_i) - f_\phi(x_j)\|^2 + \frac{1}{n} \sum_{k \neq i} \|f_\phi(x_i) - f_\phi(x_k)\|^2) - \log(n) \end{aligned}$$

因此，交叉熵 $H(p_\theta, q_\phi)$ 是有界的

$$\begin{aligned} H(p_\theta, q_\phi) &= -\frac{1}{n} \sum_i \sum_j p(j|i) \log q_\phi(j|i) \\ &\leq \frac{1}{n} \sum_i \sum_j p(j|i) \left(\frac{1}{\sigma^2} (-\|f_\phi(x_i) - f_\phi(x_j)\|^2 + \frac{1}{n} \sum_{k \neq i} \|f_\phi(x_i) - f_\phi(x_k)\|^2) - \log(n) \right) \\ &= \frac{1}{\sigma^2} \left(\frac{1}{n} \sum_{ij} p(j|i) \|f_\phi(x_i) - f_\phi(x_j)\|^2 - \frac{1}{n^2} \sum_{ijk} p(j|i) \|f_\phi(x_i) - f_\phi(x_k)\|^2 \right) - \log(n) \\ &= \frac{1}{\sigma^2} \left(\frac{1}{n} \sum_{ij} p(j|i) \|f_\phi(x_i) - f_\phi(x_j)\|^2 - 2\text{Var}(X) \right) + \log(n) \\ &= \frac{1}{\sigma^2} \left(\frac{1}{n} \sum_{ij} p(j|i) \|f_\phi(x_i) - f_\phi(x_j)\|^2 - 2\text{Var}(X) \right) + \log(n) \\ &= \frac{1}{\sigma^2} \mathcal{L}_{\text{cohesion-var}} + \log(n) \end{aligned}$$

另一方面, L.H.S. 可以通过使用二阶界限 $e^{-z} \leq 1 - z + z^2/2$ 来上界, 这意味着

$$-\log \sum_{k=1}^n e^{-z_k} \geq \log(1 - \frac{1}{n} \sum_{k=1}^n z_k + \frac{1}{n} \sum_{k=1}^n z_k^2) - \log(n)$$

另一方面, $\log(1 + u) \geq u - u^2/2$, 因此,

$$-\log \sum_{k=1}^n e^{-z_k} \geq (1 - \frac{1}{n} \sum_{k=1}^n z_k + \frac{1}{n} \sum_{k=1}^n z_k^2) - \frac{1}{2} (1 - \frac{1}{n} \sum_{k=1}^n z_k + \frac{1}{n} \sum_{k=1}^n z_k^2)^2 - \log(n)$$

因此, 在极限 $\sigma \rightarrow \infty$ 时, 界限变得更加紧密, I-Con 损失接近于凝聚方差损失 (cohesion variance loss)。□

Theorem 2. 主成分分析 (PCA) 是 I-Con 的一个渐近实例。

证明. 通过使用命题1。当 $p_{j|i} = \mathbf{1}[i = j]$ 时, 我们有下面的表达式 $\mathcal{L}$

$$\begin{aligned} \mathcal{L} &= \frac{1}{n} \sum_{ij} p_{j|i} \|f_\phi(x_i) - f_\phi(x_j)\|^2 - 2\text{Var}(X) \\ &= \frac{1}{n} \sum_i \|f_\phi(x_i) - f_\phi(x_i)\|^2 - 2\text{Var}(X) \\ &= -2\text{Var}(X) \end{aligned}$$

因此, 最小化 $\mathcal{L}$ 相当于最大化方差, 这相当于 PCA 的目标。直观地说, KL 散度要求 $-\|f_\phi(x_i) - f_\phi(x_i)\|^2 = 0$ 是与 $-\|f_\phi(x_i) - f_\phi(x_j)\|^2$ 相匹配的最大值, 这意味着 $-\|f_\phi(x_i) - f_\phi(x_j)\|^2$ 之和的最小化, 即方差最大化。如果我们将 f_ϕ 限制为一个线性投影映射, 那么最小化 $\mathcal{L}$ 将等价于 PCA。□

4 统一特征学习方法及其证明

我们现在将 I-Con 框架扩展到对比学习中常用的特征学习方法。设 $x_i \in \mathbb{R}^d$ 为输入数据点, $f_\phi(x_i) \in \mathbb{R}^m$ 为它们学习到的特征嵌入。在对比学习中, 目标是学习这些嵌入, 使得相似的数据点 (正对) 在嵌入空间中接近, 而不相似的点 (负对) 则远离。这种设置可以使用原始空间中的邻域分布来表达, 其中 “邻居” 并不是通过欧几里得空间中的接近性来定义的, 而是通过预定义的关系, 如数据增强或类别成员资格。学习到的嵌入 $f_\phi(x_i)$ 定义了一个新的邻居分布, 通常在学习到的特征空间中使用高斯核。我们展示了 InfoNCE 是 I-Con 框架的一个自然实例, 许多其他方法, 如 SupCon、CMC 和交叉熵, 也由此推导而来。

Theorem 3 (InfoNCE (Bachman et al., 2019)). InfoNCE 是 I-Con 框架的一个实例。

证明. InfoNCE 的目标是在学习的特征空间中最大化正对之间的相似性, 同时最小化负对之间的相似性。在 I-Con 框架中, 这可以解释为最小化两个分布之间的分歧: 原始空间中的邻域分布和嵌入空间中的学习分布。

邻域分布 $p_\theta(j|i)$ 在正对上均匀的, 定义为:

$$p_\theta(j|i) = \begin{cases} \frac{1}{k} & \text{if } x_j \text{ is among the } k \text{ positive views of } x_i, \\ 0 & \text{otherwise.} \end{cases}$$

其中 k 是 x_i 的正对个数。

方法	$p_\theta(j i)$ 的选取	$q_\phi(j i)$ 的选取
(B) 对比学习		
InfoNCE Loss (Bachman et al., 2019) Theorem 3	$\frac{1}{Z} \mathbb{1}[i \text{ and } j \text{ are a positive pair}]$	Gaussian on deep normalized features $\frac{\exp(f_\phi(x_i) \cdot f_\phi(x_j))}{\sum_{k \neq i} \exp(f_\phi(x_i) \cdot f_\phi(x_k))}$
Triplet Loss (Schroff et al., 2015) Theorem 5		Gaussian on deep features (1 neg. sample, $\sigma \rightarrow 0$) $\frac{\exp(-\ f_\phi(x_i) - f_\phi(x_j)\ ^2 / 2\sigma^2)}{\sum_{k \in \{i^+, i^-\}} \exp(-\ f_\phi(x_i) - f_\phi(x_k)\ ^2 / 2\sigma^2)}$
t-SimCLR, t-SimCNE (Hu et al., 2023; Böhm et al., 2023) Corollary 2		Student-T on deep features $\frac{(1 + \ \phi_i - \phi_j\ ^2 / \nu) - (\nu + 1) / 2}{\sum_{k \neq i} (1 + \ \phi_i - \phi_k\ ^2 / \nu) - (\nu + 1) / 2}$
VICReg* without covariance term (Bardes et al., 2021) Theorem 4		Wide Gaussian on learned features $\lim_{\sigma \rightarrow \infty} \frac{\exp(-\ f_\phi(x_i) - f_\phi(x_j)\ ^2 / 2\sigma^2)}{\sum_{k \neq i} \exp(-\ f_\phi(x_i) - f_\phi(x_k)\ ^2 / 2\sigma^2)}$
SupCon (Khosla et al., 2020) Theorem 6	$\frac{1}{Z} \mathbb{1}[i \text{ and } j \text{ have same class}]$	Gaussian on deep normalized features $\frac{\exp(f_\phi(x_i) \cdot f_\phi(x_j))}{\sum_{k \neq i} \exp(f_\phi(x_i) \cdot f_\phi(x_k))}$
X-Sample (Sobal et al., 2025) Theorem 7	Gaussian on corresponding embeddings $\frac{\exp(g_\theta(x_i) \cdot g_\theta(x_j))}{\sum_{k \neq i} \exp(g_\theta(x_i) \cdot g_\theta(x_k))}$	
LGSimCLR (El Banani et al., 2023)	$\frac{1}{Z} \mathbb{1}[x_i \text{ is among } x_j\text{'s } k \text{ nearest neighbors}]$	
CMC & CLIP (Tian et al., 2020) Theorem 8	$\frac{1}{Z} \mathbb{1}[i, j \text{ pos. pairs, } V_i \neq V_j]$	$\frac{\exp(f_\phi(x_i) \cdot f_\phi(x_j))}{\sum_{k \in V_j} \exp(f_\phi(x_i) \cdot f_\phi(x_k))}$

学习分布 $q_\phi(j|i)$ 基于嵌入 $f_\phi(x_i)$ 和 $f_\phi(x_j)$ 之间的相似性，约束于单位范数 ($\|f_\phi(x_i)\| = 1$)。使用温度缩放高斯核，该分布由下式给出：

$$q_\phi(j|i) = \frac{\exp(f_\phi(x_i) \cdot f_\phi(x_j) / \tau)}{\sum_{k \neq i} \exp(f_\phi(x_i) \cdot f_\phi(x_k) / \tau)},$$

其中 τ 为控制分布清晰度的温度参数。因为 $\|f_\phi(x_i)\| = 1$ ，所以 $f_\phi(x_i)$ 和 $f_\phi(x_j)$ 之间的欧氏距离是 $2 - 2(f_\phi(x_i) \cdot f_\phi(x_j))$ 。

InfoNCE的损失可以写成它的标准形式：

$$\mathcal{L}_{\text{InfoNCE}} = - \sum_i \log \frac{\exp(f_\phi(x_i) \cdot f_\phi(x_i^+) / \tau)}{\sum_k \exp(f_\phi(x_i) \cdot f_\phi(x_k) / \tau)},$$

其中 j^+ 是 i 的正对的索引。或者，从交叉熵的角度来看，损失变为：

$$\mathcal{L}_{\text{InfoNCE}} \propto \sum_i \sum_j p_\theta(j|i) \log q_\phi(j|i) = H(p_\theta, q_\phi),$$

其中 $H(p_\theta, q_\phi)$ 表示两个分布之间的交叉熵。因为 $p_\theta(j|i)$ 是固定的，所以最小化交叉熵 $H(p_\theta, q_\phi)$ 就等于最小化KL散度 $D_{\text{KL}}(p_\theta \| q_\phi)$ 。通过将学习分布 $q_\phi(j|i)$ 与目标分布 $p_\theta(j|i)$ 对齐，InfoNCE在I-Con框架内运行，将原始空间中的邻域结构保留在嵌入空间中。因此，InfoNCE是I-Con的直接实例，优化相同的基于散度的目标。□

Corollary 2. *t-SimCLR*和*t-SimCNE* (Hu et al., 2023; Böhm et al., 2023)是I-Con框架的实例。

鉴于定理 3 的证明，我们可以看到 t-SimCLR 是等价的，因为它具有相同的 p_θ ，但 q_ϕ 将从基于余弦相似度的高斯分布变为基于欧几里得距离的学生t分布。

$$q_\phi(j|i) = \frac{(\|f_\phi(x_i) - f_\phi(x_j)\|^2 / \tau)^{-1}}{\sum_{k \neq i} (\|f_\phi(x_i) - f_\phi(x_k)\|^2 / \tau)^{-1}},$$

Theorem 4. 没有协方差项的VICReg [Bardes et al. \(2021\)](#) 是 *I-Con* 框架的一个实例。

根据命题 1，我们知道任何在凝聚方差形式中的损失都是 *I-Con* (*I*-一致性) 的一个实例：

$$\mathcal{L} = \frac{1}{n} \sum_{ij} p_{j|i} \|f_\phi(x_i) - f_\phi(x_j)\|^2 - 2\text{Var}(X)$$

如果我们选择 $p_{j|i}$ 作为正对的指示符， i 和 i^+ ，我们得到

$$\mathcal{L} = \frac{1}{n} \sum_i \|f_\phi(x_i) - f_\phi(x_{i^+})\|^2 - 2\text{Var}(X)$$

这是没有协方差项的VICReg损失，不变方差项比为1:2。观察到VICReg没有负对，因为它对所有点施加了相同的排斥力。这相当于在嵌入的条件高斯分布中取 $\sigma \rightarrow \infty$ 。

Theorem 5 (Triplet Loss ([Schroff et al., 2015](#))). *Triplet Loss* 可以被视为具有以下分布的 *I-Con* 框架的一个实例 $p_\theta(j|i)$ 与 $q_\phi(j|i)$:

$$p_\theta(j|i) = \begin{cases} \frac{1}{k} & \text{if } x_j \text{ is among the } k \text{ positive views of } x_i, \\ 0 & \text{otherwise,} \end{cases}$$

$$q_\phi(j|i) = \frac{\exp\left(-\frac{\|f_\phi(x_i) - f_\phi(x_j)\|^2}{\sigma^2}\right)}{\sum_{k \neq i} \exp\left(-\frac{\|f_\phi(x_i) - f_\phi(x_k)\|^2}{\sigma^2}\right)},$$

特别是在只考虑两个邻居的特殊情况下一个正面视图和一个负面视图。

证明. 这个证明的想法最初是在([Khosla et al., 2020](#))上用泰勒近似提出的；然而，在这个证明中，我们为这个结果给出了一个更强的界。为简单起见，我们设置 $\sigma = 1$ （在证明的末尾提供了其他 σ 值的一般界限）。

$$\mathcal{L} = -\frac{1}{N} \sum_i \sum_j q_\phi(j|i) \log \frac{\exp(-\|f_\phi(x_i) - f_\phi(x_j)\|^2)}{\sum_{k \neq i} \exp(-\|f_\phi(x_i) - f_\phi(x_k)\|^2)}.$$

在每个锚 x_i 正好有一个正的 x_i^+ 和一个负的 x_i^- 的特殊情况下，分母化简为：

$$\sum_{k \neq i} \exp(-\|f_\phi(x_i) - f_\phi(x_k)\|^2) = \exp(-\|f_\phi(x_i) - f_\phi(x_i^+)\|^2) + \exp(-\|f_\phi(x_i) - f_\phi(x_i^-)\|^2).$$

让 $d_i^+ = \|f_\phi(x_i) - f_\phi(x_i^+)\|^2$ 和 $d_i^- = \|f_\phi(x_i) - f_\phi(x_i^-)\|^2$ 。将这些代入损失函数，得到：

$$\begin{aligned} \mathcal{L} &= -\frac{1}{N} \sum_i \log \frac{\exp(-d_i^+)}{\exp(-d_i^+) + \exp(-d_i^-)} \\ &= -\frac{1}{N} \sum_i \log \left(\frac{1}{1 + \exp(d_i^- - d_i^+)} \right) \\ &= \frac{1}{N} \sum_i \log(1 + \exp(d_i^+ - d_i^-)). \end{aligned}$$

认识到对数内部的表达式是软加函数，我们可以利用它的众所周知的界限：

$$\max(z, 0) \leq \log(1 + \exp(z)) \leq \max(z, 0) + \log(2).$$

让 $z = d_i^+ - d_i^-$ 代入边界，得到：

$$\frac{1}{N} \sum_i \max(d_i^+ - d_i^-, 0) \leq \mathcal{L} \leq \frac{1}{N} \sum_i \max(d_i^+ - d_i^-, 0) + \log(2),$$

左边是三重态损失 $\mathcal{L}_{\text{Triplet}} = \frac{1}{N} \sum_i \max(d_i^+ - d_i^-, 0)$ 。因此，我们得到以下界限：

$$\mathcal{L} - \log(2) \leq \mathcal{L}_{\text{Triplet}} \leq \mathcal{L}.$$

对于一般 σ ，不等式界如下：

$$\mathcal{L}_\sigma - \sigma^2 \log(2) \leq \mathcal{L}_{\text{Triplet}} \leq \mathcal{L}_\sigma,$$

其中

$$\mathcal{L}_\sigma = -\frac{\sigma^2}{N} \sum_i \sum_j q_\phi(j|i) \log \frac{\exp\left(-\frac{\|f_\phi(x_i) - f_\phi(x_j)\|^2}{\sigma^2}\right)}{\sum_{k \neq i} \exp\left(-\frac{\|f_\phi(x_i) - f_\phi(x_k)\|^2}{\sigma^2}\right)}.$$

当 σ 接近 0 时， $\mathcal{L}_{\text{Triplet}}$ 接近 $\mathcal{L}_\sigma$ 。 □

Theorem 6. 监督对比损失 (Khosla et al., 2020) 是 I-Con 框架的一个实例。

证明. 这直接从定理 3 推导出来。将监管和目标分布定义为：

$$q_\phi(j|i) = \frac{\exp(f_\phi(x_i) \cdot f_\phi(x_j)/\tau)}{\sum_{k \neq i} \exp(f_\phi(x_i) \cdot f_\phi(x_k)/\tau)},$$

$$p_\theta(j|i) = \frac{1}{K_i - 1} \mathbf{1}[i \text{ and } j \text{ share the same label}],$$

其中 f_ϕ 为到深度特征空间的映射， K_i 为 i 类中的样本个数。将这些定义替换到 I-Con 框架中可以恢复监督对比损失。 □

Theorem 7. x 样本对比学习损失 (Sobal et al., 2025) 是 I-Con 框架的一个实例。

证明. 考虑以下对应特征的 p 分布（例如图像的标题嵌入）：

$$\frac{\exp(g_\theta(x_i) \cdot g_\theta(x_j))}{\sum_{k \neq i} \exp(g_\theta(x_i) \cdot g_\theta(x_k))}$$

其中 g 可以是对应嵌入 $g_\theta(x_i)$ 的参数映射或非参数映射。另一方面，与大多数特征学习方法类似，学习到的分布在学习到的余弦距离的嵌入上是高斯分布

$$q_\phi(j|i) = \frac{\exp(f_\phi(x_i) \cdot f_\phi(x_j))}{\sum_{k \neq i} \exp(f_\phi(x_i) \cdot f_\phi(x_k))}$$

其中 f_ϕ 为到深度特征空间的映射。 □

Theorem 8. 对比多视图编码 (CMC) 和 CLIP 是 I-Con 框架的实例。

证明. 既然我们已经确定了 InfoNCE 是 I-Con 框架的一个实例，那么这个推论就自然而然地出现了。对比多视图编码 (CMC) 和 CLIP 的关键区别在于它们优化了跨不同模态的对齐。目标概率分布 $p_\theta(j|i)$ 可表示为：

$$p_\theta(j|i) = \frac{1}{Z} \mathbf{1}[i \text{ and } j \text{ are positive pairs and } V_i \neq V_j],$$

其中 V_i 和 V_j 分别表示 x_i 和 x_j 的模态集。在这里， $p_\theta(j|i)$ 为从不同模态绘制的正对分配统一的概率。

在这种情况下，学习分布 $q_\phi(j|i)$ 基于深度特征之间的高斯相似性，但条件是来自相反模态集的点。因此，将学习分布定义为：

$$q_\phi(j|i) = \frac{\exp(-\|f_\phi(x_i) - f_\phi(x_j)\|^2)}{\sum_{k \in V_j} \exp(-\|f_\phi(x_i) - f_\phi(x_k)\|^2)}.$$

这个公式表明，CMC和CLIP遵循与InfoNCE相同的原则，但在多视图设置中应用它们，通过最小化不同模式下目标分布和学习分布之间的差异，无缝地适应I-Con框架。 □

下面是监督学习方法的证明。

方法	$p_\theta(j i)$ 的选取	$q_\phi(j i)$ 的选取
(C) 监督学习		
Supervised Cross Entropy (Good, 1963) Theorem 9	Indicator over classes $\mathbb{1}[i \text{ belongs to class } j]$	$\frac{\exp(f_\phi(x_i) \cdot \phi_j)}{\sum_{k \in C} \exp(f_\phi(x_i) \cdot \phi_k)}$
Harmonic Loss (Baek et al., 2025) Theorem 10		$\lim_{\sigma \rightarrow 0} \frac{(\sigma^2 + \ f_\phi(x_i) - \phi_j\ ^2)^{-n}}{\sum_{k \in C} (\sigma^2 + \ f_\phi(x_i) - \phi_k\ ^2)^{-n}}$
Masked Lang. Modeling (Devlin et al., 2019) Theorem 11	$\frac{1}{Z} \# [\text{Context } i \text{ precedes token } j]$	$\frac{\exp(f_\phi(x_i) \cdot \phi_j)}{\sum_{k \in C} \exp(f_\phi(x_i) \cdot \phi_k)}$

Theorem 9. 交叉熵分类是I-Con框架的一个实例。

证明. 交叉熵可以看作是CMC损失的一种特殊情况，其中一个“视图”对应于数据点特征，另一个对应于类逻辑。数据点与类之间的关联取决于该点是否属于该类。这种解释已经在先前的工作中进行了探讨，其中交叉熵被证明与CLIP损失有关(Yang et al., 2022)。 □

Theorem 10. 谐波损耗分类是I-Con框架的一个实例。

证明. 这相当于从交叉熵 $q(j|i)$ 的高斯分布移动到Student-T分布，类似于从SNE移动到t-SNE。更具体地说，设 V 为数据点的集合， C 为类原型的集合， ϕ_i 为类 i 学习到的类原型， n 为调和损失度。

考虑下面的 p ，它是一个数据标签指示符

$$p(j|i) = \mathbb{1}[i \text{ belongs to class } j]$$

下面是 q ，这是一个自由度为 $2n-1$ 的Student-T分布。

$$\lim_{\sigma \rightarrow 0} \frac{(1 + \|f_\phi(x_i) - \phi_j\|^2 / ((2n-1)\sigma^2))^{-n}}{\sum_{k \in C} (1 + \|f_\phi(x_i) - \phi_k\|^2 / ((2n-1)\sigma^2))^{-n}}$$

它可以重写为：

$$\lim_{\sigma \rightarrow 0} \frac{(((2n-1)\sigma^2) + \|f_\phi(x_i) - \phi_j\|^2)^{-n}}{\sum_{k \in C} (((2n-1)\sigma^2) + \|f_\phi(x_i) - \phi_k\|^2)^{-n}}$$

由于 $\sigma \rightarrow \infty$ ，该损失函数近似为

$$\mathcal{L} = \sum_{i \in C} \frac{(\|f_\phi(x_i) - \phi_j\|^2)^{-n}}{\sum_{k \in C} (\|f_\phi(x_i) - \phi_k\|^2)^{-n}}$$

这就是所介绍的谐波损耗分类，即定理10 □

Theorem 11. 掩码语言建模 (MLM) 损失 (Devlin et al., 2019) 是I-Con框架的一个实例。

证明. 在掩码语言建模中，目标是预测一个掩码令牌 j 给定其周围的上下文 x_i 。通过定义适当的目标和学习分布，这种设置自然适合I-Con框架。

目标分布 $p_\theta(j|i)$ 是上下文 i 和token j 上的经验分布，定义为：

$$p_\theta(j|i) = \frac{1}{Z} \# [\text{Context } i \text{ precedes token } j],$$

其中 $\# [\text{Context } i \text{ precedes token } j]$ 计算令牌 j 在训练语料库中跟随上下文 x_i 的次数， Z 是一个规范化常数，确保 $\sum_j p_\theta(j|i) = 1$ 。

学习到的分布 $q_\phi(j|i)$ 使用神经网络的输出logits进行令牌预测。它被定义为上下文嵌入 $f_\phi(x_i)$ 和令牌嵌入 ϕ_j 之间的点积的softmax：

$$q_\phi(j|i) = \frac{\exp(f_\phi(x_i) \cdot \phi_j)}{\sum_{k \in \mathcal{V}} \exp(f_\phi(x_i) \cdot \phi_k)},$$

其中 $f_\phi(x_i)$ 是模型生成的上下文 x_i 的嵌入， ϕ_j 是令牌 j 的嵌入， $\mathcal{V}$ 是包含所有可能令牌的词汇表。

MLM损失的目的是最小化目标分布 $p_\theta(j|i)$ 与学习分布 $q_\phi(j|i)$ 之间的交叉熵：

$$\mathcal{L}_{\text{MLM}} = - \sum_i \sum_j p_\theta(j|i) \log q_\phi(j|i) = H(p_\theta, q_\phi).$$

由于在实践中，对于每个上下文 x_i ，只考虑真正的掩码令牌 j_i^* ，目标分布简化为：

$$p_\theta(j|i) = \delta_{j, j_i^*},$$

其中 δ_{j, j_i^*} 是Kronecker delta函数，如果 $j = j_i^*$ 等于1，否则等于0。

将其代入损失函数，则MLM损失为：

$$\mathcal{L}_{\text{MLM}} = - \sum_i \log q_\phi(j_i^* | x_i).$$

□

5 统一聚类方法及其证明

聚类与I-Con框架之间的联系比之前讨论的降维方法更为复杂。为了建立这些联系，我们首先引入K-means的概率性表述，并证明其与经典K-means算法的等价性，表明它是一种零间隙松弛。在此基础上，我们揭示了概率性K-means如何被视为I-Con的一个实例，从而导致一种新颖的聚类核。最后，我们展示了几种聚类方法如何隐式地近似并优化这个核。

方法	$p_\theta(j i)$ 的选取	$q_\phi(j i)$ 的选取
(D) 聚类		
Probabilistic k-Means (MacQueen, 1967) Theorem 13	Intra-cluster uniform probability	Gaussians on datapoints $\frac{\exp(-\ x_i - x_j\ ^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\ x_i - x_k\ ^2 / 2\sigma_i^2)}$
Spectral Clustering (Ng et al., 2001) Corollary 4	$\sum_{c=1}^m \frac{p(f_\theta(x_i) \text{ and } f_\theta(x_j) \text{ in } c)}{\mathbb{E}[\text{size of cluster } c]}$	Gaussians on spectral embeddings $\frac{\exp(-\ x_i - x_j\ ^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\ x_i - x_k\ ^2 / 2\sigma_i^2)}$
Normalized Cuts (Shi & Malik, 2000) Theorem 14	Intra-cluster uniform probability weighted by degree $\sum_{c=1}^m \frac{p(f_\theta(x_i) \text{ and } f_\theta(x_j) \text{ in } c) \cdot d_j}{\mathbb{E}[\text{degree of cluster } c]}$	Gaussians on graph weights $\frac{\exp(w_{ij} / d_j)}{\sum_k \exp(w_{ik} / d_k)}$
PMI Clustering (Adaloglou et al., 2023) Theorem 15	$\frac{1}{k} \mathbb{1}[j \text{ is } k\text{-NN of } i]$	Intra-Cluster Uniform Probability $\sum_{c=1}^m \frac{p(f_\theta(x_i) \text{ and } f_\theta(x_j) \text{ in } c)}{\mathbb{E}[\text{size of cluster } c]}$
Debiased InfoNCE Clustering (ours)	均匀分布与邻居传播的去偏图	$\sum_{c=1}^m \frac{(1 - \alpha)p(f_\theta(x_i) \text{ and } f_\theta(x_j) \text{ in } c)}{\mathbb{E}[\text{size of cluster } c]} + \frac{\alpha}{N}$

Definition 1 (经典 K-means). 设 $x_1, x_2, \dots, x_N \in \mathbb{R}^n$ 表示数据点, $\mu_1, \mu_2, \dots, \mu_m \in \mathbb{R}^n$ 为簇 (cluster) 中心。

经典 *K-means* 的目标是最小化以下损失函数:

$$\mathcal{L}_{k\text{-Means}} = \sum_{i=1}^N \sum_{c=1}^m \mathbb{1}(c^{(i)} = c) \|x_i - \mu_c\|^2,$$

其中 $c^{(i)}$ 表示数据点 x_i 的簇 (cluster) 分配, 定义为:

$$c^{(i)} = \arg \min_c \|x_i - \mu_c\|^2.$$

概率性 K-MEANS 放松 (PROBABILISTIC K-MEANS RELAXATION)

在概率K均值中, 簇分配通过假设每个数据点 x_i 以概率 ϕ_{ic} 属于一个簇 c 来放宽。换句话说, ϕ_i 表示 x_i 的簇分配向量。

Proposition 2. 概率 k 均值的松弛损失函数由下式给出:

$$\mathcal{L}_{\text{Prob-k-Means}} = \sum_{i=1}^N \sum_{c=1}^m \phi_{ic} \|x_i - \mu_c\|^2,$$

等于原来的 k 均值目标 $\mathcal{L}_{k\text{-Means}}$ 。最优分配概率 ϕ_{ic} 是确定的, 将概率1分配给最近的集群, 将概率0分配给其他集群。

证明. 对于每个数据点 x_i , 术语 $\sum_{c=1}^m \phi_{ic} \|x_i - \mu_c\|^2$ 是最小的, 当分配概率 ϕ_{ic} 是确定性的, 即,

$$\phi_{ic} = \begin{cases} 1 & \text{if } c = \arg \min_j \|x_i - \mu_j\|^2, \\ 0 & \text{otherwise.} \end{cases}$$

有了这些确定性概率, $\mathcal{L}_{\text{Prob-k-Means}}$ 简化为经典的K-means目标, 确认松弛不引入间隙。 $\square$

概率K均值的对比公式

Definition 2. 让 $\{x_i\}_{i=1}^N$ 是一组数据点。将条件概率 $q_\phi(j|i)$ 定义为:

$$q_\phi(j|i) = \frac{\sum_{c=1}^m \phi_{ic} \phi_{jc}}{\sum_{k=1}^m \phi_{kc}},$$

其中 ϕ_i 是 x_i 的软簇分配。

给定 $q_\phi(j|i)$, 我们可以将概率 K-means 重新表述为对比损失:

Theorem 12. 设 $\{x_i\}_{i=1}^N \in \mathbb{R}^n$ 和 $\{\phi_{ic}\}_{i=1}^N$ 为对应的分配概率。将目标函数 $\mathcal{L}$ 定义为:

$$\mathcal{L} = - \sum_{i,j} (x_i \cdot x_j) q_\phi(j|i).$$

最小化 $\mathcal{L}$ 相对于分配概率 $\{\phi_{ic}\}$ 产生最优的集群分配相当于那些通过 *K-means* 获得。

证明. 松弛的概率k-均值目标 $\mathcal{L}_{\text{Prob-k-Means}}$ 为:

$$\mathcal{L}_{\text{Prob-k-Means}} = \sum_{i=1}^N \sum_{c=1}^m \phi_{ic} \|x_i - \mu_c\|^2.$$

展开，我们得到：

$$\mathcal{L}_{\text{Prob-k-Means}} = \sum_{c=1}^m \left(\sum_{i=1}^N \phi_{ic} \right) \|\mu_c\|^2 - 2 \sum_{c=1}^m \left(\sum_{i=1}^N \phi_{ic} x_i \right) \cdot \mu_c + \sum_{i=1}^N \|x_i\|^2.$$

使这种损失最小化的群集中心 μ_c 如下所示：

$$\mu_c = \frac{\sum_{i=1}^N \phi_{ic} x_i}{\sum_{i=1}^N \phi_{ic}}.$$

将 μ_c 代回损失函数，得到：

$$\mathcal{L} = - \sum_{i,j} (x_i \cdot x_j) q_\phi(j|i),$$

这证明最小化这种对比公式会导致与经典K-means相同的聚类分配。 $\square$

Corollary 3. 备选损失函数：

$$\mathcal{L} = - \sum_{i,j} \|x_i - x_j\|^2 q_\phi(j|i),$$

当相对于 $\{\phi_{ic}\}$ 最小化时，产生相同的最优聚类分配。

证明. 展开损失函数的平方范数得到：

$$\mathcal{L} = - \sum_{i,j} (\|x_i\|^2 - 2x_i \cdot x_j + \|x_j\|^2) q_\phi(j|i).$$

涉及 $\|x_i\|^2$ 和 $\|x_j\|^2$ 的条款自 $\sum_j q_\phi(j|i) = 1$ 简化后，损失减少为：

$$\mathcal{L} = 2 \left(- \sum_{i,j} x_i \cdot x_j q_\phi(j|i) \right),$$

它等价于前面定理中的目标。 $\square$

作为 I-CON 方法的概率 K-MEANS

在 I-Con 框架中，目标分布和学习分布表示基于特定度量的数据点之间的亲和性。例如，在 SNE 中，这些度量是在高维和低维空间中的欧几里得距离，而在 SupCon 中，距离反映了数据点是否属于同一类别。同样，我们可以在聚类的背景下定义邻域概率的度量，其中两个点被视为邻居，如果它们属于同一簇。选择 x_j 作为 x_i 的邻居的概率是从 x_i 的簇中均匀随机选择的点是 x_j 的概率。更明确地说，令 $q_\phi(j|i)$ 表示从 x_i 的簇中均匀随机选择 x_j 的概率：

$$q_\phi(j|i) = \sum_{c=1}^m \frac{\phi_{ic} \phi_{jc}}{\sum_{k=1}^N \phi_{kc}}.$$

Theorem 13 (K-means作为I-Con的一个实例). 给定数据点 $\{x_i\}_{i=1}^N$ ，定义邻域概率 $p_\theta(j|i)$ 和 $q_\phi(j|i)$ 为：

$$p_\theta(j|i) = \frac{\exp(-\|x_i - x_j\|^2/2\sigma^2)}{\sum_k \exp(-\|x_i - x_k\|^2/2\sigma^2)}, \quad q_\phi(j|i) = \sum_{c=1}^m \frac{\phi_{ic} \phi_{jc}}{\sum_{k=1}^N \phi_{kc}}.$$

令损失函数 $\mathcal{L}_{c-SNE}$ 为分布 $q_\phi(j|i)$ 与 $p_\theta(j|i)$ 之间的KL散度之和：

$$\mathcal{L}_{c-SNE} = \sum_i D_{KL}(q_\phi(\cdot|i) \| p_\theta(\cdot|i)).$$

然后，

$$\mathcal{L}_{c-SNE} = \frac{1}{2\sigma^2} \mathcal{L}_{\text{Prob-k-Means}} - \sum_i H(q_\phi(\cdot|i)),$$

其中 $H(q_\phi(\cdot|i))$ 是 $q_\phi(\cdot|i)$ 的熵。

证明. 为简单起见, 假设 $2\sigma^2 = 1$. 用 Z_i 表示 $\sum_k \exp(-\|x_i - x_k\|^2)$. 然后我们有:

$$\log p_\theta(j|i) = -\|x_i - x_j\|^2 - \log Z_i.$$

将 $\mathcal{L}_i$ 定义为 $-\sum_j \|x_i - x_j\|^2 q_\phi(j|i)$. 利用上式, $\mathcal{L}_i$ 可以改写为:

$$\begin{aligned} \mathcal{L}_i &= -\sum_j \|x_i - x_j\|^2 q_\phi(j|i) \\ &= \sum_j (\log(p_\theta(j|i)) + \log(Z_i)) q_\phi(j|i) \\ &= \sum_j q_\phi(j|i) \log(p_\theta(j|i)) + \sum_j q_\phi(j|i) \log(Z_i) \\ &= \sum_j q_\phi(j|i) \log(p_\theta(j|i)) + \log(Z_i) \\ &= H(q_\phi(\cdot|i), p_\theta(\cdot|i)) + \log(Z_i) \\ &= D_{\text{KL}}(q_\phi(\cdot|i) \| p_\theta(\cdot|i)) + H(q_\phi(\cdot|i)) + \log(Z_i). \end{aligned}$$

因此, 在推论3中定义的 $\mathcal{L}_{\text{Prob-KMeans}}$ 可以重写为:

$$\begin{aligned} \mathcal{L}_{\text{Prob-KMeans}} &= -\sum_i \sum_j \|x_i - x_j\|^2 q_\phi(j|i) = \sum_i \mathcal{L}_i \\ &= \sum_i D_{\text{KL}}(q_\phi(\cdot|i) \| p_\theta(\cdot|i)) + H(q_\phi(\cdot|i)) + \log(Z_i) \\ &= \mathcal{L}_{\text{c-SNE}} + \sum_i H(q_\phi(\cdot|i)) + \text{constant}. \end{aligned}$$

因此,

$$\mathcal{L}_{\text{c-SNE}} = \mathcal{L}_{\text{Prob-KMeans}} - \sum_i H(q_\phi(\cdot|i)).$$

如果我们允许 σ 取任意值, 则熵罚将相应地加权:

$$\mathcal{L}_{\text{c-SNE}} = \frac{1}{2\sigma^2} \mathcal{L}_{\text{Prob-KMeans}} - \sum_i H(q_\phi(\cdot|i)).$$

注意, 上面的关系是一个附加常数。这意味着通过熵正则化最小化对比概率 **K-means** 损失可以最小化 $q_\phi(\cdot|i)$ 和 $p_\theta(\cdot|i)$ 之间的 **KL** 散度之和。 $\square$

上述完成了 **K-Means** 聚类的证明。

Corollary 4. 谱聚类是 *I-Con* 框架的一个实例。

证明. 从13定理, 我们知道 **K-Means** 聚类可以被表述为 **I-Con** 框架的一个实例, 其中聚类分配依赖于数据点的内积。

谱聚类扩展了这一思想, 首先使用从亲和矩阵 A 导出的归一化拉普拉斯函数的顶部 k 特征向量将数据嵌入到较低维空间中。亲和矩阵 A 使用相似性度量 (例如, **RBF** 内核) 构建, 并编码数据点之间分配的概率。鉴于这种转换, 谱聚类是对投影嵌入的 **I-Con** 的一个实例。 $\square$

Theorem 14. 归一化切割 (*Normalized Cuts*) ([Shi & Malik, 2000](#)) 是 *I-Con* 的一个实例。

证明. 从 k 均值分析中可以很自然地得到证明。归一化切割的损失函数定义为:

$$\mathcal{L}_{\text{NormCuts}} = \sum_{c=1}^m \frac{\text{cut}(A_c, \bar{A}_c)}{\text{vol}(A_c)},$$

方法	$p_\theta(j i)$ 的选取	$q_\phi(j i)$ 的选取
(D) 聚类		
Probabilistic k-Means (Macqueen, 1967) Theorem 13	Intra-cluster uniform probability $\sum_{c=1}^m \frac{p(f_\theta(x_i) \text{ and } f_\theta(x_j) \text{ in } c)}{\mathbb{E}[\text{size of cluster } c]}$	Gaussians on datapoints $\frac{\exp(-\ x_i - x_j\ ^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\ x_i - x_k\ ^2 / 2\sigma_i^2)}$
Spectral Clustering (Ng et al., 2001) Corollary 4		Gaussians on spectral embeddings $\frac{\exp(-\ x_i - x_j\ ^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\ x_i - x_k\ ^2 / 2\sigma_i^2)}$
Normalized Cuts (Shi & Malik, 2000) Theorem 14	Intra-cluster uniform probability weighted by degree $\sum_{c=1}^m \frac{p(f_\theta(x_i) \text{ and } f_\theta(x_j) \text{ in } c) \cdot d_j}{\mathbb{E}[\text{degree of cluster } c]}$	Gaussians on graph weights $\frac{\exp(w_{ij}/d_j)}{\sum_k \exp(w_{ik}/d_k)}$
PMI Clustering (Adaloglou et al., 2023) Theorem 15	$\frac{1}{k} \mathbb{1}[j \text{ is } k\text{-NN of } i]$	Intra-Cluster Uniform Probability $\sum_{c=1}^m \frac{p(f_\theta(x_i) \text{ and } f_\theta(x_j) \text{ in } c)}{\mathbb{E}[\text{size of cluster } c]}$
Debiased InfoNCE Clustering (ours)	均匀分布与邻居传播的去偏图	$\sum_{c=1}^m \frac{(1 - \alpha)p(f_\theta(x_i) \text{ and } f_\theta(x_j) \text{ in } c)}{\mathbb{E}[\text{size of cluster } c]} + \frac{\alpha}{N}$

其中 A_c 是 c 集群对应数据的一个子集， $\bar{A}_c$ 是它的补集， $\text{cut}(A_c, \bar{A}_c)$ 表示 A_c 和 $\bar{A}_c$ 之间的边权之和， $\text{vol}(A_c)$ 是 A_c 集群的总体积，即 A_c 内部的边权之和。

与K-Means类似，通过与软分配的对比方式重新表述，学习分布可以使用概率聚类分配 $\phi_{ic} = p(c|x_i)$ 表示为：

$$q_\phi(j|i) = \sum_{c=1}^m \frac{\phi_{ic}\phi_{jc}d_j}{\sum_{k=1}^N \phi_{kc}d_k},$$

其中 d_j 是节点 x_j 的程度，而volume和cut terms可以被看作是数据点对集群的软分配的加权和。

这种重新表述表明，规范化切割可以以与I-Con框架一致的方式编写，其中目标分布 $p_\theta(j|i)$ 和学习分布 $q_\phi(j|i)$ 表示基于图结构和聚类分配的亲和关系。

因此，标准化切割是I-Con的一个实例，其中损失函数以类似于K-Means及其概率松弛的方式基于簇的切割和体积来优化邻域结构。□

Theorem 15. 互信息聚类是I-Con的一个实例。

证明. 考虑到SimCLR、K-Means和I-Con框架之间建立的联系，这个结果自然会出现。具体来说，目标分布 $p_\theta(j|i)$ （监督部分）是观测到的正对上的均匀分布：

$$p_\theta(j|i) = \begin{cases} \frac{1}{k} & \text{if } x_j \text{ is among the } k \text{ positive views of } x_i, \\ 0 & \text{otherwise.} \end{cases}$$

另一方面，学习到的嵌入 ϕ_i 表示 x_i 到聚类的概率分配。因此，与K-Means连接的分析类似，将学习到的分布建模为：

$$q_\phi(j|i) = \sum_{c=1}^m \frac{\phi_{ic}\phi_{jc}}{\sum_{k=1}^N \phi_{kc}}.$$

这表明互信息聚类可以看作是I-Con框架中的一种方法，其中学习到的分布 $q_\phi(j|i)$ 与目标分布 $p_\theta(j|i)$ 一致，完成了证明。□

BIBLIOGRAPHY

- Nikolas Adaloglou, Felix Michels, Hamza Kalisch, and Markus Kollmann. Exploring the limits of deep image clustering using pretrained models. *arXiv preprint arXiv:2303.17896*, 2023.
- Philip Bachman, R Devon Hjelm, and William Buchwalter. Learning representations by maximizing mutual information across views. *Advances in neural information processing systems*, 32, 2019.
- David D Baek, Ziming Liu, Riya Tyagi, and Max Tegmark. Harmonic loss trains interpretable ai models. *arXiv preprint arXiv:2502.01628*, 2025.
- Adrien Bardes, Jean Ponce, and Yann LeCun. Vicreg: Variance-invariance-covariance regularization for self-supervised learning. *arXiv preprint arXiv:2105.04906*, 2021.
- Jan Niklas Böhm, Philipp Berens, and Dmitry Kobak. Unsupervised visualization of image datasets using contrastive learning. *International Conference on Learning Representations*, 2023.
- Ching-Yao Chuang, Joshua Robinson, Lin Yen-Chen, Antonio Torralba, and Stefanie Jegelka. De-biased contrastive learning, 2020. URL <https://arxiv.org/abs/2007.00224>.
- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding, 2019. URL <https://arxiv.org/abs/1810.04805>.
- Mohamed El Banani, Karan Desai, and Justin Johnson. Learning visual representations via language-guided sampling. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 19208–19220, 2023.
- Irving J Good. Maximum entropy for hypothesis formulation, especially for multidimensional contingency tables. *The Annals of Mathematical Statistics*, pp. 911–934, 1963.
- Geoffrey E Hinton and Sam Roweis. Stochastic neighbor embedding. *Advances in neural information processing systems*, 15, 2002.
- Tianyang Hu, Zhili Liu, Fengwei Zhou, Wenjia Wang, and Weiran Huang. Your contrastive learning is secretly doing stochastic neighbor embedding. In *International Conference on Learning Representations*, 2023.
- Prannay Khosla, Piotr Teterwak, Chen Wang, Aaron Sarna, Yonglong Tian, Phillip Isola, Aaron Maschinot, Ce Liu, and Dilip Krishnan. Supervised contrastive learning. *Advances in neural information processing systems*, 33:18661–18673, 2020.
- Johannes F Kruiger, Paulo E Rauber, Rafael Messias Martins, Andreas Kerren, Stephen Kobourov, and Alexandru C Telea. Graph layouts by t-sne. In *Computer graphics forum*, volume 36, pp. 283–294. Wiley Online Library, 2017.
- Wenting Li, Jiahong Xue, Xi Zhang, Huacan Chen, Zeyu Chen, Feijuan Huang, and Yuanzhe Cai. Word-graph2vec: An efficient word embedding approach on word co-occurrence graph using random walk technique, 2023. URL <https://arxiv.org/abs/2301.04312>.
- J Macqueen. Some methods for classification and analysis of multivariate observations. In *Proceedings of 5-th Berkeley Symposium on Mathematical Statistics and Probability/University of California Press*, 1967.

- Andrew Ng, Michael Jordan, and Yair Weiss. On spectral clustering: Analysis and an algorithm. *Advances in neural information processing systems*, 14, 2001.
- Karl Pearson. Liii. on lines and planes of closest fit to systems of points in space. *The London, Edinburgh, and Dublin philosophical magazine and journal of science*, 2(11):559–572, 1901.
- Florian Schroff, Dmitry Kalenichenko, and James Philbin. Facenet: A unified embedding for face recognition and clustering. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 815–823, 2015.
- Jianbo Shi and Jitendra Malik. Normalized cuts and image segmentation. *IEEE Transactions on pattern analysis and machine intelligence*, 22(8):888–905, 2000.
- Vlad Sobal, Mark Ibrahim, Randall Balestriero, Vivien Cabannes, Diane Bouchacourt, Pietro Astolfi, Kyunghyun Cho, and Yann LeCun. X-sample contrastive loss: Improving contrastive learning with sample similarity graphs. *International Conference on Learning Representations*, 2025.
- Christian Szegedy, Vincent Vanhoucke, Sergey Ioffe, Jon Shlens, and Zbigniew Wojna. Rethinking the inception architecture for computer vision. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 2818–2826, 2016.
- Yonglong Tian, Dilip Krishnan, and Phillip Isola. Contrastive multiview coding. In *Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XI 16*, pp. 776–794. Springer, 2020.
- Laurens Van der Maaten and Geoffrey Hinton. Visualizing data using t-sne. *Journal of machine learning research*, 9(11), 2008.
- Jianwei Yang, Chunyuan Li, Pengchuan Zhang, Bin Xiao, Ce Liu, Lu Yuan, and Jianfeng Gao. Unified contrastive learning in image-text-label space. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 19163–19173, 2022.