

RL—METRA: Scalable Unsupervised RL with Metric-Aware Abstraction

作者：凯鲁嘎吉 - 博客园 <http://www.cnblogs.com/kailugaji/>

近期，阅读了一篇发表在ICLR2024上的文章《[METRA: Scalable Unsupervised RL with Metric-Aware Abstraction](#)》，本博文从生成对抗网络的变种Wasserstein GAN的角度出发，来理解METRA的提出动机。首先介绍一些基础知识，包括：KL散度、JS散度、Wasserstein距离、Lipschitz条件、信息熵、联合熵、条件熵、前向与反向互信息、相对熵、Jensen不等式。然后通过Wasserstein GAN与METRA左右对比来理解METRA的由来。进一步，详细解读了METRA方法的公式推导过程、算法流程、直观理解以及和DIAYN、DADS和CIC方法之间的联系。



METRA: Metric-Aware Abstraction

凯鲁嘎吉

➤ 基础知识

- KL散度/相对熵 (Kullback–Leibler Divergence)[非对称]

$$D_{KL}(p, q) = \sum_{i=1}^N p(x_i) \log \frac{p(x_i)}{q(x_i)}$$

- JS散度 (Jensen–Shannon Divergence)[对称]

$$D_{JS}(p, q) = \frac{1}{2} KL\left(p, \frac{p+q}{2}\right) + \frac{1}{2} KL\left(q, \frac{p+q}{2}\right)$$

- 推土机距离 (Wasserstein Distance, or Earth-Mover's Distance)[对称]

$$\text{Wasserstein-}\ell: W_\ell[p, q] = \left(\inf_{\gamma \in \Pi(p, q)} \mathbb{E}_{(x, y) \sim \gamma(x, y)} [d(x, y)^\ell] \right)^{\frac{1}{\ell}}$$

其中 $\Pi(p, q)$ 是边际分布为 p 和 q 的所有可能的联合分布集合， $d(x, y)$ 为 x 和 y 的距离，比如 ℓ_2 距离等。

- Lipschitz连续函数

在数学中，对于一个实数函数 $f: \mathbb{R} \rightarrow \mathbb{R}$ ，如果满足函数曲线上任意两点连线的斜率一致有界，即任意两点的斜率都小于常数 $K > 0$,

$$|f(x_1) - f(x_2)| \leq K |x_1 - x_2|$$

则函数 f 就称为 K -Lipschitz连续函数， K 称为Lipschitz常数。

Lipschitz 连续要求函数在无限的区间上不能有超过线性的增长。如果一个函数可导，并满足Lipschitz连续，那么导数有界。如果一个函数可导，并且导数有界，那么函数为Lipschitz连续。

1



METRA: Metric-Aware Abstraction

凯鲁嘎吉

➤ 基础知识

- 信息熵(Information Entropy, or Shannon Entropy)

$$H(X) = -\mathbb{E}_{p_X(x)} [\log p_X(x)] = -\sum_x p_X(x) \log p_X(x)$$

- 联合熵(Joint Entropy)[对称]

$$H(X, Y) = -\mathbb{E}_{p(x, y)} [\log p(x, y)] = -\sum_x \sum_y p(x, y) \log p(x, y)$$

- 条件熵(Conditional Entropy)[非对称]

$$\begin{aligned} H(Y | X) &= \mathbb{E}_{p(x)} [H(Y | X = x)] = \sum_x p(x) H(Y | X = x) = -\mathbb{E}_{p(x)} \mathbb{E}_{p(y|x)} [\log p(Y | X)] \\ &= -\mathbb{E}_{p(x, y)} [\log p(Y | X)] = -\sum_x \sum_y p(x, y) [\log p(y | x)] \end{aligned}$$

- 链式法则

$$\begin{aligned} H(X, Y) &= H(X) + H(Y | X) \\ H(X, Y | Z) &= H(X | Z) + H(Y | X, Z) \end{aligned}$$

- 互信息(Mutual Information)[对称]

$$I(X; Y) = H(X) - H(X | Y) = \mathbb{E}_{p(x, y)} \left[\log \frac{p(x, y)}{p(x)p(y)} \right] = \sum_x \sum_y p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$$

- 相对熵(Relative Entropy, or KL Divergence)[非对称]

$$D_{KL}(p, q) = \mathbb{E}_p \left[\log \frac{p(x)}{q(x)} \right] = \sum_x p(x) \log \frac{p(x)}{q(x)} \quad \text{规定 } 0 \log \frac{0}{0} = 0, 0 \log \frac{0}{q} = p \log \frac{p}{0} = \infty$$

2


$$\begin{aligned} I(S; Z) &= H(S) - H(S | Z) (\text{前向互信息}) \\ &= H(Z) - H(Z | S) (\text{反向互信息}) \\ &= H(S) + H(Z) - H(S, Z) \end{aligned}$$

基础知识

- 互信息与相对熵的关系

$$I(X;Y) = D_{KL}(p(x,y), p(x)p(y))$$

- 信息熵, 联合熵, 条件熵与互信息的关系




- Jensen不等式

若 $f(x)$ 在 $[a,b]$ 上为凸函数, 对 $\forall x_i \in [a,b], \lambda_i > 0 (i=1, \dots, N), \sum_{i=1}^N \lambda_i = 1$

$$\text{则 } f\left(\sum_{i=1}^N \lambda_i x_i\right) \leq \sum_{i=1}^N \lambda_i f(x_i), \text{ 即 } f(\mathbb{E}[x]) \leq \mathbb{E}[f(x)].$$

若 $f(x)$ 为凹函数, 则相反, 例如 $f(x)$ 为对数函数, 则 $f(\mathbb{E}[x]) \geq \mathbb{E}[f(x)]$.



3

W-GAN

- 传统对抗生成网络GAN用JS散度存在的问题: 训练不稳定, 难以收敛; 判别器饱和问题; 评估指标不反映生成质量

- 因此, 用Wasserstein距离替代JS散度, 目标函数:

$$\mathcal{W}_1[p_r, p_\theta] = \inf_{\gamma \in \Pi(p_r, p_\theta)} \mathbb{E}_{(x,y) \sim \gamma} [\|x - y\|]$$

其中, p_r 为真实分布与, p_θ 为生成分布。

- Wasserstein距离通常难以直接计算, 但有个对偶形式 (利用Kantorovich-Rubinstein 对偶定理):

$$\mathcal{W}_1[p_r, p_\theta] = \sup_{\|f\|_L \leq 1} (\mathbb{E}_{x \sim p_r} [f(x)] - \mathbb{E}_{x \sim p_\theta} [f(x)])$$

其中 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 为1-Lipschitz函数, 满足

$$\|f\|_L \triangleq \sup_{x \neq y} \frac{|f(x) - f(y)|}{\|x - y\|} \leq 1$$

- 这里分母是绝对值

- 令 $f(x; \phi)$ 为一神经网络, 假设存在参数集合 Φ , 对于 $\forall \phi \in \Phi$, $f(x; \phi)$ 为K-Lipschitz连续, 从而得到:

$$\max_{\phi \in \Phi} (\mathbb{E}_{x \sim p_r} [f(x; \phi)] - \mathbb{E}_{z \sim p(z)} [f(g(z; \theta); \phi)])$$

METRA

- 传统基于互信息无监督技能发现用KL散度存在的问题: 与度量无关, 在缩放变换下保持不变; 只关心“是否不同”, 不关心“有多大不同”; 状态覆盖范围受限

- 因此, 用Wasserstein距离替代KL散度, WDM目标:

$$I_{\mathcal{W}}(S; Z) = \mathcal{W}(p(s, z), p(s)p(z))$$

其中, S 为状态空间, Z 为隐空间。

- Wasserstein距离通常难以直接计算, 但有个对偶形式 (利用Kantorovich-Rubinstein 对偶定理):

$$I_{\mathcal{W}}(S; Z) = \sup_{\|f\|_L \leq 1} (\mathbb{E}_{p(s,z)} [f(s, z)] - \mathbb{E}_{p(s)p(z)} [f(s, z)])$$

其中 $f: S \times Z \rightarrow \mathbb{R}$ 为1-Lipschitz函数, 满足

$$\|f\|_L \triangleq \sup_{(s_1, z_1) \neq (s_2, z_2)} \frac{|f(s_1, z_1) - f(s_2, z_2)|}{d((s_1, z_1), (s_2, z_2))} \leq 1$$

- 这里分母是时间距离 d

- 令 $f(s, z) = \phi(s)^\top \psi(z)$ (平均场理论), 其中 $\phi: S \rightarrow \mathbb{R}^D$ 与 $\psi: Z \rightarrow \mathbb{R}^D$ 具有独立的1-Lipschitz 约束, 从而得到:

$$\sup_{\|\phi\|_L \leq 1, \|\psi\|_L \leq 1} (\mathbb{E}_{p(s,z)} [\phi(s)^\top \psi(z)] - \mathbb{E}_{p(s)} [\phi(s)^\top] \mathbb{E}_{p(z)} [\psi(z)])$$

4



➤ METRA

□ 考虑一种仅依赖于最后状态的Wasserstein 依赖度量变体: $I_W(S_T; Z)$, 进一步分解目标如下:

$$\begin{aligned} I_W(S; Z) &\approx \sup_{\|\phi\|_L \leq 1, \|\psi\|_L \leq 1} \left(\mathbb{E}_{p(\tau, z)} [\phi(s_T)^\top \psi(z)] - \mathbb{E}_{p(\tau)} [\phi(s_T)^\top] \mathbb{E}_{p(z)} [\psi(z)] \right) \\ &= \sup_{\phi, \psi} \sum_{t=0}^{T-1} \left(\mathbb{E}_{p(\tau, z)} [(\phi(s_{t+1}) - \phi(s_t))^\top \psi(z)] - \mathbb{E}_{p(\tau)} [\phi(s_{t+1}) - \phi(s_t)]^\top \mathbb{E}_{p(z)} [\psi(z)] \right) \end{aligned}$$

这里通过裂项相消得到, 利用了 $p(s_0)$ 和 $p(z)$ 相互独立的事实。 $\mathbb{E}_{p(\tau, z)} [\phi(s_0)^\top z] - \mathbb{E}_{p(\tau)} [\phi(s_0)]^\top \mathbb{E}_{p(z)} [z] = 0$

□ 将 $\psi(z)$ 设为 z , 尽管这使得 ψ 的表达力减弱, 但能够推导出以下目标:

$$I_W(S; Z) \approx \sup_{\|\phi\|_L \leq 1} \mathbb{E}_{p(\tau, z)} \left[\sum_{t=0}^{T-1} (\phi(s_{t+1}) - \phi(s_t))^\top (z - \bar{z}) \right]$$

时间距离: 从一个状态到另一个状态所需的最小环境步数。非对称度量(拟度量)。

□ 假设先验分布 $p(z)$ 为零均值先验分布, 因此可不失一般性地假设 $\bar{z}=0$, 利用**时间距离度量**, 重写为:

$$\sup_{\pi, \phi} \mathbb{E}_{p(\tau, z)} \left[\sum_{t=0}^{T-1} (\phi(s_{t+1}) - \phi(s_t))^\top z \right]$$

$s.t. \|\phi(s) - \phi(s')\|_2 \leq 1, \forall (s, s') \in \mathcal{S}_{\text{adj}}$

在时间距离度量下, $\|\phi\|_L$ 可以等价转化为如下欧氏距离的形式 $\|\phi(s) - \phi(s')\|_2 \leq 1$

其中 $\mathcal{S}_{\text{adj}}$ 表示 MDP中相邻状态对的集合。

(a) 对于所有的 $u, v \in \mathcal{S}$, $\|\phi(u) - \phi(v)\|_2 \leq d_{\text{temp}}(u, v)$ 成立。

□ 奖励定义: $r(s, z, s') = (\phi(s') - \phi(s))^\top z$

(b) 对于所有的 $(s, s') \in \mathcal{S}_{\text{adj}}$, $\|\phi(s) - \phi(s')\|_2 \leq 1$ 。

5



➤ METRA

□ 算法流程:

Algorithm 1 Metric-Aware Abstraction (METRA)

1: 初始化: 技能策略 $\pi(a | s, z)$ 、表征函数 $\phi(s)$ 、拉格朗日乘子 λ 、经验缓冲区 D

2: 对于 $i \leftarrow 1$ 到 (# epochs) 执行

3: 对于 $j \leftarrow 1$ 到 (# episodes per epoch) 执行

4: 采样技能 $z \sim p(z)$

5: 使用 $\pi(a | s, z)$ 采样轨迹 τ 并添加到经验缓冲区 D

拉格朗日乘子法将约束优化问题转化为无约束问题

6: 结束循环

7: 更新 $\phi(s)$ 通过最大化 $\mathbb{E}_{(s, z, s') \sim D} [(\phi(s') - \phi(s))^\top z + \lambda \cdot \min(\varepsilon, 1 - \|\phi(s) - \phi(s')\|_2^2)]$

8: 更新 λ 通过最小化 $\mathbb{E}_{(s, z, s') \sim D} [\lambda \cdot \min(\varepsilon, 1 - \|\phi(s) - \phi(s')\|_2^2)]$ 拉格朗日乘子的更新

9: 更新 $\pi(a | s, z)$ 通过使用 SAC 和奖励 $r(s, z, s') = (\phi(s') - \phi(s))^\top z$ 奖励的定义

10: 结束循环

6

➤ METRA

□ 直观理解:




图 10: METRA 的直观解释。我们的核心思想是仅覆盖与状态空间 S 度量相连的紧凑潜在空间 Z 。具体而言, METRA 学习一个有损的、紧凑的表示函数 $\phi: S \rightarrow Z$, 该函数保持时间距离 (左), 并学会在 Z 的每个方向上移动, 从而实现对状态空间 S 的近似覆盖 (右)。




图 11: METRA 的示意图。我们在可扩展无监督强化学习中的核心思想是仅覆盖状态空间中最重要低维子集。这类似于 PAC。具体而言, METRA 覆盖的是最具“时间分散性”的(非线性)流形, 从而实现对状态空间的近似覆盖。在上述例子中, 二维 Z 空间捕捉了所有方向上的行为, 并不一定会覆盖每一种可能的腿部姿态。

- **核心机制:** 策略 $\pi(a | s, z)$ 需驱动智能体在潜在空间中沿不同方向 (由 z 指定) 有效移动。由于潜在距离 $\|\phi(s_1) - \phi(s_2)\|_2$ 受限原始状态间的时间距离 $d_{\text{temp}}(s_1, s_2)$, 学习的目标是将有限的潜在维度分配给原始状态中最“分散”的流形, 从而最大化所表示状态之间的最短路径长度。
- **方法类比:** 此过程类似于提取状态空间的“时间主成分”, 但基于最短路径距离且适用于非线性映射 ϕ 。其线性特例等价于在时间嵌入空间中执行 PCA。METRA 目标激励智能体在潜在容量有限的条件下, 尽可能扩展现有状态空间中最大的“时间”流形。
- **方法命名:** 编码器 ϕ 旨在以有损方式抽象状态空间, 保留关键时间距离结构(左图)的同时, 强调那些能构成最大可能“时间”流形的状态自由度(右图)。基于这一对度量感知的直觉, 方法命名为 Metric-Aware Abstraction。 7

➤ METRA 扩展

□ 附录中从公式(32)到公式(34)的推导:

下面是本文 WDM(Wasserstein dependency measure)目标的一个形式, 它是将 $I_W(S; Z)$ 用内积分解后得到的逐时间步求和形式:

$$\sum_{t=0}^{T-1} (\mathbb{E}_{p(\tau, z)} [\phi_L(s_t)^\top \psi_L(z)] - \mathbb{E}_{p(\tau)} [\phi_L(s_t)]^\top \mathbb{E}_{p(z)} [\psi_L(z)]) \quad (32)$$

然后作者做了一个简化设定: 令 $\psi_L(z) = z$, 即让 ψ 函数为恒等映射。同时假设 $p(z)$ 是均值为零的分布 (例如标准高斯分布), 因此 $\mathbb{E}_{p(z)} [\psi_L(z)] = \mathbb{E}_{p(z)} [z] = 0$ 。于是, 上式中的第二项 $\mathbb{E}_{p(\tau)} [\phi_L(s_t)]^\top \mathbb{E}_{p(z)} [z] = 0$, 可以消去。剩下第一项 $\sum_{t=0}^{T-1} \mathbb{E}_{p(\tau, z)} [\phi_L(s_t)^\top z]$ 对应的奖励信号可以设为每个时间步的瞬时奖励 (内积形式):

$$r_t = \phi_L(s_t)^\top z \quad \text{内积} \quad (34)$$

□ 如果不做简化设定, 公式(32)得到的奖励是:

$$\begin{aligned} r_t &= \phi_L(s_t)^\top \psi_L(z) - \phi_L(s_t)^\top \mathbb{E}_{p(z)} [\psi_L(z)] \\ &\approx \phi_L(s_t)^\top \psi_L(z) - \frac{1}{L} \sum_{i=1}^L \phi_L(s_t)^\top \psi_L(z_i) \end{aligned}$$

这里用到了蒙特卡洛近似采样方法。根据 Jensen 不等式, 上式奖励可以被下界界定为

$$\phi_L(s_t)^\top \psi_L(z) - \frac{1}{L} \sum_{i=1}^L \phi_L(s_t)^\top \psi_L(z_i) = \phi_L(s_t)^\top \psi_L(z) - \frac{1}{L} \sum_{i=1}^L \log \exp(\phi_L(s_t)^\top \psi_L(z_i)) \geq \phi_L(s_t)^\top \psi_L(z) - \log \left(\frac{1}{L} \sum_{i=1}^L \exp(\phi_L(s_t)^\top \psi_L(z_i)) \right)$$



➤ METRA扩展

□ 附录中从公式(33)到公式(39)(40)的推导:

公式(33)是 $I_W(S_T; Z)$ 的内积分解形式:

$$\sum_{t=0}^{T-1} (\mathbb{E}_{p(\tau, z)}[(\phi_L(s_{t+1}) - \phi_L(s_t))^\top \psi_L(z)] - \mathbb{E}_{p(\tau)}[\phi_L(s_{t+1}) - \phi_L(s_t)]^\top \mathbb{E}_{p(z)}[\psi_L(z)]) \quad (33)$$

推导出公式(39)

作者做以下简化:

1. 设 $\phi_L(s) = s$, 即令状态映射为恒等映射 (适用于状态空间为欧几里得空间的情况)。于是 $\phi_L(s_{t+1}) - \phi_L(s_t) = s_{t+1} - s_t$ 。

2. 公式(33)变为: $\sum_{t=0}^{T-1} (\mathbb{E}_{p(\tau, z)}[(s_{t+1} - s_t)^\top \psi_L(z)] - \mathbb{E}_{p(\tau)}[s_{t+1} - s_t]^\top \mathbb{E}_{p(z)}[\psi_L(z)])$

3. 将每一项的期望拆开, 得到一个时间步奖励信号 r_t :

$$r_t = (s_{t+1} - s_t)^\top \psi_L(z) - (s_{t+1} - s_t)^\top \mathbb{E}_{p(z)}[\psi_L(z)] \quad (39)$$

推导出公式(40)

公式(39)中有一个期望项 $\mathbb{E}_{p(z)}[\psi_L(z)]$, 在实际训练时需要通过采样来近似估计。

1. 从先验分布 $p(z) = \mathcal{N}(0, I)$ 中独立采样 L 个样本 $z_1, z_2, \dots, z_L$ 。

2. 用蒙特卡洛均值近似期望: $\mathbb{E}_{p(z)}[\psi_L(z)] \approx \frac{1}{L} \sum_{i=1}^L \psi_L(z_i)$

3. 代入公式(39), 得到近似的奖励信号:

$$r_t \approx (s_{t+1} - s_t)^\top \psi_L(z) - \frac{1}{L} \sum_{i=1}^L (s_{t+1} - s_t)^\top \psi_L(z_i) \quad \text{内积} \quad (40)$$

9



➤ METRA扩展

□ DIAYN方法: 反向互信息, 假设变分分布 $q(z|s)$ 为高斯分布 $\mathcal{N}(\phi(s), I)$, 奖励为欧氏距离形式:

$$I(S; Z) = -H(Z|S) + H(Z)$$

$$\gtrsim \mathbb{E}_{p(\tau, z)} \left[\sum_{t=0}^{T-1} \log q(z|s_t) \right]$$

$$\simeq \mathbb{E}_{p(\tau, z)} \left[\sum_{t=0}^{T-1} -\|z - \phi(s_t)\|_2^2 \right]$$

$$r_t^{\text{DIAYN}} = -\|\phi(s_t) - z\|_2^2, \quad \text{欧氏距离}$$

□ CIC方法: 对比学习, 通过噪声对比估计来估算互信息, 奖励为:

$$I(S; Z) \gtrsim \mathbb{E}_{p(\tau, z)} \left[\sum_{t=0}^{T-1} \left(\phi(s_t)^\top \psi(z) - \log \frac{1}{L} \sum_{i=1}^L \exp(\phi(s_t)^\top \psi(z_i)) \right) \right]$$

$$r_t^{\text{CIC}} = \phi(s_t)^\top \psi(z) - \log \frac{1}{L} \sum_{i=1}^L \exp(\phi(s_t)^\top \psi(z_i)) \quad \text{内积}$$

□ DADS方法: 前向互信息, 假设变分分布 $q(s'|s, z)$ 被建模为高斯分布 $q(s'|s, z) = \mathcal{N}(\psi(s, z), I)$, 奖励为:

$$I(S'; Z|S) = -H(S'|S, Z) + H(S'|S)$$

$$\gtrsim \mathbb{E}_{p(\tau, z)} \left[\sum_{t=0}^{T-1} \log q(s_{t+1}|s_t, z) - \log p(s_{t+1}|s_t) \right]$$

$$\approx \mathbb{E}_{p(\tau, z)} \left[\sum_{t=0}^{T-1} \left(\log q(s_{t+1}|s_t, z) - \frac{1}{L} \sum_{i=1}^L \log q(s_{t+1}|s_t, z_i) \right) \right],$$

$$r_t^{\text{DADS}} = -\|(s_{t+1} - s_t) - \psi(s_t, z)\|_2^2 + \frac{1}{L} \sum_{i=1}^L \|(s_{t+1} - s_t) - \psi(s_t, z_i)\|_2^2 \quad \text{欧氏距离}$$

10

额外补充:

- **total_steps**: 表示在整个训练过程中, 智能体在环境中采取的总动作次数。
- **n_epochs**: 表示训练过程的总迭代次数。每个epoch是一个完整的训练周期, 通常包含数据采集、策略更新和评估等完整流程。
- **num_episodes_per_epoch**: 表示每个epoch中收集的episode数量。一个episode是从初始状态开始到终止状态结束的一段完整轨迹, 由多个step组成。例如CartPole中小车从启动到杆子倒下的全过程。episode结束后环境会自动重置, 开始新的尝试。
- **episode_length**: 表示每个episode的长度, 即每个episode中包含的steps数量。
- **step**: 智能体执行一次动作的交互过程, 例如游戏角色移动一次或机械臂抓取一次。这是RL中最小的数据采集单位, 每次step产生一个 (s, a, r, s') 样本。

总环境步数 (total_steps) 为 (前提是右边三个量都是固定的): $\text{total_steps} \approx \text{n_epochs} \times \text{num_episodes_per_epoch} \times \text{episode_length}$

例如, $\text{n_epochs} = 10000$ 、 $\text{num_episodes_per_epoch} = 8$ 、 $\text{episode_length} = 200$ (Ant/HalfCheetah), 则: $\text{total_steps} \approx 10000 \times 8 \times 200 = 1.6 \times 10^7$ 步。

METRA与LSD、DADS、DIAYN的区别：

区别	METRA (2024)	LSD (2022)	DADS (2020)	DIAYN (2019)
谱归一化	✗	✓	✗	✗
z 单位化	✓	✓	✗	✗
有无约束目标	✓	✗	✗	✗
奖励 r 的定义	$(\phi(s') - \phi(s))^{\top} z$	$(\phi(s') - \phi(s))^{\top} z$	$\log q(s_{t+1} s_t, z)$ $-\frac{1}{L} \sum_{i=1}^L \log q(s_{t+1} s_t, z_i)$	$\log q(z s)$ $\propto -\ \phi(s) - z\ ^2$
状态表征目标	$\mathbb{E}_{p^{\beta}(s, s', z)} \left[(\phi(s') - \phi(s))^{\top} z \right]$ $+\lambda \cdot \min(\varepsilon, 1 - \ \phi(s) - \phi(s')\ _2^2)$	$\mathbb{E}_{z, \tau} \left[\sum_{t=0}^{T-1} (\phi(s') - \phi(s))^{\top} z \right]$	$\mathbb{E}_{z, \tau} \left[\sum_{t=0}^{T-1} \begin{pmatrix} \log q(s_{t+1} s_t, z) \\ -\log p(s_{t+1} s_t) \end{pmatrix} \right]$	$\mathbb{E}_{z, \tau} \left[\sum_{t=0}^{T-1} \log q(z s_t) \right]$

批注：表格里的谱归一化表示神经网络的每一层权重都满足李普希兹连续性。**z单位化**表示对z进行单位化，使其成为单位向量（长度为1）。

METRA代码里不同任务参数设置：

任务	技能维度	每个 epoch 梯度步	缓冲池容量	并行进程数	最大路径长度	日志记录间隔	评估间隔	模型保存间隔
HalfCheetah(States)	16(离散)	50	1e6	1	200	100	1000	10000
Ant(States)	2	50	1e6	1	200	100	1000	10000
Quadruped(Pixels)	4	200	3e5	4	200	25	125	1000
Humanoid(Pixels)	2	200	3e5	4	200	25	125	1000
Kitchen(Pixels)	24(离散)	100	1e5	4	50	25	250	1000

参考资料：

[1] Park S, Rybkin O, Levine S. [METRA: Scalable Unsupervised RL with Metric-Aware Abstraction](#). In International Conference on Learning Representations (ICLR), 2024.

[2] 平均场理论：凯鲁嘎吉 - <https://www.cnblogs.com/kailugaji/p/10692797.html>、<https://www.cnblogs.com/kailugaji/p/12463966.html>

[3] 生成对抗网络(GAN与W-GAN)：凯鲁嘎吉 - <https://www.cnblogs.com/kailugaji/p/15352841.html>

[4] 非对称度量即拟度量的定义：凯鲁嘎吉 - <https://www.cnblogs.com/kailugaji/p/19210601>

[5] DIAYN: Benjamin Eysenbach, Abhishek Gupta, Julian Ibarz, and Sergey Levine. [Diversity is all you need: Learning skills without a reward function](#). In International Conference on Learning Representations (ICLR), 2019.

[6] DADS: Archit Sharma, Shixiang Gu, Sergey Levine, Vikash Kumar, and Karol Hausman. [Dynamics aware unsupervised discovery of skills](#). In International Conference on Learning Representations (ICLR), 2020.

[7] CIC: Michael Laskin, Hao Liu, Xue Bin Peng, Denis Yarats, Aravind Rajeswaran, and P. Abbeel. [Unsupervised reinforcement learning with contrastive intrinsic control](#). In Neural Information Processing Systems (NeurIPS), 2022.

[8] MoonOut - 大佬解读：[Skill Discovery | METRA: 让策略探索 state 的紧凑 embedding space](#)

[9] CSF: 对METRA的进一步解读与改进：凯鲁嘎吉 - [论文解读 | Can A Misl Fly? Analysis And Ingredients for Mutual Information Skill Learning](#)

CSF对METRA代码进一步补充扩展，得到如下奖励与目标：

不同奖励函数对比表

模式	触发条件	奖励公式（连续技能）	奖励公式（离散技能）	核心思想	典型算法
Inner Product (METRA 风格)	self.inner == True	$r = (\phi(s') - \phi(s))^T z$ (若 no_diff_in_rep=True: $r = \phi(s)^T z$)	$r = (\phi(s') - \phi(s))^T \cdot (z - \frac{1}{d} \mathbf{1}) \cdot \frac{d}{d-1}$	技能 z 应与状态表征的变化方向对齐	METRA
General $f(s, s')$ (MLP Pair Encoder)	self.metra_mlp_rep == True	$r = f(s, s')^T z$	同左（通常不用于离散）	使用专用网络 f 编码状态转移对 (s, s') ，更灵活	CSF / METRA 泛化
DIAYN 风格 (后验匹配)	默认（以上均为 False）	$r = \log p(z s') - \log p(z)$ (通常 $p(z)$ 为均匀分布)	$r = -\text{CE}(p(z s'), z) + \log d$	鼓励状态可区分技能，最大化互信息 $I(s'; z)$	DIAYN

不同目标函数对比表

模式	条件触发	目标函数表达式	数学公式	说明
无约束模式	not self.dual_reg	rewards	$\mathcal{L}_{\text{TE}} = -\mathbb{E}[r]$	基础设定，如 CIC、VISR、DIAYN 等方法，仅最大化奖励。
自归一化模式	self.self_normalizing == True	rewards	$\mathcal{L}_{\text{TE}} = -\mathbb{E}[r / \ r\]$	编码向量被归一化为单位长度，奖励仅反映方向一致性，不依赖幅度。
InfoNCE 对比学习模式	self.log_sum_exp == True	rewards - $\lambda \cdot \text{log_sum_exp}$	$\mathcal{L}_{\text{TE}} = -\mathbb{E} \left[r - \lambda \cdot \log \sum_k e^{f_k} \right]$	CSF 风格：引入 InfoNCE 负样本惩罚，鼓励正样本对相似、负样本对远离。通常 $\lambda = 1$ 。
固定拉格朗日乘子约束	self.fixed_lam is not None	rewards + $\lambda \cdot \text{cst_penalty}$	$\mathcal{L}_{\text{TE}} = -\mathbb{E} \left[r + \lambda \cdot \min \left(d - \ \phi(s') - \phi(s)\ ^2, \text{slack} \right) \right]$	METRA 风格：强制编码变化接近常数 d （此处 $d = 1$ ），使用固定超参 λ 。
可学习对偶变量约束	默认（dual_reg=True 且以上均不满足）	rewards + $\text{dual_lam} \cdot \text{cst_penalty}$	$\mathcal{L}_{\text{TE}} = -\mathbb{E} \left[r + \lambda_{\text{dual}} \cdot \min \left(1 - \ \phi(s') - \phi(s)\ ^2, \text{slack} \right) \right]$	METRA 风格：拉格朗日乘子 $\lambda_{\text{dual}} = \exp(\theta)$ 可学习，通过对偶上升自动调节约束强度。