

一类涉及矩阵范数的优化问题

作者：凯鲁嘎吉 - 博客园 <http://www.cnblogs.com/kailugaji/>

这篇博文主要探讨一下有关矩阵范数的优化问题，我们知道，矩阵按行或列拆开就是向量，因此矩阵范数优化问题在某种程度上可以转化为向量范数的优化，而向量拆开是一个个数值，因此向量优化问题就进一步退化为单变量优化。因此，我们从最基础的单变量优化出发，单变量优化问题搞清楚之后，再逐步拓展到向量、矩阵范数的优化上。文中涉及到向量范数、矩阵范数、软阈值算子(soft thresholding/shrinkage operator)与奇异值收缩算子(singular value shrinkage operator)等概念。这类优化问题在矩阵补全/填充、压缩感知、稀疏表达、低秩矩阵分解(比如[张长青2015在ICCV会议上发表的Low-Rank Tensor Constrained Multiview Subspace Clustering中E与G的求解问题](#))、鲁棒主成分分析(Robust PCA)等领域有广泛的应用。尤其是矩阵的 $L_{2,1}$ 范数与矩阵的核范数/迹范数(nuclear/trace norm)在去噪去冗余降维等方面应用最广。

1. 向量范数与矩阵范数

➤ 向量的范数 $\mathbf{x} \in \mathbf{R}^n$

▣ 向量的0范数

向量 \mathbf{x} 中非0元素的个数

▣ 向量的1范数

$$\|\mathbf{x}\|_1 = \sum_{i=1}^n |x_i|$$

▣ 向量的2范数

$$\|\mathbf{x}\|_2 = (\mathbf{x}, \mathbf{x})^{\frac{1}{2}} = \sqrt{\sum_{i=1}^n x_i^2}$$

▣ 向量的p范数

$$\|\mathbf{x}\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}, p \in [1, \infty)$$

▣ 向量的无穷范数

$$\|\mathbf{x}\|_{\infty} = \max_{1 \leq i \leq n} |x_i|$$

➤ 矩阵的范数 $\mathbf{A} \in \mathbf{R}^{m \times n}$

▣ 矩阵的列范数

$$\|\mathbf{A}\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}|$$

▣ 矩阵的行范数

$$\|\mathbf{A}\|_{\infty} = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|$$

▣ 矩阵的2范数

$$\|\mathbf{A}\|_2 = \sqrt{\lambda_{\max}(\mathbf{A}^T \mathbf{A})}$$

其中 $\lambda_{\max}(\mathbf{A}^T \mathbf{A})$ 表示 $\mathbf{A}^T \mathbf{A}$ 的最大特征值

▣ 矩阵的Frobenius范数

$$\|\mathbf{A}\|_F = \sqrt{\text{tr}(\mathbf{A}^T \mathbf{A})} = \sqrt{\sum_{i=1}^m \sum_{j=1}^n a_{ij}^2}$$

▣ $L_{2,1}$ 范数

$$\|\mathbf{A}\|_{2,1} = \sum_{i=1}^m \sqrt{\sum_{j=1}^n a_{ij}^2}$$

▣ 核范数: 矩阵的奇异值之和(用来约束低秩low-rank) $\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^T$

$$\|\mathbf{A}\|_* = \text{tr}(\sqrt{\mathbf{A}^T \mathbf{A}}) = \text{tr}(\mathbf{\Sigma})$$

2. 单变量绝对值优化问题

➤ 单变量绝对值优化问题

- 问题描述：已知 x 与 y 是数值，给定如下优化问题， y 已知， $\alpha > 0$ ，求 x 的最优解

$$\min_x J(x) = \alpha |x| + \frac{1}{2} |x - y|^2 \quad \text{这里假定 } 0/0=0, |x| \text{ 表示 } x \text{ 的绝对值}$$

- x 的最优解如下：

$$\hat{x} = \frac{y}{|y|} \max(|y| - \alpha, 0) = \text{sgn}(y) \max(|y| - \alpha, 0) = \text{soft}(y, \alpha)$$

- 其中 $\text{sgn}()$ 为符号函数

- $\text{soft}()$ 为软阈值算子(soft thresholding operator)或收缩算子(shrinkage operator)

$$\text{sgn}(y) = \frac{y}{|y|} = \begin{cases} 1, & y > 0; \\ 0, & y = 0; \\ -1, & y < 0. \end{cases} \quad \text{soft}(y, \alpha) = \text{sgn}(y) \max(|y| - \alpha, 0) = \begin{cases} y + \alpha, & y \leq -\alpha; \\ 0, & |y| \leq \alpha; \\ y - \alpha, & y \geq \alpha. \end{cases}$$

► 单变量绝对值优化问题

• 解: $\frac{\partial J(x)}{\partial x} = x - y + \alpha \frac{x}{|x|} = 0 \Rightarrow y = x + \alpha \frac{x}{|x|} = \frac{|x| + \alpha}{|x|} x$

若 $y > 0$, 则 $x \geq 0$.

当 $x = 0$, $J(x) = \frac{1}{2} y^2$;

当 $x > 0$, $y = \alpha + x \Rightarrow x = y - \alpha, J(x) = \alpha(y - \alpha) + \frac{1}{2} \alpha^2 = \alpha y - \frac{1}{2} \alpha^2$.

$\frac{1}{2} y^2 - \left(\alpha y - \frac{1}{2} \alpha^2 \right) = \frac{1}{2} (y - \alpha)^2 \geq 0. \quad \therefore x = \max(y - \alpha, 0).$

若 $y < 0$, 则 $x \leq 0$.

当 $x = 0$, $J(x) = \frac{1}{2} y^2$;

当 $x < 0$, $y = x - \alpha \Rightarrow x = y + \alpha, J(x) = -\alpha(y + \alpha) + \frac{1}{2} \alpha^2 = -\alpha y - \frac{1}{2} \alpha^2$.

$\frac{1}{2} y^2 - \left(-\alpha y - \frac{1}{2} \alpha^2 \right) = \frac{1}{2} (y + \alpha)^2 \geq 0. \quad \therefore x = \min(y + \alpha, 0).$

若 $y = 0$, 则 $x = 0$ 或 $x > 0$ 或 $x < 0$.

当 $x > 0$, $x = -\alpha, J(x) = -\frac{1}{2} \alpha^2 < 0$ (舍).

当 $x = 0$, $J(x) = 0$;

当 $x < 0$, $x = \alpha, J(x) = -\frac{1}{2} \alpha^2 < 0$ (舍).

$\therefore x = 0.$

$\therefore \hat{x} = \max(y - \alpha, 0) + \min(y + \alpha, 0)$

$= \frac{y}{|y|} \max(|y| - \alpha, 0)$

$= \operatorname{sgn}(y) \max(|y| - \alpha, 0)$

$= \operatorname{soft}(y, \alpha)$

➤ 单变量绝对值优化问题

- 从结果引出思考

$$\hat{x} = \text{soft}(y, \alpha) = \text{sgn}(y) \max(|y| - \alpha, 0) = \begin{cases} y + \alpha, & y \leq -\alpha; \\ 0, & |y| \leq \alpha; \\ y - \alpha, & y \geq \alpha. \end{cases}$$

- 由 $y = x + \alpha \frac{x}{|x|} = \frac{|x| + \alpha}{|x|} x$ 及上述结果可知,

当 $|y| > \alpha$ 时, x 与 y 呈正线性相关, 两者同向。因此有 x 与 y 这两者的单位长度相等, 即 $\frac{\partial |x|}{\partial x} = \frac{x}{|x|} = \frac{y}{|y|} \quad (|y| > \alpha)$

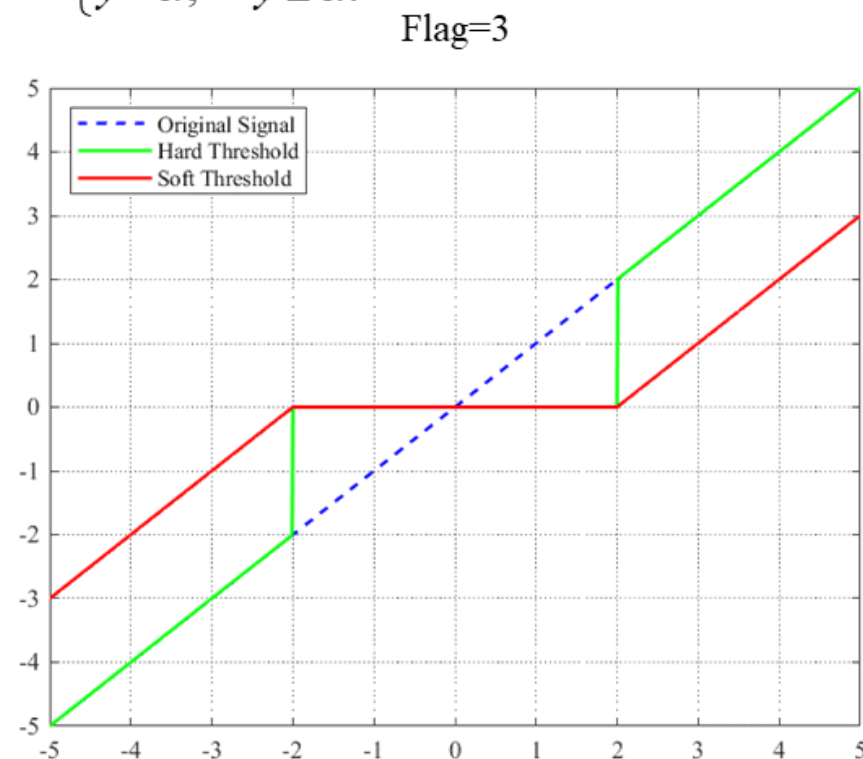
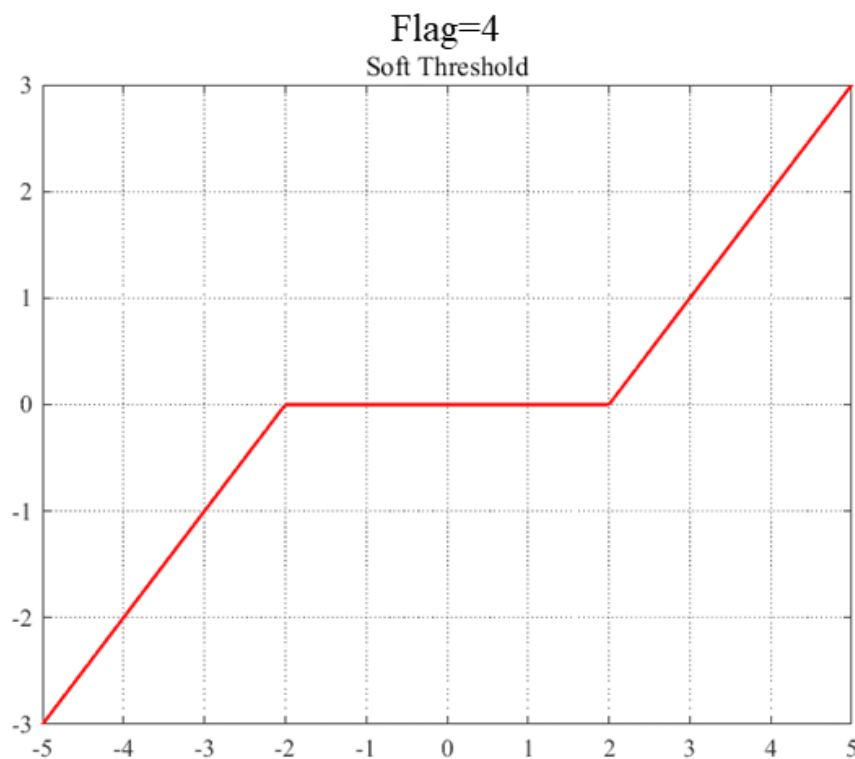
$$\therefore x - y + \alpha \frac{x}{|x|} = x - y + \alpha \frac{y}{|y|} = 0$$

$$\begin{aligned} \Rightarrow \hat{x} &= y - \alpha \frac{y}{|y|} = \frac{y}{|y|} (|y| - \alpha) \quad (|y| > \alpha) \\ &= \text{sgn}(y) \max(|y| - \alpha, 0) \end{aligned}$$

解析解

➤ 单变量绝对值优化问题(MATLAB程序实现)

$$\hat{x} = \text{soft}(y, \alpha) = \text{sgn}(y) \max(|y| - \alpha, 0) = \begin{cases} y + \alpha, & y \leq -\alpha; \\ 0, & |y| \leq \alpha; \\ y - \alpha, & y \geq \alpha. \end{cases}$$



蓝虚线：原始信号，绿线：硬阈值函数，红线：软阈值函数。 $(\alpha=2, \text{横坐标}y, \text{纵坐标}x)$

3. 向量范数优化问题

➤ 向量范数优化问题

- 问题描述：已知 \mathbf{x} 与 \mathbf{y} 是两个向量，给定如下优化问题， \mathbf{y} 已知， $\alpha > 0$ ，求 \mathbf{x} 的最优解

$$\min_{\mathbf{x}} J(\mathbf{x}) = \alpha \|\mathbf{x}\| + \frac{1}{2} \|\mathbf{x} - \mathbf{y}\|^2 \quad \text{这里假定 } 0/0=0, \|\mathbf{x}\| \text{ 表示向量 } \mathbf{x} \text{ 的某种范数}$$

$$\bullet \text{ 解: } \frac{\partial J(\mathbf{x})}{\partial \mathbf{x}} = \mathbf{x} - \mathbf{y} + \alpha \frac{\mathbf{x}}{\|\mathbf{x}\|} = 0 \Rightarrow \mathbf{y} = \mathbf{x} + \alpha \frac{\mathbf{x}}{\|\mathbf{x}\|} = \frac{\|\mathbf{x}\| + \alpha}{\|\mathbf{x}\|} \mathbf{x} \Rightarrow \mathbf{x} = \frac{\|\mathbf{x}\|}{\|\mathbf{x}\| + \alpha} \mathbf{y}$$

$$\text{由 } \frac{\partial \|\mathbf{x}\|}{\partial \mathbf{x}} = \frac{\mathbf{x}}{\|\mathbf{x}\|} = \frac{\mathbf{y}}{\|\mathbf{y}\|} \quad (\|\mathbf{y}\| > \alpha) \quad \therefore \mathbf{x} - \mathbf{y} + \alpha \frac{\mathbf{x}}{\|\mathbf{x}\|} = \mathbf{x} - \mathbf{y} + \alpha \frac{\mathbf{y}}{\|\mathbf{y}\|} = 0$$

$$\begin{aligned} \Rightarrow \hat{\mathbf{x}} &= \mathbf{y} - \alpha \frac{\mathbf{y}}{\|\mathbf{y}\|} = \frac{\mathbf{y}}{\|\mathbf{y}\|} (\|\mathbf{y}\| - \alpha) \quad (\|\mathbf{y}\| > \alpha) \\ &= \text{sgn}(\mathbf{y}) \max(\|\mathbf{y}\| - \alpha, 0) \end{aligned}$$

数值解

解析解

4. 矩阵 $L_{2,1}$ 范数优化问题

➤ 矩阵 $L_{2,1}$ 范数优化问题

- 问题描述：已知 X 与 Y 是两个矩阵(大小为 $N \times M$)，给定如下优化问题， Y 已知， $\alpha > 0$ ，求 X 的最优解

$$\min_X J(X) = \alpha \|X\|_{2,1} + \frac{1}{2} \|X - Y\|_F^2 \quad \text{这里假定 } 0/0=0, \|X\| \text{ 表示矩阵 } X \text{ 的某种范数}$$

- 解： $\|X\|_{2,1} = \sum_{i=1}^N \sqrt{\sum_{j=1}^M x_{ij}^2} = \sum_{i=1}^N \|X_{i\cdot}\|_2$

$$\frac{\partial J(X_i)}{\partial X_i} = X_i - Y_i + \alpha \frac{\partial \|X_{i\cdot}\|_2}{\partial X_i} = X_i - Y_i + \alpha \frac{X_{i\cdot}}{\|X_{i\cdot}\|_2} = 0 \Rightarrow X_{i\cdot} = \frac{\|X_{i\cdot}\|_2}{\|X_{i\cdot}\|_2 + \alpha} Y_i$$

$$\text{由 } \frac{\partial \|X_{i\cdot}\|_2}{\partial X} = \frac{X_{i\cdot}}{\|X_{i\cdot}\|_2} = \frac{Y_i}{\|Y_i\|_2} \quad (\|Y_i\|_2 > \alpha)$$

$$\Rightarrow \hat{X}_{i\cdot} = Y_i - \alpha \frac{Y_i}{\|Y_i\|_2} \quad (\|Y_i\|_2 > \alpha) = \frac{Y_i}{\|Y_i\|_2} (\|Y_i\|_2 - \alpha) \quad (\|Y_i\|_2 > \alpha)$$

$$= \frac{Y_i}{\|Y_i\|_2} \max(\|Y_i\|_2 - \alpha, 0)$$

数值解

解析解

5. 矩阵核范数优化问题

➤ 矩阵核范数优化问题

- 问题描述：已知 X 与 Y 是两个矩阵，给定如下优化问题， Y 已知， $\alpha > 0$ ，求 X 的最优解

$$\min_X J(X) = \alpha \|X\|_* + \frac{1}{2} \|X - Y\|_F^2 \quad \text{这里假定 } 0/0=0, \|X\| \text{ 表示矩阵 } X \text{ 的某种范数}$$

$$\bullet \text{ 解: } \frac{\partial J(X)}{\partial X} = X - Y + \alpha \frac{\partial \|X\|_*}{\partial X} = 0$$

考虑特征值分解 $X = U_X \Sigma_X V_X^T$, $Y = U_Y \Sigma_Y V_Y^T$
 Σ 中元素非负, U 与 V 为正交阵, $U^T U = U U^T = I$.

$$\begin{aligned} \|X\|_* &= \text{tr}(\sqrt{X^T X}) = \text{tr}(\sqrt{(U_X \Sigma_X V_X^T)^T (U_X \Sigma_X V_X^T)}) \\ &= \text{tr}(\sqrt{V_X \Sigma_X^2 V_X^T}) = \text{tr}(\sqrt{V_X^T V_X \Sigma_X^2}) = \text{tr}(\sqrt{\Sigma_X^2}) = \text{tr}(\Sigma_X) \end{aligned}$$

(用到迹的循环性, Σ 非负性, U 与 V 正交矩阵的性质)

$$\begin{aligned} \Rightarrow \frac{\partial \|X\|_*}{\partial X} &= \frac{\partial \text{tr}(\Sigma_X)}{\partial X} = \frac{\text{tr}(\partial \Sigma_X)}{\partial X} \\ &= \frac{\text{tr}(U_X^T \partial X V_X)}{\partial X} = \frac{\text{tr}(V_X U_X^T \partial X)}{\partial X} \\ &= (V_X U_X^T)^T = U_X V_X^T \end{aligned}$$

$$\begin{aligned} \partial X &= \partial U_X \Sigma_X V_X^T + U_X \partial \Sigma_X V_X^T + U_X \Sigma_X \partial V_X^T \\ \therefore U_X \partial \Sigma_X V_X^T &= \partial X - \partial U_X \Sigma_X V_X^T - U_X \Sigma_X \partial V_X^T \\ \text{等式两边左乘 } U_X^T, \text{ 右乘 } V_X & \\ \therefore U_X^T U_X \partial \Sigma_X V_X^T V_X &= U_X^T \partial X V_X - U_X^T \partial U_X \Sigma_X V_X^T V_X - U_X^T U_X \Sigma_X \partial V_X^T V_X \\ \therefore \partial \Sigma_X &= U_X^T \partial X V_X - U_X^T \partial U_X \Sigma_X - \Sigma_X \partial V_X^T V_X \\ \therefore \text{tr}(\partial \Sigma_X) &= \text{tr}(U_X^T \partial X V_X - U_X^T \partial U_X \Sigma_X - \Sigma_X \partial V_X^T V_X) \\ &= \text{tr}(U_X^T \partial X V_X) \end{aligned}$$

(对角阵乘以反对称阵为零矩阵)

➤ 矩阵核范数优化问题

- 问题描述：已知 X 与 Y 是两个矩阵，给定如下优化问题， Y 已知， $\alpha > 0$ ，求 X 的最优解

$$\min_X J(X) = \alpha \|X\|_* + \frac{1}{2} \|X - Y\|_F^2 \quad \text{这里假定 } 0/0=0, \|X\| \text{ 表示矩阵 } X \text{ 的某种范数}$$

- 解： $\frac{\partial J(X)}{\partial X} = X - Y + \alpha \frac{\partial \|X\|_*}{\partial X} = X - Y + \alpha U_X V_X^T = 0 \Rightarrow X = Y - \alpha U_X V_X^T$

$$\text{由 } \frac{\partial \|X\|_*}{\partial X} = U_X V_X^T = U_Y V_Y^T \quad (\Sigma_Y > \alpha I)$$

$$\begin{aligned} \Rightarrow \hat{X} &= Y - \alpha U_Y V_Y^T \quad (\Sigma_Y > \alpha I) \\ &= U_Y \Sigma_Y V_Y^T - \alpha U_Y V_Y^T = U_Y (\Sigma_Y - \alpha I) V_Y^T \quad (\Sigma_Y > \alpha I) \\ &= U_Y \max(\Sigma_Y - \alpha I, 0) V_Y^T = D(Y, \alpha) \end{aligned}$$

解析解

奇异值阈值/收缩算子

6. MATLAB程序

这个程序主要集中于单变量绝对值优化与向量的2范数优化问题。flag=1是向量的优化，其中我们用两种方法进行求解，解析解与数值解，从结果可以看出，在数值解拥有足够的迭代次数时，两者结果大体一致。flag=2是单变量绝对值优化问题，可以直观看出变量 x 与最优值之间的函数图像。flag=3与flag=4是软阈值函数图像，结果见PPT第5页。

```

clear
clc
flag=2; % flag=1, 向量; flag=2, 单变量(一个数值); flag=3, MATLAB自带的软阈值函数; flag=4, 自定义软阈值函数
%% 向量的情况 2D shrinkage formula
% 最小化问题:  $z(x)=\alpha*\|x\|+(\beta/2)*\|x-y\|^2$ 
% alpha=0.5;
% beta=1;
% 用的2范数
if flag==1
    % 法1: 解析解
    % 当 $\|y\|>\alpha$ ,  $x=(\|y\|-\alpha/\beta)*(y/\|y\|)$ 
    y=0.1:0.1:1;
    num=length(y);
    yy=norm(y, 2);
    x_1=((yy-0.5)/yy).*y;
    z_1=0.5*norm(x_1, 2)+0.5*(x_1-y)*(x_1-y)';
    % 法2: 数值解--只要重复次数够大, 能逼近解析解的结果
    %  $x=(\|y\|/((\alpha/\beta)+\|y\|)).*y$ 
    N=50; %重复迭代N次
    x_2=rand(1, num);
    for i=1:N
        xx=norm(x_2, 2);
        x_2=(xx/(0.5+xx)).*y;
    end
    z_2=0.5*norm(x_2, 2)+0.5*(x_2-y)*(x_2-y)';
    % 结果
    x_result=[x_1; x_2] % x的结果, 第一行是方法1的结果, 第二行是方法2的结果
    z=[z_1; z_2] % 最小化问题z的结果, 第一行是方法1的结果, 第二行是方法2的结果

%% 单变量的情况 1D shrinkage formula
elseif flag==2
    %  $z(x)=(\beta/2)*(x-y)^2+\alpha*|x|$ 
    % alpha=0.5, beta=1
    % 当 $|y|>\alpha$ ,  $x=(|y|-\alpha)*(y/|y|)$ 
    x=0.1:0.1:1;
    y=1;
    z=0.5*(x-y).^2+0.5.*abs(x);
    [z_min, index]=min(z);

```

```

plot(x, z);
hold on
plot(x(index), z_min, 'ro');
xlabel('x');
ylabel('z');
x_result=x(index)
z=z_min
%% MATLAB自带的软阈值函数 1D shrinkage formula
elseif flag==3
    x=-5:0.01:5;
    thr=2;
    %  $z(x)=(\beta/2)*(x-y)^2+\alpha*|x|$ 
    %  $thr=\alpha/\beta$ 
    ysoft=wthresh(x,'s',thr); % 软阈值
    ythard = wthresh(x,'h',thr); % 硬阈值
    plot(x, x, 'b--', x, ythard, 'g-', x, ysoft, 'r-', 'LineWidth',1.3);
    legend('Original Signal','Hard Threshold','Soft Threshold','Location','northwest'); %图例的设置
    % 设置网格线
    grid on;
    set(gca, 'FontName','Times New Roman');
    set(gca, 'GridLineStyle',':');
    set(gca, 'GridAlpha', 1);
    saveas(gcf,sprintf('matlab_shrinkage.jpg'),'bmp'); %保存图片
%% 自定义软阈值函数 1D shrinkage formula
elseif flag==4
    x=-5:0.01:5;
    thr=2;
    y=Soft_Threshold(x,thr);
    plot(x, y, 'r-', 'LineWidth',1.3)
    title('Soft Threshold');
    % 设置网格线
    grid on;
    set(gca, 'FontName','Times New Roman');
    set(gca, 'GridLineStyle',':');
    set(gca, 'GridAlpha', 1);
    saveas(gcf,sprintf('soft_shrinkage.jpg'),'bmp'); %保存图片
end
% 自定义软阈值函数

```

```
% z(x)=(beta/2)*(x-y)^2+alpha*|x|
% thr=alpha/beta
function y=Soft_Threshold(x,thr)
    y=sign(x).*max(abs(x) - thr,0);
end
```

当flag=1时，给出向量最优化问题，x_result与z的第一行是解析解的结果，第二行是数值解的结果，可以看到在一定精度范围内两者结果一致。(前提是数值解需要一定的迭代次数)

x_result =

0.0745	0.1490	0.2236	0.2981	0.3726	0.4471	0.5216	0.5961	0.6707	0.7452
0.0745	0.1490	0.2236	0.2981	0.3726	0.4471	0.5216	0.5961	0.6707	0.7452

z =

0.8561
0.8561


当flag=2时，可以从图中看出变量x与目标函数之间的曲线图。

x_result =

0.5000

z =

0.3750



7. 参考文献

- [1] Yang, Junfeng & Yin, Wotao & Zhang, Yin & Wang, Yilun. (2009). [A Fast Algorithm for Edge-Preserving Variational Multichannel Image Restoration](#). SIAM J. Imaging Sciences. 2. 569-592.
- [2] Liu, Jun & Ji, Shuiwang & Ye, Jieping. (2009). [Multi-Task Feature Learning Via Efficient \$l_2, l_1\$ -Norm Minimization](#). Proceedings of the 25th Conference on Uncertainty in Artificial Intelligence, UAI 2009. 339-348.

- [3] Peng, Yali & Sehdev, Paramjit & Liu, Shigang & Li, Jun & Wang, Xili. (2018). [l2,1-norm minimization based negative label relaxation linear regression for feature selection](#). Pattern Recognition Letters. 116.
- [4] Cai, Jian-Feng & Candès, Emmanuel & Shen, Zuowei. (2010). [A Singular Value Thresholding Algorithm for Matrix Completion](#). SIAM Journal on Optimization. 20. 1956-1982.
- [5] [最优化之Robust PCA](#) - 博客园 - [quarryman](#)
- [6] linear algebra - [Derivative of the nuclear norm](#) - Mathematics Stack Exchange
- [7] 2010 [Proximal gradient method](#) (PPT)
- [8] Toh, Kim-Chuan & Yun, Sangwoon. (2010). [An Accelerated Proximal Gradient Algorithm for Nuclear Norm Regularized Least Squares Problems](#). Pacific Journal of Optimization. 6.
- [9] ECE236C - Optimization Methods for Large-Scale Systems <http://www.seas.ucla.edu/~vandenbe/ee236c.html>
- [10] 潘少华, 文再文. [低秩稀疏矩阵优化问题的模型与算法](#)[J]. 运筹学学报, 2020(3):1-26.