

变分推断与变分自编码器

作者：凯鲁嘎吉 - 博客园 <http://www.cnblogs.com/kailugaji/>

本文主要介绍变分自编码器(Variational Auto-Encoder, VAE)及其推导过程，但变分自编码器涉及一些概率统计的基础知识，因此为了更好地理解变分自编码器，首先介绍变分推断(Variational Inference)与期望最大化(Expectation-Maximization, EM)算法，进而介绍变分自编码器，并给出另一种理解方法(参考文献[3])。

1. 变分推断

➤ 参数估计

- 根据样本所提供的信息，对总体分布中的未知参数 θ 进行估值

极大似然估计

➤ 贝叶斯估计

$$p(\theta | X) = \frac{p(X | \theta)p(\theta)}{p(X)} = \frac{p(X | \theta)p(\theta)}{\int p(X, \theta)d\theta}$$

最大后验估计

- 贝叶斯估计中分母 $p(X)$ 往往很难求，于是找一个简单的函数

$$q(\theta) \approx p(\theta | X)$$

- 如何评价 $q(\theta)$ 与 $p(\theta | X)$ 之间的近似程度呢？——Kullback-Leibler散度
- 目标函数： $\min KL(q(\theta) \| p(\theta | X))$

变分推断

- 目标函数: $\min KL(q(\theta) \| p(\theta|X))$


$$\begin{aligned} KL(q \| p) &= \int q(\theta) \ln \frac{q(\theta)}{p(\theta|X)} d\theta \\ &= \int q(\theta) \ln \frac{q(\theta)}{p(X, \theta)} d\theta + \ln p(X) \end{aligned}$$



$$\ln p(X) = KL(q \| p) + \int q(\theta) \ln \frac{p(X, \theta)}{q(\theta)} d\theta = KL(q \| p) + L(q)$$

- $\ln p(X) = KL(q \| p) + L(q)$, 而 $\ln p(X)$ 是与 θ 无关的常量, 不变。
- $\min KL(q \| p) \Leftrightarrow \max L(q)$, 变分贝叶斯学习通过 $q(\theta)$ 的迭代实现 $L(q)$ 的最大化

$$\max L(q) = \int q(\theta) \ln p(X, \theta) d\theta - \int q(\theta) \ln q(\theta) d\theta$$



► 平均场理论

- 根据平均场理论, 变分分布 $q(\theta)$ 可以因式分解为 M 个互不相交的部分

$$q(\theta) = \prod_{i=1}^M q_i(\theta_i)$$

$$\begin{aligned} \max L(q) &= \int q \ln p(X, \theta) d\theta - \int q \ln q d\theta = \int q_j \left\{ \int \ln p(X, \theta) \prod_{i \neq j} q_i d\theta_i \right\} d\theta_j - \int q_j \ln q_j d\theta_j + c \\ &= \int q_j \ln \tilde{p}(X, \theta_j) d\theta_j - \int q_j \ln q_j d\theta_j + c = -KL(q_j \parallel \tilde{p}(X, \theta_j)) + c \end{aligned}$$

$$\text{其中 } \ln \tilde{p}(X, \theta_j) = E_{i \neq j}[\ln p(X, \theta)] + c = \int \ln p(X, \theta) \prod_{i \neq j} q_i d\theta_i + c$$

$$q_j = \tilde{p}(X, \theta_j), L(q) \text{最大} \quad \therefore \ln q_j^* = \ln \tilde{p}(X, \theta_j) = E_{i \neq j}[\ln p(X, \theta)] + c$$

$$q_j^*(\theta_j) = \frac{\exp(E_{i \neq j}[\ln p(X, \theta)])}{\int \exp(E_{i \neq j}[\ln p(X, \theta)]) d\theta_j}$$

➤EM算法

$$\begin{aligned}\ln p(X; \theta) &= KL(q(Z) \parallel p(Z | X; \theta)) + \int q(Z) \ln \frac{p(X, Z; \theta)}{q(Z)} dZ \\ &= KL(q(Z) \parallel p(Z | X; \theta)) + L(q, X; \theta)\end{aligned}$$

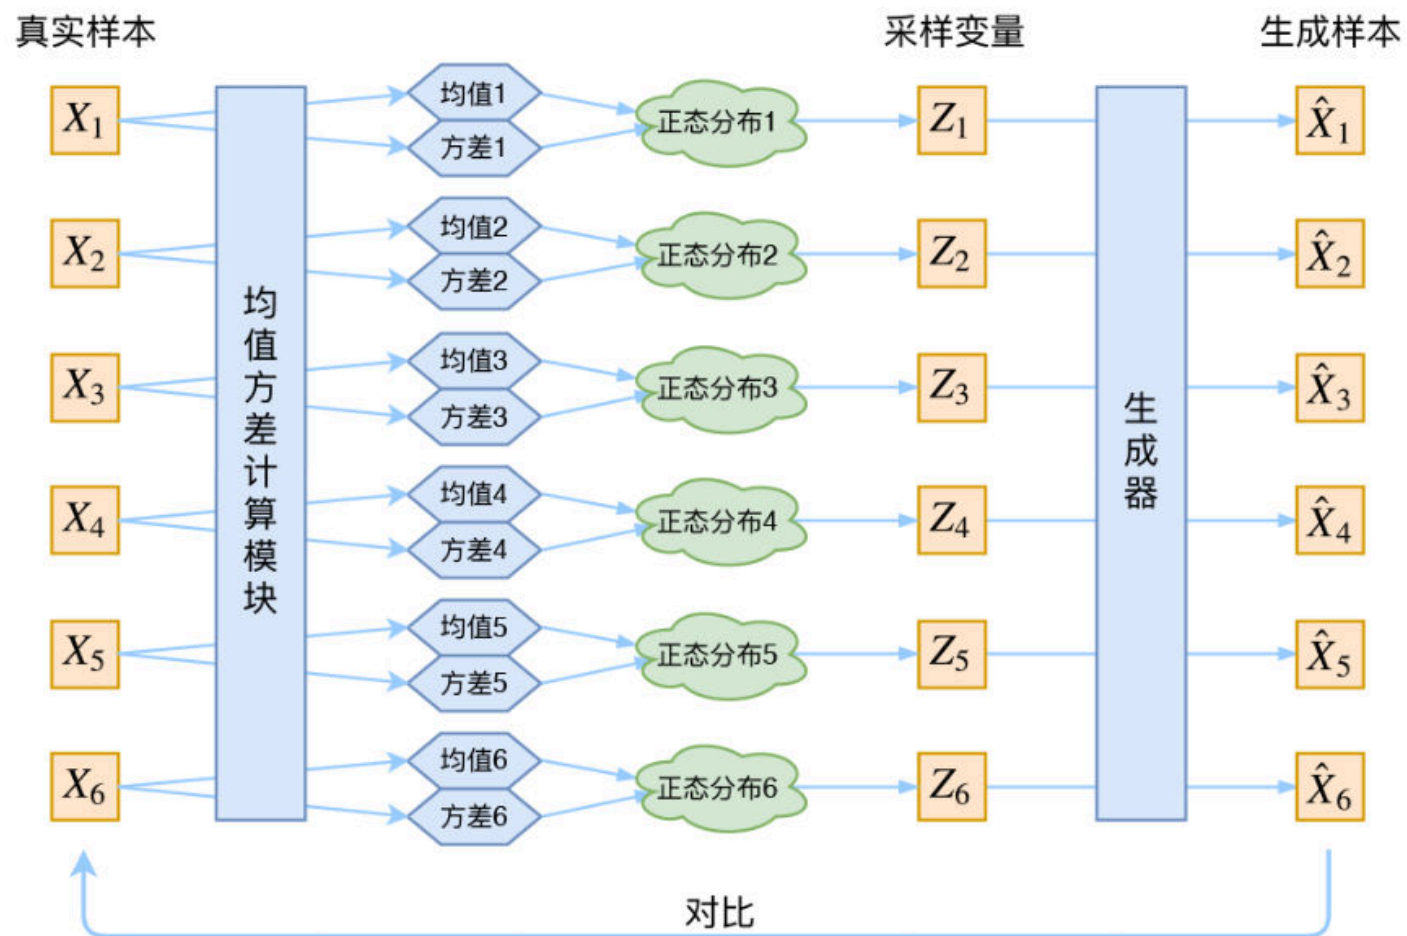
- E-step: 固定 θ , 求 $q(Z)$

$$q_{t+1}(Z) = \arg \max_q L(q, X; \theta_t)$$

- ✓ 若 $p(Z|X; \theta)$ 好求, 则 $q(Z) = p(Z|X; \theta)$
- ✓ 否则, 用变分推断近似估计 $q(Z)$

- M-step: 固定 $q(Z)$, 求 θ

$$\theta_{t+1} = \arg \max_{\theta} L(q_{t+1}, X; \theta)$$




- 深度生成模型

- 就是利用神经网络来建模条件分布 $p(x|z;\theta)$ 。
- 对抗生成式网络（Generative Adversarial Network, GAN）
- 变分自编码器（Variational Autoencoder, VAE）

- 生成模型

- 指一系列用于随机生成可观测数据的模型。生成数据 x 的过程可以分为两步进行：
- 根据隐变量的先验分布 $p(z;\theta)$ 进行采样，得到样本 z ；
- 根据条件分布 $p(x|z;\theta)$ 进行采样，得到 x 。



$$p(X) = \int p(X, Z) dZ = \int p(X | Z) p(Z) dZ$$


- 给定一个样本 \mathbf{x} , 其对数边际似然 $\log p(\mathbf{x}; \theta)$ 可以分解为

$$\log p(\mathbf{x}; \theta) = \int q(\mathbf{z}; \phi) \log \frac{p(\mathbf{x}, \mathbf{z}; \theta)}{q(\mathbf{z}; \phi)} d\mathbf{z} - \int q(\mathbf{z}; \phi) \log \frac{p(\mathbf{z} | \mathbf{x}; \theta)}{q(\mathbf{z}; \phi)} d\mathbf{z}$$

$$= L(q, \mathbf{x}; \theta, \phi) + KL(q(\mathbf{z}; \phi) \| p(\mathbf{z} | \mathbf{x}; \theta))$$

$$= E_{\mathbf{z} \sim q(\mathbf{z}; \phi)} \left[\log \frac{p(\mathbf{x}, \mathbf{z}; \theta)}{q(\mathbf{z}; \phi)} \right] + KL(q(\mathbf{z}; \phi) \| p(\mathbf{z} | \mathbf{x}; \theta))$$

$$= E_{\mathbf{z} \sim q(\mathbf{z}; \phi)} \left[\log \frac{p(\mathbf{x} | \mathbf{z}; \theta) p(\mathbf{z}; \theta)}{q(\mathbf{z}; \phi)} \right] + KL(q(\mathbf{z}; \phi) \| p(\mathbf{z} | \mathbf{x}; \theta))$$




- 变分自编码器目标函数:

$$\max_{\theta, \phi} L(q, \mathbf{x}; \theta, \phi)$$

$$= E_{\mathbf{z} \sim q(\mathbf{z}; \phi)} \left[\log \frac{p(\mathbf{x} | \mathbf{z}; \theta) p(\mathbf{z}; \theta)}{q(\mathbf{z}; \phi)} \right]$$

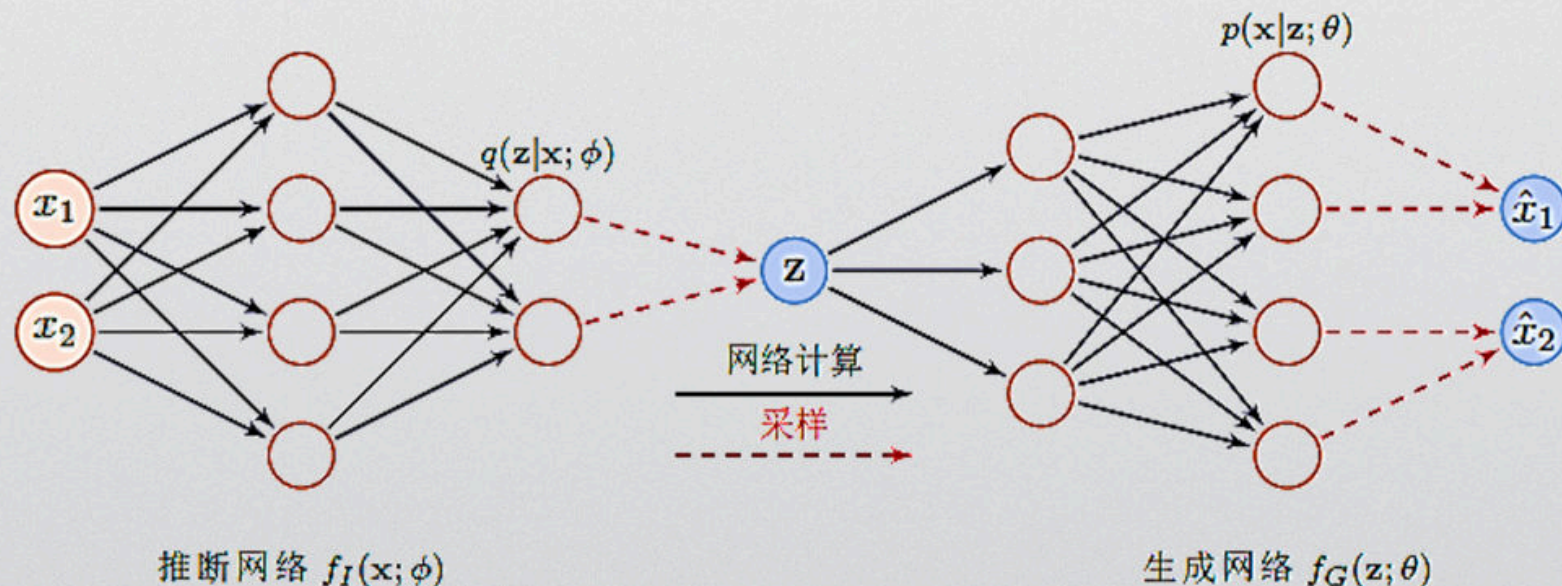
$$= E_{\mathbf{z} \sim q(\mathbf{z} | \mathbf{x}; \phi)} [\log p(\mathbf{x} | \mathbf{z}; \theta)] - KL(q(\mathbf{z} | \mathbf{x}; \phi) || p(\mathbf{z}; \theta))$$



生成

推断

变分自编码器



- 变分自编码器的模型结构可以分为两个部分：
 - ✓ 寻找后验分布 $p(z|x;\theta)$ 的变分近似 $q(z|x;\phi^*)$ (即: $q(z;\phi^*)$);
 - 变分推断: 用简单的分布 q 去近似复杂的分布 $p(z|x;\theta)$
 - ✓ 在已知 $q(z|x;\phi^*)$ 的情况下, 估计更好的生成 $p(x|z;\theta)$ 。

变分自编码器

- 变分自编码器的模型结构分为两个部分：

- ✓ 推断网络： $q(\mathbf{z}|\mathbf{x};\phi)$ 尽可能接近 $p(\mathbf{z}|\mathbf{x};\theta)$ (不用平均场理论，而是直接假设分布，用神经网络训练参数)

$$\phi^* = \arg \min_{\phi} KL(q(\mathbf{z} | \mathbf{x}; \phi) \| p(\mathbf{z} | \mathbf{x}; \theta)) = \arg \max_{\phi} L(q, \mathbf{x}; \theta, \phi)$$

$$q(\mathbf{z} | \mathbf{x}; \phi) = \mathcal{N}(\mathbf{z}; \mu_I, \sigma_I^2 \mathbf{I})$$

$$\mathbf{h} = \sigma(W^{(1)}\mathbf{x} + \mathbf{b}^{(1)}), \mu_I = W^{(2)}\mathbf{h} + \mathbf{b}^{(2)}, \sigma_I = \text{softplus}(W^{(3)}\mathbf{h} + \mathbf{b}^{(3)})$$

- ✓ 生成网络： $p(\mathbf{x}, \mathbf{z}; \theta) = p(\mathbf{x}|\mathbf{z}; \theta)p(\mathbf{z}; \theta)$

$$\theta^* = \arg \max_{\theta} L(q, \mathbf{x}; \theta, \phi)$$

$$p(\mathbf{z}; \theta) = \mathcal{N}(\mathbf{z}; \mathbf{0}, \mathbf{I})$$

- ✓ 总体目标函数：

$$\begin{aligned} \max_{\theta, \phi} L(q, \mathbf{x}; \theta, \phi) &= \max_{\theta, \phi} E_{\mathbf{z} \sim q(\mathbf{z}; \phi)} \left[\log \frac{p(\mathbf{x} | \mathbf{z}; \theta) p(\mathbf{z}; \theta)}{q(\mathbf{z}; \phi)} \right] \\ &= \max_{\theta, \phi} E_{\mathbf{z} \sim q(\mathbf{z}|\mathbf{x}; \phi)} [\log p(\mathbf{x} | \mathbf{z}; \theta)] - KL(q(\mathbf{z} | \mathbf{x}; \phi) \| p(\mathbf{z}; \theta)) \end{aligned}$$

- 总体目标函数:

$$\begin{aligned}\max_{\theta, \phi} L(q, \mathbf{x}; \theta, \phi) &= E_{\mathbf{z} \sim q(\mathbf{z} | \mathbf{x}; \phi)} [\log p(\mathbf{x} | \mathbf{z}; \theta)] - KL(q(\mathbf{z} | \mathbf{x}; \phi) \| p(\mathbf{z}; \theta)) \\ &\stackrel{(1)}{\approx} \frac{1}{K} \sum_{k=1}^K \log p(\mathbf{x} | \mathbf{z}^{(k)}; \theta) - KL(q(\mathbf{z} | \mathbf{x}; \phi) \| p(\mathbf{z}; \theta)) \\ &\stackrel{(2)}{=} \sum_{n=1}^N \left(\frac{1}{K} \sum_{k=1}^K \log p(\mathbf{x}^{(n)} | \mathbf{z}^{(n,k)}; \theta) - KL(q(\mathbf{z} | \mathbf{x}^{(n)}; \phi) \| N(\mathbf{z}; \mathbf{0}, \mathbf{I})) \right)\end{aligned}$$

(1): 对于样本 \mathbf{x} , 根据 $q(\mathbf{z} | \mathbf{x}; \phi)$ 采集 K 个 \mathbf{z} , $1 \leq k \leq K$

(2): $p(\mathbf{z}; \theta) = \mathcal{N}(\mathbf{z}; \mathbf{0}, \mathbf{I})$

- 总体目标函数:

$$\max_{\theta, \phi} L(q, \mathbf{x}; \theta, \phi) = \max_{\theta, \phi} E_{\mathbf{z} \sim q(\mathbf{z} | \mathbf{x}; \phi)} [\log p(\mathbf{x} | \mathbf{z}; \theta)] - KL(q(\mathbf{z} | \mathbf{x}; \phi) \| p(\mathbf{z}; \theta))$$

若 $p(\mathbf{x} | \mathbf{z}; \phi) = \mathcal{N}(\mathbf{z}; \mu_G, \mathbf{I})$, $q(\mathbf{z} | \mathbf{x}; \phi) = \mathcal{N}(\mathbf{z}; \mu_I, \sigma_I^2 \mathbf{I})$, 目标函数简化为:

$$\max_{\theta, \phi} -\|\mathbf{x} - \mu_G\|^2 - KL(N(\mu_I, \sigma_I) \| N(\mathbf{0}, \mathbf{I}))$$


若 $p(\mathbf{x} | \mathbf{z}; \phi) = \mu_G^x (1 - \mu_G)^{1-x}$, $q(\mathbf{z} | \mathbf{x}; \phi) = \mathcal{N}(\mathbf{z}; \mu_I, \sigma_I^2 \mathbf{I})$, 目标函数简化为:

$$\max_{\theta, \phi} x \log(\mu_G) + (1 - x) \log(1 - \mu_G) - KL(N(\mu_I, \sigma_I) \| N(\mathbf{0}, \mathbf{I}))$$


变分自编码器

- 分布 $q(z|x, \phi)$ 依赖于参数 ϕ ，采样无法刻画 z 与 ϕ 函数关系，无法求导
- 重参数化（reparameterization）是实现通过随机变量实现反向传播的一种重要手段。将采样关系 \rightarrow 函数关系。

从 $\mathcal{N}(\mu, \sigma^2)$ 中采样一个 Z ，相当于从 $\mathcal{N}(0, 1)$ 中采样一个 ϵ ，然后让 $Z = \mu + \epsilon \times \sigma$ 。





$$z \sim N(\mu, \sigma^2)$$
$$\epsilon = \frac{z - \mu}{\sigma} \sim N(0, 1)$$



代码里 z 是这样的来的: $z \sim \mu + \text{var_epsilon} \{e^{0.5 \ln(\sigma^2)}\} = \mu + \text{var_epsilon} \sigma$

采样





3. 变分自编码器另一种理解——直面联合分布

概率论基础知识

$$E(x) = \int xp(x)dx = c, x \sim p(x)$$

$$E(f(x, \xi)) = \int f(x, \xi)p(x)dx = g(\xi), x \sim p(x)$$

$$E(f(x)) = \int f(x) \cdot p(x)dx = c, x \sim p(x)$$

$$\int p(z | x)dz = 1$$

变分自编码器另一种理解

- 变分自编码器另一种理解——直面联合分布

$$p(X) = \int p(X, Z) dZ = \int p(X | Z) p(Z) dZ$$

$$q(X) = \int q(X, Z) dZ = \int q(X | Z) q(Z) dZ$$

✓ 用 $q(X) \approx p(X) \Leftrightarrow q(X, Z) \approx p(X, Z)$

$$\begin{aligned} KL(q(x, z) \| p(x, z)) &= \iint q(x, z) \log \frac{q(x, z)}{p(x, z)} dz dx \\ &= \int q(x) \left[\int q(z | x) \log \frac{q(x) q(z | x)}{p(x, z)} dz \right] dx = E_{x \sim q(x)} \left[\int q(z | x) \log \frac{q(x) q(z | x)}{p(x, z)} dz \right] \\ &= E_{x \sim q(x)} \left\{ \int \left[q(z | x) \log q(x) + q(z | x) \log \frac{q(z | x)}{p(x, z)} \right] dz \right\} \end{aligned}$$

变分自编码器另一种理解

$$\begin{aligned} KL(q(x, z) \parallel p(x, z)) &= E_{x \sim q(x)} \left[\int q(z | x) \log \frac{q(z | x)}{p(x, z)} dz \right] + c \\ &= E_{x \sim q(x)} \left[\int q(z | x) \log \frac{q(z | x)}{p(x | z)p(z)} dz \right] + c \\ &= E_{x \sim q(x)} \left[- \int q(z | x) \log p(x | z) dz + \int q(z | x) \log \frac{q(z | x)}{p(z)} dz \right] + c \\ &= E_{x \sim q(x)} \left[E_{z \sim q(z|x)} [-\log p(x | z)] + E_{z \sim q(z|x)} \left[\log \frac{q(z | x)}{p(z)} \right] \right] + c \\ &= E_{x \sim q(x)} \left[E_{z \sim q(z|x)} [-\log p(x | z)] + KL(q(z | x) \parallel p(z)) \right] + c \end{aligned}$$

VAE的损失函数

$KL(q(x, z) \parallel p(x, z))$ 等价于VAE的损失函数

4. KL散度公式推导

\mathcal{KL} 散度公式推导

$$\text{令 } f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$$KL(N(\mu, \sigma) \parallel N(0, I))$$

$$\begin{aligned} &= \int f(x; \mu, \sigma^2) \log \left(\frac{e^{-\frac{(x-\mu)^2}{2\sigma^2}}}{\sqrt{2\pi\sigma^2}} \cdot \frac{\sqrt{2\pi}}{e^{-\frac{x^2}{2}}} \right) dx = \int f(x; \mu, \sigma^2) \log \left(\frac{1}{\sqrt{\sigma^2}} e^{\frac{x^2 - (x-\mu)^2}{2}} \right) dx \\ &= \frac{1}{2} \int f(x; \mu, \sigma^2) \left(-\log \sigma^2 + x^2 - \frac{(x-\mu)^2}{\sigma^2} \right) dx \stackrel{(1)}{=} \frac{1}{2} (-\log \sigma^2 + \mu^2 + \sigma^2 - 1) \end{aligned}$$

(1) 用到了正态分布的二阶矩公式，详见下一页

KL散度公式推导

$$\text{令 } f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$$\text{若 } X \sim N(\mu, \sigma^2)$$

$$\because E(X) = \mu, D(X) = E(X^2) - (E(X))^2 = \sigma^2$$

$$\therefore E(X^2) = \int x^2 \cdot f(x; \mu, \sigma^2) dx = (E(X))^2 + D(X) = \mu^2 + \sigma^2$$

$$\because E(X - \mu)^n = \int (x - \mu)^n \cdot f(x; \mu, \sigma^2) dx$$

$$= \begin{cases} 0, & n \text{ is odd,} \\ \sigma^n (n-1)!!, & n \text{ is even.} \end{cases}$$

$$\therefore E(X - \mu)^2 = \int (x - \mu)^2 \cdot f(x; \mu, \sigma^2) dx = \sigma^2$$

5. 参考文献

[1] [变分贝叶斯](#) - 凯鲁嘎吉 - 博客园

[2] 邱锡鹏, [神经网络与深度学习](#)[M]. 2019.

[3] [标签 vae 下的文章](#) - 科学空间|Scientific Spaces

[4] Kingma D P , Welling M . [Auto-Encoding Variational Bayes](#)[J]. 2013.

[5] 变分推断详细请参考: [华俊豪博客-变分推理](#)、[变分贝叶斯算法理解与推导](#)

[6] Tutorial - What is a variational autoencoder? - Jaan Altosaar <https://jaan.io/what-is-variational-autoencoder-vae-tutorial/>

[7] CS 285, Variational Inference and Generative Models, <http://rail.eecs.berkeley.edu/deeprlcourse-fa20/static/slides/lec-18.pdf>

[8] Ankush Ganguly, Samuel W. F. Earp, An Introduction to Variational Inference, 2021. <https://arxiv.org/pdf/2108.13083.pdf>