

多元/多维高斯/正态分布概率密度函数推导 (Derivation of the Multivariate/Multidimensional Normal/Gaussian Density)

作者：凯鲁嘎吉 - 博客园 <http://www.cnblogs.com/kailugaji/>

当年在学《概率论与数理统计》时，遇到二元正态分布的概率密度函数，那个公式特别长，当时只是要求记住，并未深究其原因，今天终于有机会好好回顾一下了。二元/二维只是多元的一个特例，现在将问题延伸到多元/多维高斯/正态分布概率密度函数的推导上。多元高斯分布在很多场景下都有用，比如高斯混合模型(Gaussian Mixture Model)中，每个组件都是单个多元高斯分布，样本不仅是一维的，现实中大多是数据样本都是多维的。只有真正弄清楚公式的来龙去脉，来能更好的编写程序，进行实现(虽然很多包都是现成的，不需要自己从头编写)。想要推导概率密度函数公式，需要知道线性代数中矩阵论的一些基础知识，从单变量到二元/二维再延伸到多元/多维，本身就涉及到从标量到向量再到矩阵的一个过程。这篇博客详细推导了多元/多维高斯/正态分布概率密度函数公式，并应用到二维高斯分布中，进行进一步分析。也给出了当维度之间独立同分布(Independent identically distributed, i.i.d.)情况下多维高斯分布的概率密度函数的特例。值得注意的是，整个过程仅是对一个样本进行计算，该样本无论是一个标量，还是一个多维向量，最终出来的概率密度函数都是一个数(标量)。如果有N个样本(按列排开)的话，其概率密度函数就是N维列向量。注意：多元就是多维，高斯分布就是正态分布。(只是大概推导，过程可能并不严谨，望海涵)

1. 前提基础

包括连续随机变量变换法(Transformations of Continuous Random Variables)，单变量正态分布的概率密度函数(Univariate Normal Density)，以及随机变量间的独立性(Independence of Random Variables)。

➤ 前提基础

• 连续随机变量变换法

(Transformations of Continuous Random Variables)

这里以二维随机变量为例，该方法可推广到多维连续随机变量上。设二维随机变量 (X, Y) 的联合密度函数为 $p(x, y)$ ，

若函数

$$\begin{cases} u = g_1(x, y), \\ v = g_2(x, y) \end{cases}$$

有连续偏导数，且存在唯一的反函数

$$\begin{cases} x = x(u, v), \\ y = y(u, v) \end{cases}$$

其变换的雅可比(Jacobian)行列式为

$$J = \frac{\partial(x, y)}{\partial(u, v)} = \det \begin{pmatrix} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \end{pmatrix} = \left(\frac{\partial(u, v)}{\partial(x, y)} \right)^{-1} = \det \begin{pmatrix} \frac{\partial u}{\partial x} & \frac{\partial u}{\partial y} \\ \frac{\partial v}{\partial x} & \frac{\partial v}{\partial y} \end{pmatrix}^{-1} \neq 0$$


$$\text{若 } \begin{cases} U = g_1(X, Y), \\ V = g_2(X, Y) \end{cases}$$

则 (U, V) 的联合密度函数为

$$p(u, v) = p(x(u, v), y(u, v)) |J|$$

- 定理：若 X 在 S 上有一个连续分布，其概率密度函数为 f ，则 $Y=r(X)$ 在 T 上有一个连续分布，其概率密度函数 g 为


$$g(y) = f(x) \left| \det \left(\frac{dx}{dy} \right) \right|, y \in T.$$



- 简要论述：该定理仅仅是连续随机变量变换法的一维形式。已知 $y=r(x)$ 有连续偏导数，且存在唯一的反函数 $x=r^{-1}(y)$ ，其变换的雅可比行列式为

$$J = \det \left(\frac{dx}{dy} \right) = \left(\det \left(\frac{dy}{dx} \right) \right)^{-1}$$

则 Y 的概率密度函数为 $g(y)=f(x)|J|$ ，定理得证。



茆诗松, 程依明, 濮晓龙. 概率论与数理统计教程. 高等教育出版社, 2011.

The Multivariate Normal Distribution <http://www.randomservices.org/random/special/MultiNormal.html>


➤ 前提基础

- 单变量正态分布的密度函数(Univariate Normal Density)
- 随机变量间的独立性(Independence of Random Variables)

若随机变量 X 的密度函数为

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, -\infty < x < +\infty$$

则称 X 服从正态分布, 称 X 为正态变量, 记作 $X \sim \mathcal{N}(\mu, \sigma^2)$ 。



特别地, $X \sim \mathcal{N}(0, 1)$, 则

$$p(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, -\infty < x < +\infty$$

茆诗松, 程依明, 濮晓龙. 概率论与数理统计教程. 高等教育出版社, 2011.

在连续随机变量场合, 如果对任意 D 个实数 x_1, x_2, \dots, x_D , 都有

$$p(x_1, x_2, \dots, x_D) = \prod_{d=1}^D p_d(x_d)$$

则称 X_1, X_2, \dots, X_D 相互独立。

若 $Z = (Z_1, Z_2, \dots, Z_D)^T \sim \mathcal{N}(0, I)$, D 个维度的变量之间相互独立, 则 Z 的概率密度函数 g 为

$$\begin{aligned} g(z_1, z_2, \dots, z_D) &= \prod_{d=1}^D \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2} z_d^2\right) \\ &= \left(\frac{1}{\sqrt{2\pi}}\right)^D \prod_{d=1}^D \exp\left(-\frac{1}{2} z_d^2\right) = \left(\frac{1}{\sqrt{2\pi}}\right)^D \exp\left(-\frac{1}{2} \sum_{d=1}^D z_d^2\right) \\ &= \frac{1}{(2\pi)^{D/2}} \exp\left(-\frac{1}{2} z^T z\right) \end{aligned}$$

其中 $z = (z_1, z_2, \dots, z_D)^T$ $(z_1, z_2, \dots, z_D) \begin{pmatrix} z_1 \\ z_2 \\ \vdots \\ z_D \end{pmatrix} = \sum_{d=1}^D z_d^2$

技巧: $e^a e^b e^c = e^{a+b+c}$

2. 多维高斯分布的概率密度函数定义及其推导

➤ 多维高斯分布的概率密度函数定义

设 D 维随机变量 $X = (X_1, X_2, \dots, X_D)^T$ 的协方差矩阵为 $\Sigma = \text{Cov}(X)$, 数学期望向量为 $\mu = (\mu_1, \mu_2, \dots, \mu_D)^T$.

又记 $x = (x_1, x_2, \dots, x_D)^T$, 则由密度函数

$$p(x) = p(x_1, x_2, \dots, x_D) = \frac{1}{(2\pi)^{D/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1} (x - \mu)\right)$$

定义的分布称为 D 元正态分布 记为 $X \sim \mathcal{N}(\mu, \Sigma)$ 其中 $|\Sigma|$ 表示 Σ 的行列式, Σ^{-1} 表示 Σ 的逆矩阵,

$(x - \mu)^T$ 表示向量 $(x - \mu)$ 的转置. 注: Σ 为对称正定矩阵.

若记 $\Sigma^{-1} = (\sigma_{ij}^{-1})$ 存在, 则上式可写为

$$p(x) = p(x_1, x_2, \dots, x_D) = \frac{1}{(2\pi)^{D/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2} \sum_{i=1}^D \sum_{j=1}^D \sigma_{ij}^{-1} (x_i - \mu_i)(x_j - \mu_j)\right)$$

➤ 多维高斯分布的概率密度函数推导

假设 $X \sim \mathcal{N}(\mu, \Sigma)$, 令 $X = \mu + AZ$, 其中 $AA^T = \Sigma$, A 是非奇异矩阵 (由于 Σ 为正定阵)

$\det(\Sigma) = (\det(A))^2$. $Z = (Z_1, Z_2, \dots, Z_D)^T$ 的概率密度函数为:

$$X \sim \mathcal{N}(\mu, \Sigma) \Rightarrow \frac{X - \mu}{\sqrt{\Sigma}} \sim \mathcal{N}(0, I)$$

$$g(z_1, z_2, \dots, z_D) = \frac{1}{(2\pi)^{D/2}} \exp\left(-\frac{1}{2} z^T z\right), z = (z_1, z_2, \dots, z_D)^T$$

由 $X = \mu + AZ \Rightarrow Z = A^{-1}(X - \mu) \Rightarrow$ 雅可比矩阵 $J = \det\left(\frac{dZ}{dX}\right) = \det(A^{-1}) = \det(A)^{-1}$ 随机变量
变换法

$$\begin{aligned} f(x) &= g(z) \left| \det\left(\frac{dz}{dx}\right) \right| = |(\det(A))^{-1}| g(A^{-1}(x - \mu)) = |(\det(A))|^{-1} \frac{1}{(2\pi)^{D/2}} \exp\left(-\frac{1}{2} (A^{-1}(x - \mu))^T (A^{-1}(x - \mu))\right) \\ &= \frac{1}{(2\pi)^{D/2}} (\det(\Sigma))^{-1/2} \exp\left(-\frac{1}{2} (x - \mu)^T (A^T)^{-1} A^{-1} (x - \mu)\right) = \frac{1}{(2\pi)^{D/2}} (\det(\Sigma))^{-1/2} \exp\left(-\frac{1}{2} (x - \mu)^T (AA^T)^{-1} (x - \mu)\right) \\ &= \frac{1}{(2\pi)^{D/2}} (\det(\Sigma))^{-1/2} \exp\left(-\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu)\right) \end{aligned}$$

原式得证。 技巧: $|A^{-1}| = |A|^{-1}, (AB)^{-1} = B^{-1}A^{-1}, (A^T)^{-1} = (A^{-1})^T$

3. 多维高斯分布的概率密度函数(维度之间独立同分布)

➤ 多维高斯分布的概率密度函数(维度之间独立同分布)

设 D 维*i.i.d*随机变量 $X = (X_1, X_2, \dots, X_D)^T$ 的协方差矩阵为对角阵 $\Lambda = (\sigma_d^2)$ 仅对角线上有元素, 其余全是 0.

数学期望向量为 $\mu = (\mu_1, \mu_2, \dots, \mu_D)^T$ 又记 $x = (x_1, x_2, \dots, x_D)^T$ 则密度函数为

$$\begin{aligned}
 p(x) &= p(x_1, x_2, \dots, x_D) = \prod_{d=1}^D p(x_d) = \prod_{d=1}^D \frac{1}{\sqrt{2\pi}\sigma_d} \exp\left(-\frac{(x_d - \mu_d)^2}{2\sigma_d^2}\right) \\
 &= \left(\frac{1}{\sqrt{2\pi}}\right)^D \prod_{d=1}^D \frac{1}{\sigma_d} \exp\left(-\frac{1}{2} \sum_{d=1}^D \frac{(x_d - \mu_d)^2}{\sigma_d^2}\right) = \frac{1}{(2\pi)^{D/2} |\Lambda|^{1/2}} \exp\left(-\frac{1}{2} (x - \mu)^T \Lambda^{-1} (x - \mu)\right)
 \end{aligned}$$

$$(x - \mu)^T \Lambda^{-1} (x - \mu) = ((x_1 - \mu_1), (x_2 - \mu_2), \dots, (x_D - \mu_D)) \begin{pmatrix} \sigma_1^{-2} & 0 & 0 & 0 \\ 0 & \sigma_2^{-2} & 0 & 0 \\ 0 & 0 & \ddots & 0 \\ 0 & 0 & 0 & \sigma_D^{-2} \end{pmatrix} \begin{pmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \\ \vdots \\ x_D - \mu_D \end{pmatrix}$$

$$\Lambda = \begin{pmatrix} \sigma_1^2 & 0 & 0 & 0 \\ 0 & \sigma_2^2 & 0 & 0 \\ 0 & 0 & \ddots & 0 \\ 0 & 0 & 0 & \sigma_D^2 \end{pmatrix}, |\Lambda| = \prod_{d=1}^D \sigma_d^2$$

4. 二维高斯分布的概率密度函数定义及其推导

➤ 二维高斯分布的概率密度函数

由多维高斯分布的概率密度函数定义，二维高斯分布的概率密度函数推导如下

$$\text{令 } \rho = \frac{\sigma_{12}}{\sigma_1 \sigma_2}$$

$$p(x) = p(x_1, x_2) = \frac{1}{2\pi |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right)$$

$$\Sigma = \begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{pmatrix} \Rightarrow |\Sigma| = \sigma_1^2 \sigma_2^2 - \sigma_{12}^2 = \sigma_1^2 \sigma_2^2 \left(1 - \frac{\sigma_{12}^2}{\sigma_1^2 \sigma_2^2}\right) = \sigma_1^2 \sigma_2^2 (1 - \rho^2), \Sigma^{-1} = \frac{1}{|\Sigma|} \begin{pmatrix} \sigma_2^2 & -\sigma_{12} \\ -\sigma_{12} & \sigma_1^2 \end{pmatrix}$$

利用伴随矩阵求逆矩阵

$$\begin{aligned} (x - \mu)^T \Sigma^{-1} (x - \mu) &= ((x_1 - \mu_1), (x_2 - \mu_2)) \frac{1}{|\Sigma|} \begin{pmatrix} \sigma_2^2 & -\sigma_{12} \\ -\sigma_{12} & \sigma_1^2 \end{pmatrix} \begin{pmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{pmatrix} \\ &= \frac{1}{|\Sigma|} \left((x_1 - \mu_1) \sigma_2^2 - (x_2 - \mu_2) \sigma_{12}, -(x_1 - \mu_1) \sigma_{12} + (x_2 - \mu_2) \sigma_1^2 \right) \begin{pmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{pmatrix} \\ &= \frac{1}{|\Sigma|} \left((x_1 - \mu_1)^2 \sigma_2^2 - (x_1 - \mu_1)(x_2 - \mu_2) \sigma_{12} - (x_1 - \mu_1)(x_2 - \mu_2) \sigma_{12} + (x_2 - \mu_2)^2 \sigma_1^2 \right) \\ &= \frac{(x_1 - \mu_1)^2 \sigma_2^2 - 2(x_1 - \mu_1)(x_2 - \mu_2) \sigma_{12} + (x_2 - \mu_2)^2 \sigma_1^2}{\sigma_1^2 \sigma_2^2 (1 - \rho^2)} \end{aligned}$$

➤ 二维高斯分布的概率密度函数

因此，二维高斯分布的概率密度函数为

$$\text{其中 } \rho = \frac{\sigma_{12}}{\sigma_1 \sigma_2}$$

$$p(x) = p(x_1, x_2) = \frac{1}{2\pi(\sigma_1^2 \sigma_2^2 (1 - \rho^2))^{1/2}} \exp \left(-\frac{(x_1 - \mu_1)^2 \sigma_2^2 - 2(x_1 - \mu_1)(x_2 - \mu_2)\sigma_{12} + (x_2 - \mu_2)^2 \sigma_1^2}{2\sigma_1^2 \sigma_2^2 (1 - \rho^2)} \right)$$


$$= \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left(-\frac{1}{2} \frac{\left(\frac{x_1 - \mu_1}{\sigma_1}\right)^2 - 2\rho \left(\frac{x_1 - \mu_1}{\sigma_1}\right) \left(\frac{x_2 - \mu_2}{\sigma_2}\right) + \left(\frac{x_2 - \mu_2}{\sigma_2}\right)^2}{1 - \rho^2} \right)$$

上下同除以 $\sigma_1^2 \sigma_2^2$

$$\text{其中 } \left(\frac{x_1 - \mu_1}{\sigma_1}\right)^2 - 2\rho \left(\frac{x_1 - \mu_1}{\sigma_1}\right) \left(\frac{x_2 - \mu_2}{\sigma_2}\right) + \left(\frac{x_2 - \mu_2}{\sigma_2}\right)^2 = ((x_1 - \mu_1), (x_2 - \mu_2)) \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix} \begin{pmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{pmatrix}$$

$$\therefore \Sigma = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}, \sigma_{12} = \text{cov}(X_1, X_2) = \rho\sigma_1\sigma_2$$

$$\text{corr}(X_1, X_2) = \frac{\text{cov}(X_1, X_2)}{\sigma_1\sigma_2} = \rho (\rho \text{ 就是相关系数})$$



茆诗松, 程依明, 濮晓龙. 概率论与数理统计教程. 高等教育出版社, 2011.

5. 参考文献

[1] 茆诗松, 程依明, 濮晓龙. 概率论与数理统计教程. 高等教育出版社, 2011.

[2] The Multivariate Normal Distribution <http://www.randomservices.org/random/special/MultiNormal.html>

[3] Basic Multivariate Normal Theory <http://www2.stat.duke.edu/~st118/sta732/mvnormal.pdf>

[4] 凯鲁嘎吉 - 博客园 - 左边栏搜索"高斯"相关博文 <https://zzk.cnblogs.com/my/s/blogpost-p?Keywords=%E9%AB%98%E6%96%AF>