

字典更新与K-SVD

凯鲁嘎吉 - 博客园 <http://www.cnblogs.com/kailugaji/>

1. 矩阵的奇异值分解 (Singular Value Decomposition, SVD)

对于每一个秩为 r 的矩阵 $A \in \mathbb{C}^{m \times n}$ ，存在正交矩阵 $U_{m \times m}$, $V_{n \times n}$ 与一个对角阵 $\Sigma_{r \times r} = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$ ，如下

$$A = U \left[\begin{array}{c|c} \Sigma_r & O \\ \hline O & \underbrace{O}_{n-r} \end{array} \right] V^{-1} = U \left[\begin{array}{c|c} \Sigma_r & O \\ \hline O & O \end{array} \right] V^H$$

这种分解方式称为矩阵 A 的奇异值分解 (SVD)。

$$\begin{array}{ccccc} U & & \Sigma & & V^T & & A \\ \left[\begin{array}{cc} -.40 & .916 \\ .916 & .40 \end{array} \right] & \times & \left[\begin{array}{cc} 5.39 & 0 \\ 0 & 3.154 \end{array} \right] & \times & \left[\begin{array}{cc} -.05 & .999 \\ .999 & .05 \end{array} \right] & = & \left[\begin{array}{cc} 3 & -2 \\ 1 & 5 \end{array} \right] \end{array}$$

$$\begin{array}{ccccc} U & & \Sigma & & V^T & & A \\ \left[\begin{array}{cc} -.39 & -.92 \\ -.92 & .39 \end{array} \right] & \times & \left[\begin{array}{ccc} 9.51 & 0 & 0 \\ 0 & .77 & 0 \end{array} \right] & \times & \left[\begin{array}{ccc} -.42 & -.57 & -.70 \\ .81 & .11 & -.58 \\ .41 & -.82 & .41 \end{array} \right] & = & \left[\begin{array}{ccc} 1 & 2 & 3 \\ 4 & 5 & 6 \end{array} \right] \end{array}$$

令 $A \in \mathbb{C}^{n \times n}$, 如果 $A^H A = A A^H$ (可交换), 则 A 被称为正规矩阵(normal matrix), 其中 A^H 是矩阵 A 的共轭转置(conjugate transpose).

若 $A^H A = A A^H = E$, 则 A 被称为酉矩阵(unitary matrix), 即它的共轭转置也是它的逆矩阵。

若 $A^H = A$, 则 A 被称为 H 矩阵(Hermitian matrix).

例: 求矩阵 A 的共轭转置 A^H

$$A = \begin{bmatrix} 1+i & -i & 0 \\ 2 & 3-2i & i \end{bmatrix}$$

解: 我们有复共轭

$$\overline{A} = \begin{bmatrix} 1-i & i & 0 \\ 2 & 3+2i & -i \end{bmatrix}$$

(实部与原实部相等, 虚部大小相等, 符号相反。)

因此共轭转置是

$$A^H = \overline{A}^T = \begin{bmatrix} 1-i & 2 \\ i & 3+2i \\ 0 & -i \end{bmatrix}$$

$$\sigma_i = \sqrt{\lambda_i}, \quad i = 1, 2, \dots, r.$$

A 可以分解为:

$$A = U \begin{bmatrix} \Sigma_r & O \\ O & O \end{bmatrix} V^{-1} = U \begin{bmatrix} \Sigma_r & O \\ O & O \end{bmatrix} V^H$$

$$A_{m \times n} = U_{m \times m} \Sigma_{m \times n} V^T_{n \times n}$$

$$A_{m \times n} = U_{m \times r} \Sigma_{r \times r} V^T_{r \times n}$$

奇异值分解有广泛的用途, 例如对于低秩矩阵近似(low-rank matrix approximation)问题, 给定一个秩为 r 的矩阵 \mathbf{A} , 欲求其最优 k 秩近似矩阵 $\tilde{\mathbf{A}}$, $k \leq r$, 该问题可形式化为

$$\begin{aligned} \min_{\tilde{\mathbf{A}} \in \mathbb{R}^{m \times n}} \quad & \|\mathbf{A} - \tilde{\mathbf{A}}\|_F \\ \text{s.t.} \quad & \text{rank}(\tilde{\mathbf{A}}) = k. \end{aligned} \tag{A.34}$$

奇异值分解提供了上述问题的解析解: 对矩阵 \mathbf{A} 进行奇异值分解后, 将矩阵 Σ 中的 $r - k$ 个最小的奇异值置零获得矩阵 Σ_k , 即仅保留最大的 k 个奇异值, 则

$$\mathbf{A}_k = \mathbf{U}_k \Sigma_k \mathbf{V}_k^T \tag{A.35}$$

就是式(A.34)的最优解, 其中 \mathbf{U}_k 和 \mathbf{V}_k 分别是式(A.33)中的前 k 列组成的矩阵. 这个结果称为 Eckart-Young-Mirsky 定理.

2. 字典更新方法

设矩阵 Y 为样本集，由 N 个样本组成，每个样本由 n 个特征表示，即 Y 的大小为 $(n * N)$ 。所谓稀疏表示，就是找到一组向量基，将此组向量基进行线性组合类表示矩阵(样本集)。即 $Y=DX$ ，其中 D 为字典，大小为 $(n*K)$ ， X 为系数矩阵，大小为 $(K*N)$ ， K 为字典的个数。

$$Y = DX$$

固定字典
Pre-constructed dictionary

DCT字典，Haar字典，小波字典，Gabor字典等。

优点：计算量低，使用简单。

缺点：不能保证表达的稀疏程度。
只适用于部分类型的图像。

学习字典
Learned dictionary

从学习的角度建立字典。

优点：适用于任何类型的图像。

缺点：计算复杂度高。局限于低维度信号(小patch)。

超完备字典 Overcomplete Dictionary

字典的原子数量大于特征维度。

主要目标

寻找最佳的字典 D ，同时使 X 系数矩阵达到稀疏最大。系数矩阵中，0 元素越多，越稀疏，即目标是用更少的原子线性组合来逼近原始矩阵。我这里系数矩阵指的是待优化的稀疏矩阵。

假设随机初始化 D ，已知 Y ，用 OMP(正交匹配追踪算法)等方法求出稀疏系数 X ，以下方法用于求解未知变量 D 。

OMP 算法具体步骤：

输 入：字典 $D = \{d_r\}_{r \in [1, L]}$ ，信号 x ，稀疏度 K ；

初始化：残差 $r_0 = x$ ，支撑索引集 $\Lambda_0 = \emptyset, k = 1$ ；

过 程：在第 k 次迭代循环，运行步骤 1-4：

步骤 1：通过运算得出支撑索引： $\lambda_k = \arg \max_{i=1, \dots, N} |\langle r_{k-1}, d_i \rangle|$ ；

步骤 2：引入信号支撑集 $\Lambda_k = \Lambda_{k-1} \cup \{\lambda_k\}$ ；

步骤 3：更新残差 $r_k = g - D_{\Lambda_k} (D_{\Lambda_k}^T D_{\Lambda_k})^{-1} D_{\Lambda_k}^T g$ ；

步骤 4： $k = k + 1$ ，判断是否满足迭代终止条件 $k = L$ ，若满足，则停止迭代；若不满足，则返回步骤 1。

输 出：支撑索引集 $\Lambda_k = \Lambda_{k-1}$ ，稀疏系数 $b = D_{\Lambda_k} (D_{\Lambda_k}^T D_{\Lambda_k})^{-1} D_{\Lambda_k}^T g$ 。

2.1 最优方向法 (Method of Optimal Directions, MOD)

$$\begin{aligned} \min \quad & \|Y - DX\|_F^2 \\ \text{s.t.} \quad & \sum_i \|x_i\|_0 \leq T_0 \end{aligned} \quad (1)$$

MOD 是早期的基于样本学习的字典学习算法. 设目标函数中 X 已知, 信号的误差定义如下:

$$\|E\|_F^2 = \|Y - DX\|_F^2 \quad (2)$$

MOD 算法更新字典的策略就是实现表征误差最小化, 所以公式两端对未知变量 D 求偏导, 会推导出 $(Y - DX)X^T = 0$

整个字典的更新过程如下:

$$D^{(n+1)} = Y(X^{(n)})^T \cdot (X^{(n)}(X^{(n)})^T)^{-1} \quad (3)$$


一般 MOD 算法需要几十次迭代才能收敛, 运算中需要对矩阵求逆, 造成计算量过大。

2.2 标准正交基联合(Unions of Orthonormal Bases, UOB)

考虑一个由正交基组成的字典 D ，对 D 进行按列划分， $D=[D_1,D_2,...,D_K]$ ，稀

疏系数 X 进行按行划分， $X=\begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_K \end{bmatrix}$

目标就是 $Y=DX$ ，即



UOB 算法的思想是按顺序一列一列地更新标准正交基 D_i 。

$$\begin{aligned} \min \quad & \|Y - DX\|_F^2 = \|(Y - \sum_{i \neq k} D_i X_i) - D_k X_k\|_F^2 = \|E_k - D_k X_k\|_F^2 \\ \text{s.t.} \quad & D^T D = I. \end{aligned} \quad (4)$$

该问题的增广拉格朗日函数为：

$$L(D, \mu) = \|Y - DX\|_F^2 + \text{Tr}[\mu(D^T D - I)] \quad (5)$$

其中 μ 是 $N*N$ 的拉格朗日乘子矩阵， I 为单位阵。

令 $Z = YX^T$, $Q(\mu) = XX^T + (\mu + \mu^T)/2$, 则式(7)可写为 $D^{-1} = Q(\mu)Z^{-1}$ 是一个正交阵, 即

$$Q(\mu)Z^{-1}(Z^{-1})^T Q^T(\mu) = I \quad (8)$$

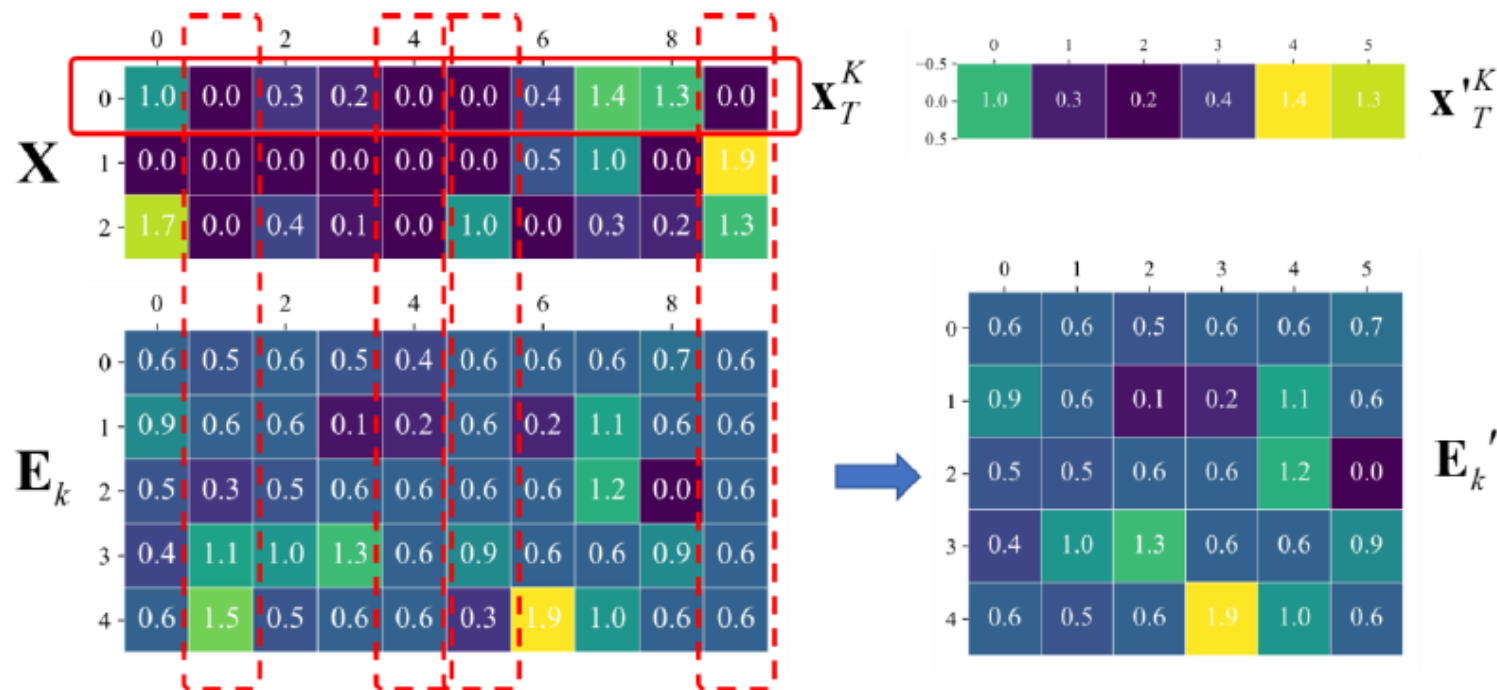
令 $Z = USV^T$ 是 Z 的奇异值分解, U, V 是正交阵, S 是对角阵。式(8)写为 $(Q(\mu)VS^{-1})(S^{-1}V^T Q^T(\mu)) = I$, 即下列矩阵是正定的:

$$W(\mu) = Q(\mu)VS^{-1} \quad (9)$$

注意到 $Q(\mu) = W(\mu)SV^T$ 一定对称, 所以 $W(\mu) = V\Lambda$, 其中 Λ 是对角线元素为 ± 1 的对角阵。 $D = U\Lambda V^T$ 有 2^N 个候选解, 但能使 L 最小化的唯一解为 $\Lambda = I$, 此时 $D = UV^T$ 。即使 Z 的 SVD 分解不唯一, 但 UV^T 一定是唯一的。

2.3 K-SVD

K-SVD 目标函数仍为(4)，目标是使 E_k 尽可能接近 $D_k X_k$ 。由于初始化 D 是超完备字典，必定存在冗余，首先去除 E_k 中对应 X_k 为 0 项对应的部分，简化计算，同时优化后的系数 X 中为 0 的部分仍是 0，保证稀疏性。



简化后的 X_k 记作 X_k^R ，相应地 E_k 记作 E_k^R 。此时目标函数(4)已经转化为

$$\min \|E_k^R - D_k X_k^R\|_F^2 \quad (10)$$

$D_k X_k^R$ 的秩为 1，直接分解 $E_k^R = U \Delta V^T$ ，找 SVD 分解后秩为 1 且最接近 $D_k X_k^R$ 的矩阵。由于矩阵经过奇异值分解后，奇异值的重要顺序是从上到下排列的，即靠前的都是比较重要的项，甚至有的矩阵的奇异值第一个远大于剩余的奇异值，则

K-SVD 步骤如下:

1. 在已知稀疏矩阵 X 以及数据样本 $\{y_i\}_{i=1}^N$ 的情况下, 给出要解决的问题:

$$\min_D \{ \|Y - DX\|_F^2 \} \quad s. t \quad \forall i, \|x_i\|_0 \leq T_0$$

2. 给出初始字典 $D^{(0)} \in R^{n \times K}$, 其中的列向量都是 l^2 范数下的标准形式。给定 $J = 1$ 。

3. 对 $D^{(J-1)}$ 中的每列 $k = 1, 2, \dots, K$ 进行迭代:

(1) 通过 $E_k = Y - \sum_{j \neq k} d_j x_T^j$ 来计算误差;

(2) 由 E_k 通过 ω_k 的限定得到 E_R^k ;

(3) 对 E_R^k 进行奇异值分解得到 $E_R^k = U\Delta V^T$, 令 \tilde{d}_k 是 U 的第一列, 则 \tilde{d}_k 是 d_k 更新的结果。同时, 用 V 的第一列和 $\Delta(1,1)$ 的乘积对 x_R^k 进行更新。

最后, $J = J + 1$ 继续重复迭代过程, 直到满足停止条件。

3. 参考文献

[K-means & K-SVD原理](#)

[最优方向法 \(MOD\)](#)

[K-SVD: 一种用于稀疏表示的过完备字典设计算法 || 论文翻译&解读&代码实现](#)

[K-SVD: An Algorithm for Designing Overcomplete Dictionaries for Sparse Representation](#)

[Learning Unions of Orthonormal Bases with Thresholded Singular Value Decomposition](#)

[机器学习中的数学\(5\)-强大的矩阵奇异值分解\(SVD\)及其应用](#)

[字典学习 \(Dictionary Learning, KSVD\) 详解](#)

周志华-机器学习