

宽度学习系统用于数据聚类

作者：凯鲁嘎吉 - 博客园 <http://www.cnblogs.com/kailugaji/>

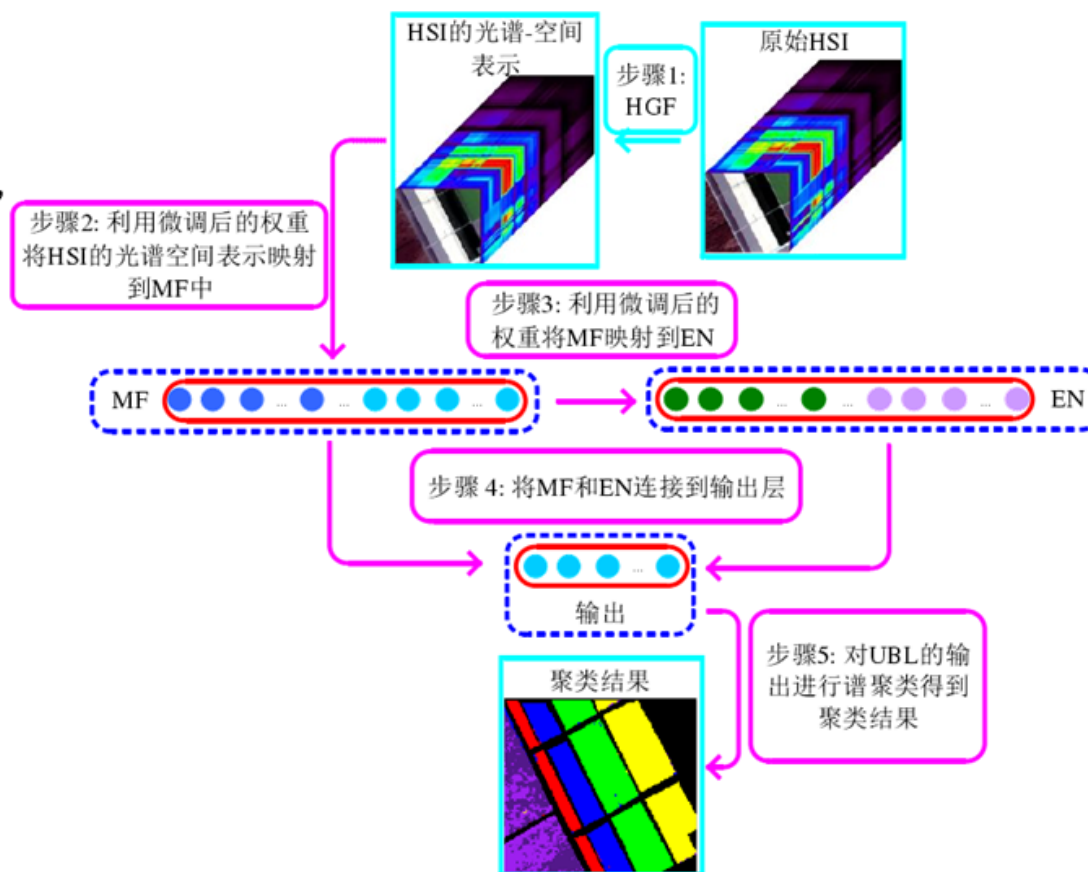
阅读本文的前提：[宽度学习系统\(Broad Learning System, BLS\)](#)。了解什么是宽度学习系统，有一篇文章是关于BLS的综述，适合BLS入门的初学者看，参看参考文献[2]。

本博文给出宽度学习系统用于聚类的一个应用实例——基于无监督宽度学习的高光谱图像聚类([Hyperspectral Image Clustering Based on Unsupervised Broad Learning](#))。由于高光谱图像(HSI)的大量训练样本难以标记，无监督聚类方法受到了广泛的关注。最近提出的宽度学习(BL)可以实现线性和非线性映射。然而，最初的BL是一个有监督的模型。本文提出了一种用于HSI聚类的新方法—无监督宽度学习(UBL)。首先，对UBL的输入和映射特征执行一个图正则化稀疏自编码器，以保持原始HSI的内在流形结构。然后，设计了由输出层权值的 l_2 范数和图正则化项组成的UBL目标函数，该目标函数可以通过选择最小特征值对应的特征向量来求解。最后，将谱聚类应用到UBL的输出上，得到HSI聚类结果。

➤ Flowchart of HSI Clustering Based on UBL

基于无监督宽度学习(UBL)的高光谱图像(HSI)聚类流程图包括五个步骤:

- 1) 利用分层引导滤波(HGF)对原始HSI进行预处理, 得到HSI的频谱空间表示;
- 2) 将光谱空间HSI表达式映射到映射特征层(Mapped Feature, MF), 并通过图正则化的稀疏自编码器(Graph Regularized Sparse Autoencoder, GRSAE)微调权重;
- 3) 用增强节点(Enhancement Node, EN)扩展MF的宽度, 并用GRSAE微调EN的权重;
- 4) 将MF和EN连接到输出层, 得到UBL的输出, 通过求解广义特征值分解问题, 可以很容易地得到UBL的输出层权重;
- 5) 对输出进行谱聚类, 得到聚类结果。



➤ 基于分层引导滤波(HGF)的光谱-空间特征提取

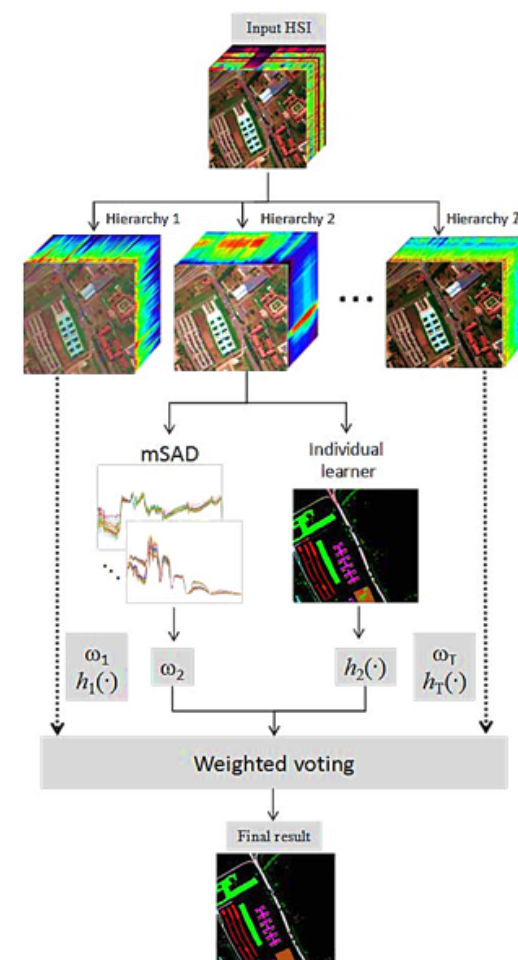
- 原始的高光谱图像是以3D张量的形式呈现的, 包含了丰富的光谱和空间信息, 如果直接对其向量化, 会导致: 1)维数的大幅增加;2)数据固有结构的破坏, 进而导致信息的损失。最近, HGF被用于获取HSI的光谱-空间表示, 其能够去除噪声和细节, 保留HSI的整体结构。因此, 本文首先利用HGF对原始高光谱图像进行预处理, 得到HSI的光谱-空间表示。
- 作为引导滤波和滚动引导滤波的扩展, HGF可以产生一系列光谱-空间特征。HGF最小化以下能量函数:

$$E(a_k^p, b_k^p) = \sum_{i \in \omega_k} ((a_k^p \mathbf{G}_i + b_k^p - \mathbf{I}_i^p)^2 + \epsilon a_k^{p2})$$

- 利用岭回归理论求解:

$$a_k^p = \frac{\frac{1}{|\omega|} \sum_{i \in \omega_k} \mathbf{I}_i^p \mathbf{G}_i - \mu_k \bar{\mathbf{I}}_k^p}{\sigma_k^2 + \epsilon}$$

$$b_k^p = \mathbf{I}_k^p - a_k^p \mu_k^p$$



B. Pan, Z. Shi and X. Xu, "Hierarchical Guidance Filtering-Based Ensemble Classification for Hyperspectral Images," in IEEE Transactions on Geoscience and Remote Sensing, vol. 55, no. 7, pp. 4177-4189, July 2017.

► Fine-Tune Weights of MF and EN With GRSAE

原始的BLS是随机生成MF和EN的连接权重。为获得更好的特征表示，Chen和Liu采用线性SAE对其进行微调。无论是用随机生成的权重映射输入数据，还是用线性SAE微调输入数据，得到的特征往往忽略了输入数据的内在结构。流形学习的目的是构造一个图，其中表示数据点的顶点通过边进行连接。结果表明，它能较好地表示数据之间的关系。通过加入图正则化项，可以保持输入数据的流形结构。本文将图正则化技术应用于MF和EN权重的微调过程，这样MF和EN就可以与输入数据保持相同的流形结构。

X : 输入数据, E : 映射特征节点, W : 特征权重, L : K 近邻得到的拉普拉斯矩阵。用ADMM对目标函数进行求解, 得到最终的 W 。

W 得到后, 线性映射通过特征层输出 Z , 再经非线性映射得到增强层输出 H 。


$$Z_i = XW_i^M \Rightarrow H = \sigma(ZW^E)$$

稀疏自编码器

图正则化

$$\arg \min_{W_i^M} \|XW_i^M - E_i\|_2^2 + \lambda \|W_i^M\|_1 + \alpha \sum_{i=1}^n \sum_{j=1}^n w_{ij} \|e_i - e_j\|_2^2$$

$$= \arg \min_{W_i^M} \|XW_i^M - E_i\|_2^2 + \lambda \|W_i^M\|_1 + \alpha \text{tr}(E_i^T L E_i)$$



➤ Unsupervised Broad Learning (UBL)

- 在无监督的情况下，无任何先验知识或标签信息可供利用。因此，在构造UBL目标函数时，需要首先去掉传统BLS中的经验风险项，仅保留输出层权重的 L_2 范数项。此外，为将原始HSI的流形结构传递到输出层，需要在目标函数中额外添加图正则项。

- UBL总体目标函数为

$$\arg \min_{W^m} \frac{1}{2} \left(\|W^m\|_2^2 + \zeta \text{Tr}([Z | H]^T (W^m)^T L^m W^m [Z | H]) \right)$$

UBL的图正则项参数 利用[Z|H]构造的K近邻得到的拉普拉斯矩阵

s.t. $(W^m)^T W^m = I$ 为避免广义特征值分解过程中存在的秩亏问题

- 可以通过计算下面式子中前c个最小特征值所对应的特征向量来得到 W^m

$$(I + \zeta [Z | H]^T L^m [Z | H]) W^m = \lambda [Z | H]^T [Z | H] W^m$$

- 得到 W^m 之后，UBL的输出为 $Y = [Z | H] W^m$
- 通过对Y进行谱聚类，得到最终的聚类结果 Y^c 。

Y. Kong, Y. Cheng, C. L. P. Chen and X. Wang, "Hyperspectral Image Clustering Based on Unsupervised Broad Learning," IEEE Geoscience and Remote Sensing Letters, vol. 16, no. 11, pp. 1741-1745, Nov. 2019.

参考文献:

- [1] Y. Kong, Y. Cheng, C. L. P. Chen and X. Wang, "[Hyperspectral Image Clustering Based on Unsupervised Broad Learning](#)," IEEE Geoscience and Remote Sensing Letters, vol. 16, no. 11, pp. 1741-1745, Nov. 2019.

[2] X. Gong, T. Zhang, C. L. P. Chen and Z. Liu, "[Research Review for Broad Learning System: Algorithms, Theory, and Applications](#)," IEEE Transactions on Cybernetics, doi: 10.1109/TCYB.2021.3061094.